

Université Claude Bernard Lyon 1



Institut de Physique des Deux Infinis de Lyon (IP2I)

Identification des particules hadroniques et reconstruction de l'énergie dans un calorimètre SDHCAL à l'aide de méthodes d'apprentissage automatique

RAPPORT DE STAGE

Année universitaire 2024–2025

Mohamed Yanis IDIR

Master Physique Subatomique

Encadré par :

Pr. Imad Laktineh, Université Lyon 1
Pr. Gérald Grenier, Université Lyon 1

Table des matières

Résumé **iv**

Remerciements **v**

Introduction **1**

1 Interactions particule–matière et développement des gerbes **5**
1.1 Interaction des particules avec la matière . . . 5
1.1.1 Particules chargées . . . 5
1.1.2 Hadrons et neutrons . . . 5
1.2 Gerbes électromagnétiques . . . 6
1.3 Gerbes hadroniques . . . 6
1.3.1 Développement et longueur d'interaction . . . 6
1.3.2 Fraction électromagnétique et rapport h/e . . . 7
1.3.3 Énergie invisible, fuites et résolution . . . 7
1.3.4 Structure temporelle et profils spatiaux . . . 8

2 Le calorimètre SDHCAL **9**
2.1 Concept et géométrie du prototype . . . 9
2.2 Détection dans les GRPC et lecture semi-digitale . . . 9
2.3 Simulation et digitalisation . . . 10
2.4 Validation expérimentale et performances de référence . . . 10

3 Identification hadronique dans le SDHCAL par apprentissage supervisé **12**
3.1 Enjeux physiques et signatures attendues . . . 12
3.2 Stratégie : pourquoi un apprentissage supervisé . . . 13
3.3 Données simulées et descripteurs physiques . . . 14
3.4 Protocole d'entraînement et métriques . . . 15
3.5 Résultats de classification . . . 15
3.5.1 Variables discriminantes . . . 18
3.5.2 Limites et systématiques . . . 19
3.6 Étude exploratoire : approche GNN . . . 20
3.7 Approfondissement de la confusion pion/proton . . . 21

4 Reconstruction de l'énergie **24**
4.1 Enjeux dans un calorimètre semi-digital . . . 24
4.2 Données disponibles et protocole d'évaluation . . . 24
4.3 Méthode paramétrique par comptage de seuils . . . 24

4.4 Ajustement des paramètres par minimisation d'une fonction pondérée . . . 25
4.5 Résultats de la méthode paramétrique . . . 25
4.6 Régression LightGBM . . . 26
4.7 Comparaison et portée des résultats . . . 27
4.7.1 Paramétrisation de la résolution . . . 28
4.7.2 La coupure de confinement et ce qu'elle impose . . . 28
4.7.3 Reconstruction au niveau des hits . . . 29
4.8 Limites et systématiques . . . 32

5 Analyse sur échantillons mixtes 33
5.1 Motivation et scénarios comparés . . . 33
5.2 Chaîne PID + régression BDT . . . 33
5.3 Chaîne PID + méthode paramétrique . . . 33
5.4 Référence pion appliquée à toutes les espèces . . . 33
5.5 Comparaison quantitative à 20 et 80 GeV . . . 37
5.6 Limites de l'analyse . . . 37
5.7 Lever la réserve : le gain vient-il du PID ou du régresseur ? . . . 38

Conclusion générale 39

Perspectives 41

A Descripteurs de gerbe : définitions 42
A.1 Principe et inventaire . . . 42
A.2 Variables liées aux seuils semi-digitaux . . . 42
A.3 Descripteurs longitudinaux . . . 43
A.4 Descripteurs transverses et géométriques . . . 43
A.5 Densité locale et structure en amas . . . 44
A.6 Variables temporelles . . . 45
A.7 Profil longitudinal et ajustement de Gaisser–Hillas . . . 46
A.8 Recherche de segments quasi-linéaires . . . 46
A.9 Corrections apportées à l'implémentation . . . 47
A.10 Hiérarchie des variables et tableau récapitulatif . . . 48

Annexes 42

B Configuration du classificateur PID 51
B.1 Jeux de données et variables d'entrée . . . 51
B.2 Nettoyage et prétraitement . . . 51
B.3 Protocole d'apprentissage . . . 52
B.4 Rééquilibrage des classes par SMOTE . . . 53
B.5 Modèle et hyperparamètres . . . 54
B.6 Métriques d'évaluation . . . 54

C Classification hadronique par réseaux sur amas **55**
C.1 Données et prétraitement des nœuds . . . 55
C.2 Construction du graphe . . . 55
C.3 Architecture et entraînement . . . 56
C.4 Résultats, limites et perspectives . . . 57
C.5 Tableau récapitulatif . . . 58

D Régression de l'énergie avec LightGBM **59**
D.1 Données et variables d'entrée . . . 59
D.2 Apprentissage en espace logarithmique . . . 60
D.3 Modèle et hyperparamètres . . . 60
D.4 Métriques d'évaluation . . . 61

E Reconstruction d'énergie par méthode paramétrique χ^2 **62**
E.1 Sélection des événements et prétraitement . . . 62
E.2 Procédure numérique avec `TMinuit` . . . 62
E.3 Calcul de l'énergie reconstruite . . . 63
E.4 Chaîne PID + reconstruction paramétrique . . . 63
E.5 Forces et limites de la méthode . . . 66
E.6 Tableau récapitulatif . . . 66

F Compléments sur le détecteur et l'identification hadronique **67**
F.1 Électronique de lecture et acquisition . . . 67
F.2 Signatures calorimétriques attendues . . . 67
F.3 Corrélations entre variables d'entrée . . . 68

Résumé

La mesure précise de l'énergie des hadrons constitue un enjeu majeur de la physique des hautes énergies. Contrairement aux gerbes électromagnétiques, relativement stables et bien modélisées, les gerbes hadroniques présentent d'importantes fluctuations événement par événement, liées notamment à la fraction électromagnétique, aux pertes d'énergie invisibles ainsi qu'aux fuites longitudinales et latérales. Ces effets dégradent la linéarité de la réponse calorimétrique et limitent la résolution en énergie.

Le *Semi-Digital Hadron CALorimeter* (SDHCAL) propose une approche originale fondée sur une très haute granularité spatiale associée à une lecture semi-digitale à trois seuils. Une telle architecture permet d'accéder finement à la topologie des gerbes hadroniques et ouvre des perspectives intéressantes aussi bien pour l'identification des particules que pour la reconstruction de leur énergie.

Dans ce travail, une chaîne d'analyse complète a été développée et appliquée à des échantillons simulés de pions, protons et kaons neutres longs. L'identification hadronique repose principalement sur des arbres de décision boostés (*Boosted Decision Trees*, BDT), tandis qu'une étude exploratoire de réseaux de neurones graphiques (GNN) a également été menée. Pour la reconstruction de l'énergie, deux approches ont été comparées : une méthode paramétrique fondée sur une minimisation pondérée des écarts entre énergie reconstruite et énergie vraie, et une régression supervisée par BDT exploitant un ensemble enrichi de descripteurs de gerbe.

Les performances ont ensuite été étudiées dans plusieurs scénarios combinant identification des particules et reconstruction d'énergie. Le classificateur multiclasse atteint une accuracy équilibrée de 67.8 %, avec une séparation nettement meilleure des K_L^0 que des pions et des protons. L'introduction du PID agit surtout sur le biais de reconstruction : à 80 GeV, la chaîne BDT + BDT maintient le biais des trois espèces en dessous de 1 %. Les différences de dispersion entre scénarios restent plus limitées.

Cette étude met en évidence l'intérêt d'exploiter conjointement la morphologie des gerbes, l'information semi-digitale et l'identification de l'espèce. Ses performances reposent toutefois sur la simulation ; leur transfert à une mesure expérimentale nécessitera une confrontation aux données de faisceau et une étude dédiée des incertitudes systématiques.

Mots-clés : SDHCAL, calorimétrie hadronique, identification des particules, reconstruction d'énergie, apprentissage automatique.

Remerciements

Je tiens à exprimer ma profonde gratitude à mes encadrants de stage, le Pr. Imad Laktineh et le Pr. Gérald Grenier, pour la confiance qu'ils m'ont accordée, la qualité de leur accompagnement scientifique et la pertinence de leurs conseils. J'ai énormément appris à leurs côtés ; leur exigence, leur disponibilité et leur bienveillance ont été déterminantes tout au long de ce travail.

Je souhaite également adresser mes remerciements chaleureux aux doctorants William Vaginey et Tanguy Pasquier, qui m'ont guidé au quotidien, répondu avec patience à mes nombreuses questions et partagé de précieux conseils pratiques.

Enfin, je remercie l'ensemble de l'équipe « Particules » ainsi que tout l'IP2I pour leur accueil, leurs échanges stimulants et l'excellente ambiance de travail, qui ont rendu ce stage particulièrement enrichissant et agréable.

Introduction

La mesure précise de l'énergie des hadrons demeure l'un des défis historiques de la calorimétrie en physique des hautes énergies. Contrairement aux gerbes électromagnétiques, relativement bien comprises et caractérisées par des fluctuations modérées, les gerbes hadroniques présentent une variabilité importante d'un événement à l'autre. La fraction électromagnétique, l'énergie invisible liée aux processus nucléaires, ainsi que les fuites longitudinales et latérales dégradent directement la linéarité de réponse et la résolution énergétique des calorimètres hadroniques. Ces limitations constituent un enjeu majeur pour les détecteurs de nouvelle génération.

Quelles particules, quelle mesure. Le *Modèle Standard* constitue le cadre théorique de référence pour décrire les particules élémentaires et trois des quatre interactions fondamentales [1, 2]. Les particules qu'il décrit sont représentées Figure 1. Dans le contexte de la calorimétrie hadronique, les objets effectivement observés ne sont toutefois pas les quarks eux-mêmes : le confinement de couleur interdit de les observer isolément [3], et les états finals sont constitués de hadrons — baryons (qqq) et mésons ($q\bar{q}$) — dont l'interaction avec la matière absorbante repose sur des processus nucléaires inélastiques complexes.

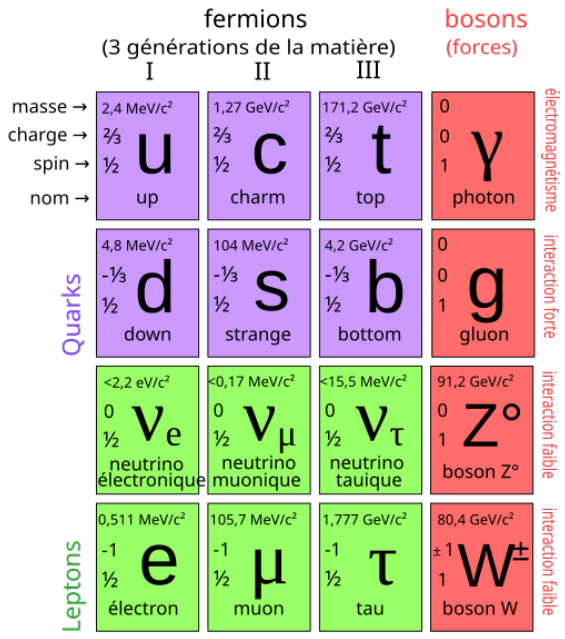


FIGURE 1. Particules élémentaires décrites par le Modèle Standard [4].

Ce travail porte sur trois espèces hadroniques représentatives, choisies pour leurs signatures calorimétriques distinctes : les pions chargés π^-, les protons p et les kaons neutres K^0. Leurs propriétés fondamentales et les conséquences calorimétriques qui en découlent sont rassemblées au Tableau 3.1,

au chapitre 3.

Pourquoi la résolution énergétique est le verrou. Dans les expériences de physique des hautes énergies, une fraction importante de l'énergie finale est transportée par des hadrons organisés en jets, et la mesure de ces jets repose de manière déterminante sur les calorimètres hadroniques. Or les gerbes hadroniques présentent des fluctuations importantes liées aux processus nucléaires inélastiques, à l'énergie invisible et aux fuites, ce qui dégrade la résolution énergétique. Ces limitations constituent la motivation centrale du développement de calorimètres à haute granularité.

Dans les approches de type *Particle Flow Algorithm* (PFA) [5], la mesure des jets repose sur la combinaison optimale des différents sous-détecteurs. Dans ce cadre, le calorimètre hadronique (HCAL) occupe une place centrale : sa granularité, sa capacité de séparation spatiale et la qualité de sa reconstruction énergétique conditionnent fortement la performance globale du détecteur.

C'est dans cette perspective qu'a été développé le *Semi-Digital Hadron CALorimeter* (SDHCAL), au sein de la collaboration CALICE. Ce concept associe une segmentation spatiale très fine, reposant sur des cellules centimétriques, à une lecture semi-digitale sur trois seuils codés sur deux bits. Une telle architecture permet de conserver une information calorimétrique riche tout en maîtrisant le volume de données et la consommation électronique. La haute granularité obtenue ouvre également la voie à une analyse détaillée de la morphologie des gerbes, aussi bien pour l'identification de particules (*Particle Identification*, PID) que pour la reconstruction d'énergie.

Parallèlement, les méthodes d'apprentissage automatique (*Machine Learning*) occupent désormais une place croissante en physique des particules. Après les premières approches multivariées popularisées notamment via TMVA [6], des techniques plus récentes telles que les arbres de décision boostés, les réseaux convolutionnels ou les réseaux de neurones graphiques ont démontré leur capacité à exploiter efficacement la complexité des données issues des détecteurs modernes [7, 8].

Le présent travail s'inscrit dans cette dynamique et propose une chaîne d'analyse complète appliquée à un prototype SDHCAL simulé, intégrant à la fois **l'identification hadronique** et la **reconstruction de l'énergie**. Deux approches de reconstruction énergétique sont étudiées :

(i) une méthode paramétrique fondée sur la minimisation d'un χ^2 utilisant les compteurs multi-seuils (N_1, N_2, N_3) ;

(ii) une régression supervisée par arbres de décision boostés (*Boosted Decision Trees*, BDT), exploitant un ensemble étendu de descripteurs de gerbe.

L'identification des particules repose également sur un classifieur BDT, complété par une étude exploratoire basée sur les réseaux de neurones graphiques (GNN).

Motivation du PID dans les données de type faisceau. Dans les études expérimentales de calorimétrie hadronique, la calibration du détecteur est généralement réalisée à partir de faisceaux dominés par des pions, qui constituent une espèce abondante et relativement bien contrôlée. Cette calibration pion sert ensuite de référence pour reconstruire l'énergie des gerbes hadroniques. Toutefois, en pratique, les faisceaux utilisés lors des tests ne sont pas parfaitement purs : ils présentent des contaminations non négligeables en protons, électrons ou muons, dont la proportion peut varier avec l'énergie et les conditions expérimentales. Lors des tests du prototype SDHCAL au SPS, le faisceau de pions positifs de la ligne H6 était ainsi contaminé par des protons au-delà de 20 GeV, la contamination atteignant

45 à 60 % entre 50 et 100 GeV — en l'absence de détecteur Cherenkov permettant de séparer les deux espèces [9]. Sans dispositif d'identification dédié en amont du calorimètre, l'espèce incidente n'est donc pas connue événement par événement.

Or, les différentes particules hadroniques n'interagissent pas de manière identique dans le calorimètre. Les protons, par exemple, présentent une longueur d'interaction plus courte que celle des pions dans l'acier — 16,8 cm contre 20,4 cm [9] — de sorte qu'ils amorcent leur gerbe plus tôt en moyenne et subissent moins de fuites longitudinales, ce qui modifie le développement de la gerbe et son confinement. De même, la fraction électromagnétique, fortement liée à la production de π^0, peut fluctuer différemment selon l'espèce incidente. L'application d'une calibration unique, dérivée des pions, à un échantillon contenant un mélange de particules introduit ainsi un biais potentiel dans la reconstruction de l'énergie.

Dans ce contexte, l'identification des particules apparaît comme un levier essentiel pour améliorer les performances du détecteur. En distinguant les espèces incidentes à partir de la topologie de leur gerbe, il devient possible d'appliquer des calibrations spécifiques à chaque type de particule, ou à défaut de mieux contrôler les effets de mélange. Cette approche permet de rapprocher les conditions expérimentales réelles d'un scénario idéal dans lequel l'espèce incidente serait parfaitement connue, et constitue une motivation centrale du développement de méthodes de PID dans le SDHCAL.

Trois scénarios de référence. Afin de quantifier l'impact de cette information, les performances de reconstruction sont étudiées selon trois configurations représentatives :

(i) **Référence pion universelle** : calibration paramétrique déterminée sur les pions et appliquée à toutes les espèces ; cette référence simple n'est pas une borne inférieure générale, car elle n'est pas optimisée comme estimateur inclusif ;

(ii) **PID + calibration paramétrique** : routage des événements selon la classe prédite, puis application de la calibration analytique correspondante ;

(iii) **PID + régression BDT** : même routage, suivi d'un modèle de régression spécifique à la classe prédite.

Une reconstruction utilisant directement l'espèce vraie de la simulation constitue par ailleurs un cas idéal utile pour interpréter les méthodes, mais elle ne correspond pas à une chaîne expérimentale accessible. La comparaison retenue permet surtout d'évaluer dans quelle mesure le PID réduit les biais dus à l'application d'une calibration unique à un mélange d'espèces.

Objectifs du travail. Les objectifs principaux de cette étude sont les suivants :

1. **Extraire des observables discriminantes** et robustes pour le PID et la reconstruction d'énergie, en s'appuyant sur la topologie des gerbes ;
2. **Comparer approches paramétrique et supervisée** en termes de linéarité, de biais et de résolution ;
3. **Quantifier l'apport du PID** sur la performance énergétique dans des échantillons mixtes ;
4. **Explorer les approches fondées sur les graphes** pour les calorimètres hautement granulaires.

Organisation du mémoire. Le manuscrit est organisé comme suit. Le chapitre 1 rappelle les mécanismes d'interaction particule–matière et le développement des gerbes, en insistant sur les grandeurs

qui gouvernent la réponse d'un calorimètre hadronique. Le chapitre 2 présente le prototype SDHCAL, sa lecture semi-digitale et sa chaîne de simulation. Le chapitre 3 est consacré à l'identification hadronique par apprentissage supervisé, et le chapitre 4 à la reconstruction de l'énergie par les deux approches comparées. Le chapitre 5 réunit les deux volets sur des échantillons mixtes, avant la conclusion. Les détails de mise en œuvre — calcul des descripteurs, configuration des modèles et procédures numériques — sont reportés en annexe.

Chapitre 1

Interactions particule–matière et développement des gerbes

Selon leur nature, leur charge et leur énergie, les particules incidentes déposent leur énergie par ionisation, rayonnement ou interactions nucléaires, donnant naissance à des cascades secondaires appelées **gerbes**. Ce chapitre rappelle les grandeurs qui gouvernent ce développement et qui seront remobilisées pour interpréter la réponse du SDHCAL.

1.1 Interaction des particules avec la matière

1.1.1 Particules chargées

Dans un milieu, une particule chargée perd principalement de l'énergie par **ionisation** et **excitation** des atomes. La dépendance moyenne du pouvoir d'arrêt suit la loi de Bethe–Bloch [10, 4] :

$$\left\langle -\frac{\mathrm{d}E}{\mathrm{d}x} \right\rangle = K z^2 \frac{Z}{A} \frac{1}{\beta^2} \left[\frac{1}{2} \ln\left(\frac{2 m_e c^2 \beta^2 \gamma^2 T_{\max}}{I^2} \right) - \beta^2 - \frac{\delta}{2} \right], \tag{1.1}$$

où $K = 4\pi N_A r_e^2 m_e c^2$, z est la charge de la particule incidente, Z/A le rapport le rapport du numéro atomique au nombre de masse du milieu, I le potentiel moyen d'excitation, $T_{\max}$ l'énergie maximale transférable à un électron libre et δ le terme de correction de densité [4].

Cette expression présente un *minimum d'ionisation* pour $\beta\gamma \simeq 3$–4 (régime de la particule au minimum d'ionisation, MIP). Dans la gamme d'énergies considérée pour le SDHCAL (1–130 GeV), l'ionisation domine pour les hadrons et les muons, ce qui justifie l'usage du MIP comme unité de calibration et motive la lecture multi-seuils pour caractériser la densité locale de dépôt. Le *bremsstrahlung* ne domine que pour les $e^{\pm}$ au-delà de l'énergie critique, que le PDG paramétrise par $E_c \simeq 610\,\mathrm{MeV}/(Z+1{,}24)$ pour les solides [4] — soit environ 22 MeV dans le fer — et reste donc marginal ici.

Les photons, quant à eux, interagissent via l'*effet photoélectrique* à basse énergie (keV), la *diffusion Compton* aux énergies intermédiaires (quelques MeV), puis la *création de paires* $\gamma \to e^+e^-$ à haute énergie ($\gg 2m_e c^2$) [4]. Dans le SDHCAL, ces mécanismes contribuent essentiellement à la composante électromagnétique des gerbes, alimentée par la désintégration $\pi^0 \to \gamma\gamma$.

1.1.2 Hadrons et neutrons

Les hadrons chargés perdent d'abord de l'énergie par ionisation, mais, soumis à l'**interaction forte**, leurs processus d'interaction sont beaucoup plus complexes. Lorsqu'un hadron incident interagit avec un noyau, il déclenche une **spallation nucléaire** [11, 12] en deux étapes : une **cascade intranucléaire**, au cours de laquelle le hadron induit des collisions secondaires — certains hadrons produits s'échappent

du noyau, d'autres sont réabsorbés — puis la **désexcitation du noyau**, par évaporation de protons, de neutrons et de particules α, suivie d'émission de γ.

Ce processus est hautement stochastique, et une fraction de l'énergie reste **invisible aux calorimètres** : énergie de liaison nucléaire consommée lors de la spallation, recul du noyau résiduel, et neutrons secondaires faiblement ou tardivement détectés — ces derniers produisant, selon leur énergie, des signaux retardés ou délocalisés par diffusion élastique, diffusion inélastique ou capture radiative [11, 13]. Cette combinaison d'ionisation, d'interactions fortes et de cascades nucléaires, avec une part d'énergie non détectée, explique la difficulté à atteindre une résolution comparable à celle des calorimètres électromagnétiques [14, 12].

Enfin, les **hadrons neutres** tels que le K^0 n'ionisent pas et ne déposent de l'énergie que via ces interactions nucléaires, ce qui rend leur point de départ de gerbe nettement plus variable. Cette propriété sera exploitée au chapitre 3.

1.2 Gerbes électromagnétiques

Les gerbes électromagnétiques (EM) sont initiées par des électrons, des photons, ou par des $\pi^0 \to \gamma\gamma$ [15, 16]. Elles résultent de l'alternance entre *bremsstrahlung* ($e^\pm \to e^\pm\gamma$) et *création de paires* ($\gamma \to e^+e^-$), jusqu'à ce que l'énergie descende sous l'énergie critique E_c, où l'ionisation devient dominante. Leur structure est fixée par deux grandeurs [4] : la **longueur de radiation** X_0, distance sur laquelle un électron perd en moyenne $1/e$ de son énergie par bremsstrahlung, qui donne l'échelle longitudinale ; et le **rayon de Molière** $R_M \approx 21\,\text{MeV} \cdot X_0/E_c$, qui définit l'extension transverse — environ 90% de l'énergie est contenue dans un cylindre de rayon R_M. Elles constituent une référence utile : leur développement est compact, régulier et bien modélisé, contrairement aux gerbes hadroniques.

1.3 Gerbes hadroniques

Lorsqu'un hadron de haute énergie pénètre dans un matériau absorbant, il initie une **gerbe hadronique** — une cascade complexe de particules secondaires résultant d'interactions nucléaires successives. Contrairement au cas électromagnétique, ces gerbes présentent d'importantes fluctuations événement par événement dans leur composition, leur extension spatiale et la fraction d'énergie effectivement détectée [12, 14].

1.3.1 Développement et longueur d'interaction

La gerbe débute par une interaction inélastique du hadron incident avec un noyau du milieu, produisant pions chargés et neutres, kaons, nucléons secondaires et fragments nucléaires ; les hadrons secondaires suffisamment énergétiques alimentent la cascade à leur tour. Une caractéristique essentielle est la production de π^0, qui se désintègrent quasi instantanément selon $\pi^0 \to \gamma\gamma$ et initient des sous-gerbes électromagnétiques imbriquées. La fraction d'énergie dérivée vers cette composante EM fluctue fortement d'un événement à l'autre et constitue la principale source de variabilité de la réponse calorimétrique.

Le développement longitudinal est gouverné par la **longueur d'interaction nucléaire** [4] :

$$\lambda_I = \frac{A}{N_A \rho \sigma_{\text{inel}}}, \tag{1.2}$$

où A est la masse molaire du matériau, ρ sa densité, N_A le nombre d'Avogadro et σ_{inel} la section efficace inélastique hadron-noyau.

TABLE 1.1. Comparaison des longueurs caractéristiques pour quelques matériaux d'absorbeur courants [4].

Matériau	Z	X_0 (cm)	λ_I (cm)	λ_I / X_0
Fer (Fe)	26	1.76	16.77	9.5
Plomb (Pb)	82	0.56	17.59	31.4
Acier inox	–	1.76	16.77	9.5
Tungstène (W)	74	0.35	9.95	28.4

Le Tableau 1.1 montre que, quelle que soit la densité du matériau, λ_I reste toujours bien supérieure à X_0 : les gerbes hadroniques sont plus profondes et plus diffuses que les gerbes électromagnétiques, ce qui impose des calorimètres plus épais et moins bien contenus.

1.3.2 Fraction électromagnétique et rapport h/e

La fraction d'énergie transférée à la composante EM via la production de π^0 est appelée **fraction électromagnétique**, $f_{\text{em}} = E_{\text{EM}}/E_{\text{tot}}$. En moyenne, elle croît avec l'énergie incidente selon une loi approximative [12] :

$$\langle f_{\text{em}} \rangle \approx 1 - \left(\frac{E}{E_0}\right)^{m-1}, \tag{1.3}$$

avec E_0 et m des paramètres dépendant du matériau et de l'espèce hadronique. Toutefois, f_{em} fluctue fortement d'un événement à l'autre, même à énergie fixée. La réponse moyenne d'un calorimètre à une gerbe hadronique s'écrit alors [12] :

$$\langle E_\pi \rangle = \left[f_{\text{em}} + (1 - f_{\text{em}}) \frac{h}{e} \right] E, \tag{1.4}$$

où e et h désignent respectivement les réponses électromagnétique et hadronique du détecteur. Un calorimètre est dit **compensant** lorsque $h/e = 1$, ce qui minimise l'effet des fluctuations de f_{em} sur la résolution. Hors compensation, ces fluctuations constituent la contribution dominante à la non-linéarité et à la dégradation de la résolution énergétique.

1.3.3 Énergie invisible, fuites et résolution

L'énergie invisible évoquée plus haut est intrinsèquement variable d'un événement à l'autre [14] ; s'y ajoutent les **fuites longitudinales ou latérales**, lorsque la gerbe n'est pas totalement contenue dans le volume instrumenté. La paramétrisation standard de la résolution énergétique d'un calorimètre hadronique est alors [14] :

$$\frac{\sigma(E)}{E} = \frac{a}{\sqrt{E/\text{GeV}}} \oplus b \oplus \frac{c}{E/\text{GeV}}, \tag{1.5}$$

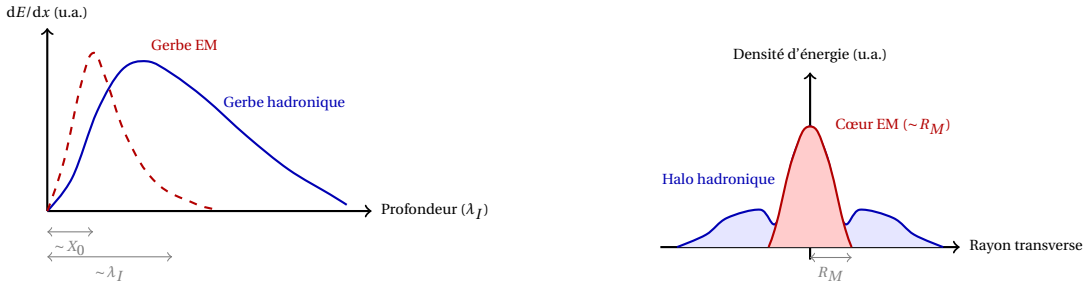
où a est le terme stochastique (dominé par les fluctuations de f_{em} et les fluctuations d'échantillonnage), b le terme constant (effets systématiques, non-uniformités, fuites) et c le terme de bruit

électronique. Cette décomposition sera ajustée sur les résultats du chapitre 4, où elle permet de distinguer ce qui relève des fluctuations de gerbe de ce qui relève des limites instrumentales.

1.3.4 Structure temporelle et profils spatiaux

Les cascades hadroniques ont une structure temporelle plus étendue que les gerbes électromagnétiques : une partie du signal est déposée rapidement par les particules relativistes, d'autres contributions apparaissent plus tardivement via les neutrons ralentis puis capturés, avec des temps caractéristiques de quelques dizaines de nanosecondes. La réponse mesurée dépend donc de la fenêtre temporelle d'acquisition, aspect pertinent pour le SDHCAL dont les variables temporelles constituent des descripteurs potentiellement discriminants pour le PID (chapitre 3).

Spatialement, le profil longitudinal présente une montée rapide suivie d'une décroissance lente, tandis que le profil transverse se compose d'un **cœur dense**, enrichi en composante électromagnétique et de rayon proche de R_M, entouré d'une **région périphérique diffuse**, dominée par les hadrons secondaires et les neutrons, qui s'étend jusqu'à plusieurs λ_I.



(a) Profils longitudinaux comparés.

(b) Profil transverse d'une gerbe hadronique.

FIGURE 1.1. (a) Profils longitudinaux comparés d'une gerbe hadronique (bleu) et électromagnétique (rouge pointillé) ; les échelles caractéristiques X_0 et λ_I sont indiquées. (b) Profil transverse d'une gerbe hadronique montrant le cœur électromagnétique compact (rouge) et le halo hadronique étendu (bleu).

Les fluctuations de f_{em}, les profils spatiaux différenciés selon l'espèce et la structure temporelle des dépôts constituent autant d'observables exploitables pour le PID et la reconstruction d'énergie — à condition de disposer d'un calorimètre suffisamment granulaire pour les mesurer finement. C'est précisément l'objet du détecteur décrit au chapitre suivant.

Chapitre 2

Le calorimètre SDHCAL

2.1 Concept et géométrie du prototype

Le *Semi-Digital Hadron CALorimeter* (SDHCAL) est un calorimètre hadronique hautement granulaire développé dans le cadre de la collaboration CALICE [17, 9], dans le contexte des futurs collisionneurs linéaires [18], où la reconstruction précise des jets impose une excellente séparation spatiale des particules et une mesure fiable des gerbes hadroniques.

Contrairement aux calorimètres conventionnels, il ne repose pas uniquement sur une mesure globale de l'énergie déposée : son principe consiste à exploiter la structure tridimensionnelle des gerbes, en combinant une granularité spatiale fine et une lecture à trois seuils conservant l'information de densité locale des dépôts. Cette approche est particulièrement adaptée aux algorithmes de type *Particle Flow Algorithm* [5, 19].

Le prototype est un calorimètre à échantillonnage constitué de 48 couches actives insérées entre des plaques d'acier inoxydable de 2 cm d'épaisseur [17], soit une profondeur totale d'environ $6\,\lambda_I$. Chaque couche active couvre 96×96 cm^2 et est segmentée en pads de 1×1 cm^2, soit 9216 cellules indépendantes par plan, ce qui donne accès à une image tridimensionnelle détaillée du développement des cascades.

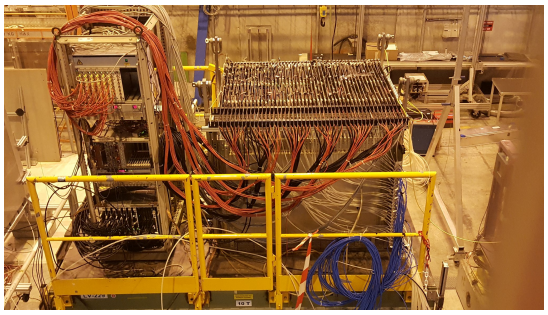


FIGURE 2.1. Vue du prototype SDHCAL instrumenté lors d'une campagne de test faisceau.

2.2 Détection dans les GRPC et lecture semi-digitale

Les détecteurs actifs utilisés sont des chambres résistives à plaques de verre, ou *Glass Resistive Plate Chambers* (GRPC) [20] : deux plaques de verre séparées par un faible entrefer gazeux, dans lequel se développe l'avalanche induite par le passage d'une particule chargée. Le signal induit est collecté sur les pads de lecture situés à proximité de l'anode ; la charge mesurée dépend du nombre d'ionisations initiales, de la position de passage, des conditions de champ électrique, de la composition du gaz et des fluctuations propres à l'avalanche. Ces chambres offrent un coût modéré pour de grandes surfaces, une bonne homogénéité spatiale, une efficacité élevée pour les particules au minimum d'ionisation et une compatibilité naturelle avec une lecture segmentée en pads [20, 21].

L'originalité du SDHCAL réside dans sa lecture semi-digitale codée sur deux bits : trois seuils de charge $T_1 < T_2 < T_3$ sont appliqués à chaque canal, et chaque hit est classé selon le plus haut seuil franchi, ce qui permet de distinguer les dépôts isolés, les régions de densité intermédiaire et les zones très denses de la gerbe. Une lecture purement digitale saturerait dans les régions centrales des gerbes ; la lecture semi-digitale conserve une sensibilité à la densité locale tout en maintenant une électronique plus simple qu'une lecture analogique complète.

Les observables directement accessibles sont le nombre total de hits, les compteurs par seuil N_1, N_2, N_3, les fractions relatives entre seuils, les distributions spatiales des hits et les densités locales de dépôt. Elles constituent la base des méthodes de reconstruction d'énergie et d'identification hadronique étudiées dans ce mémoire. L'électronique de lecture embarquée qui produit ces signaux est décrite en Annexe F.

2.3 Simulation et digitalisation

L'étude présentée dans ce mémoire repose sur une chaîne de simulation basée sur l'environnement iLCSoft, utilisant Geant4 [22, 23] pour la propagation des particules dans le détecteur. La simulation fournit les dépôts d'énergie élémentaires dans les couches actives.

Une étape de digitalisation transforme ensuite ces dépôts physiques en hits comparables à ceux produits par l'électronique réelle : sélection temporelle des dépôts, application d'une efficacité de détection, génération d'une charge induite fluctuante, diffusion transverse vers les pads voisins, puis application des trois seuils semi-digitaux. La sortie contient, pour chaque hit, ses coordonnées discrètes (I, J, K), le seuil franchi, un horodatage et l'identifiant de l'événement, converties ensuite en formats `ROOT` [24] et `CSV`. Cette étape est déterminante pour la suite : toutes les observables exploitées dans les chapitres 3 et 4 sont construites à partir de ces hits digitalisés, et non des dépôts d'énergie continus fournis par Geant4.

2.4 Validation expérimentale et performances de référence

Le prototype a été étudié au CERN avec des faisceaux de muons, d'électrons et de hadrons entre 5 et 80 GeV [17, 9]. Dans l'étude publiée des données de 2012, une digitalisation fondée sur Geant4 et la liste de physique FTFP-BERT-HP est ajustée sur les réponses aux muons et aux électrons, puis confrontée aux distributions hadroniques. La comparaison porte notamment sur le nombre total de hits, les distributions par seuil N_1, N_2, N_3, l'efficacité MIP et la multiplicité des pads. Elle fournit un cadre expérimental pour tester la digitalisation et estimer les incertitudes de modélisation ; elle ne constitue toutefois pas une validation automatique des échantillons simulés employés dans ce mémoire, dont les conditions de production doivent être documentées séparément.

Les données de faisceau donnent également un ordre de grandeur de référence pour la reconstruction d'énergie. À 80 GeV, la résolution publiée en mode semi-digital est de $7.5 \pm 0.3\,\%$ sur la ligne H6 et de $7.7 \pm 0.5\,\%$ sur la ligne H2, contre respectivement $9.5 \pm 0.3\,\%$ et $10.6 \pm 0.8\,\%$ en mode binaire [9]. L'avantage des trois seuils apparaît surtout au-dessus de 30 GeV, lorsque la saturation locale devient importante. Ces valeurs sont des mesures sur données réelles, obtenues avec leurs propres sélections et ajustements de distributions ; elles servent ici de repère expérimental et ne sont pas comparées numériquement aux indicateurs historiques de dispersion de cette étude sur simulation.

Grâce à l'information multi-seuil, l'énergie incidente y est estimée à partir d'une combinaison pondérée des compteurs de hits N_1, N_2, N_3, dont les coefficients dépendent du nombre total de hits [9]. Cette méthode, reprise et étudiée en détail au chapitre 4, sert de référence paramétrique dans ce travail.

Le concept a naturellement ses limites : dépendance des chambres gazeuses aux conditions opératoires, nécessité d'une calibration précise, et profondeur finie du prototype aux plus hautes énergies — cette dernière contrainte se manifestera directement dans les résultats du chapitre 4.

Chapitre 3

Identification hadronique dans le SDHCAL par apprentissage supervisé

La granularité du SDHCAL et sa lecture à trois seuils donnent accès à la morphologie des gerbes au-delà du seul nombre total de hits. Ce chapitre étudie dans quelle mesure cette information permet de distinguer les espèces hadroniques avant d'appliquer une reconstruction d'énergie adaptée.

3.1 Enjeux physiques et signatures attendues

L'identification des particules (*Particle Identification*, PID) constitue une étape importante dans les expériences de physique des hautes énergies. Dans les états finals hadroniques, les particules produites forment souvent des jets issus de la fragmentation de quarks et de gluons, et une mauvaise identification des espèces peut conduire à une association incorrecte des dépôts d'énergie, à une calibration inadéquate ou à une dégradation de la résolution globale [4]. Une telle séparation est importante non seulement pour la classification des événements, mais aussi pour la reconstruction de l'énergie, puisque la réponse calorimétrique dépend de l'espèce incidente. Elle s'inscrit plus largement dans la logique des approches de type *Particle Flow*, où la qualité de la reconstruction globale repose sur une identification correcte des objets détectés.

Les trois espèces étudiées présentent des différences de masse, de charge et de structure interne qui influencent leur mode d'interaction avec la matière et donc la structure moyenne de leurs gerbes. Ces propriétés, et les conséquences calorimétriques attendues, sont rassemblées dans le Tableau 3.1. Les **pions chargés** sont des mésons légers : avant leur première interaction nucléaire, ils déposent de l'énergie par ionisation dans les premières couches du calorimètre, puis la production de pions neutres secondaires, suivie de la désintégration $\pi^0 \to \gamma\gamma$, alimente la composante électromagnétique de la cascade — leurs gerbes présentent ainsi souvent un développement relativement précoce et un cœur électromagnétique marqué. Les **protons** sont des baryons de masse plus élevée, dont la nature baryonique modifie la dynamique de la cascade, notamment à travers la conservation du nombre baryonique : à énergie identique, leurs gerbes tendent en moyenne à être plus hadroniques, plus profondes et plus diffuses, avec une fraction électromagnétique généralement plus faible. Les **kaons neutres**, enfin, ne portent pas de charge électrique et ne déposent donc pas d'énergie par ionisation avant leur première interaction nucléaire ; le point de départ de leur gerbe, gouverné par leur libre parcours moyen dans le matériau, est nettement plus variable, et leur contenu en étrangeté implique des voies de réaction différentes de celles des pions et des protons.

Ces différences se traduisent par des signatures calorimétriques moyennes distinctes — signal d'ionisation avant gerbe, fraction électromagnétique, profondeur de première interaction, développement longitudinal et extension transverse — dont la comparaison espèce par espèce est donnée au Tableau F.1,

TABLE 3.1. Propriétés fondamentales des trois espèces hadroniques étudiées et conséquences calorimétriques attendues [4].

Espèce	Masse (MeV)	Charge	Temps de vie	Contenu en quarks	Nature	Conséquence principale
Pion chargé π^-	139.57	-1	26.0 ns	$\bar{u}d$	Méson	Ionisation initiale ; composante EM souvent marquée
Proton p	938.27	$+1$	stable	uud	Baryon	Gerbe plus hadronique et plus profonde
Kaon neutre K^0	497.61	0	51.2 ns	$\frac{1}{\sqrt{2}}(d\bar{s} - s\bar{d})$	Méson neutre	Pas d'ionisation initiale ; départ de gerbe variable

en Annexe F. Ces tendances restent toutefois statistiques, car les gerbes hadroniques présentent de fortes fluctuations événement par événement.

Ces différences suggèrent que des observables de morphologie, telles que le profil longitudinal, la compacité transverse, la profondeur du premier dépôt ou la répartition entre seuils, portent une information discriminante exploitable pour le PID.

3.2 Stratégie : pourquoi un apprentissage supervisé

La difficulté provient de la nature même des interactions hadroniques. Contrairement aux gerbes électromagnétiques, dont le développement est relativement régulier, les gerbes hadroniques présentent de fortes fluctuations d'un événement à l'autre. Le point de première interaction, la profondeur moyenne de développement, l'étalement transverse, la densité locale des dépôts et la fraction d'énergie invisible varient sensiblement, même à énergie incidente fixée. Certaines espèces, comme les protons et les pions chargés, produisent ainsi des signatures partiellement recouvrantes, rendant leur séparation non triviale.

Le SDHCAL possède néanmoins plusieurs caractéristiques favorables à cette tâche : sa très haute granularité permet de reconstruire la morphologie des gerbes couche par couche, tandis que la lecture semi-digitale à trois seuils apporte une information indirecte sur la densité locale du dépôt d'énergie. Lorsqu'une information temporelle est disponible, elle peut également contribuer à la discrimination via le temps de vol ou la dynamique d'initiation de la gerbe. L'ensemble forme un espace d'observables riche, mais complexe, dans lequel les corrélations entre variables jouent un rôle important.

Dans ce contexte, une approche par apprentissage supervisé s'impose naturellement : les descripteurs extraits sont nombreux, souvent corrélés, et leur pouvoir discriminant repose sur des dépendances non linéaires difficiles à exploiter au moyen de simples coupures séquentielles. L'objectif est donc d'entraîner un classificateur capable d'apprendre automatiquement une frontière de séparation efficace entre espèces à partir de leur signature calorimétrique.

Plusieurs familles de modèles ont été comparées sur un même jeu de variables d'entrée : perceptrons multicouches [25, 26], forêts aléatoires et arbres de décision boostés [27]. Les méthodes de boosting se sont révélées les plus performantes pour ce problème tabulaire, plus précises que les forêts aléatoires tout en nécessitant moins d'ajustements fins qu'un réseau dense. L'implémentation **LightGBM** [28] a été retenue comme modèle de référence pour la classification multiclasse π^-, p, K^0, notamment pour l'accès direct qu'elle donne à des indicateurs d'importance des variables, utiles à l'interprétation physique. Le détail de la comparaison entre modèles et les hyperparamètres retenus figurent en Annexe B.5.

3.3 Données simulées et descripteurs physiques

L'étude repose sur des échantillons simulés de particules mono-énergétiques correspondant aux trois espèces considérées : pions négatifs π^-, protons p et kaons neutres K^0. Chaque classe contient environ 1.3×10^5 événements, générés entre 1 et 130 GeV.

La troisième espèce appelle une précision, car elle conditionne la lecture des résultats qui suivent. La branche `particlePDG` vaut 311 pour la totalité de ces événements, code du K^0 et non du K^0_L, dont le code est 130. Le primaire est donc un état propre de saveur, que le transport Monte-Carlo décompose en un mélange de K^0_S et de K^0_L. Les deux composantes ne se comportent pas de la même façon : le K^0_L, de longueur de désintégration kilométrique aux énergies considérées, atteint le calorimètre et y interagit hadroniquement, tandis qu'une fraction des K^0_S se désintègre avant ou pendant la gerbe, en $\pi^+\pi^-$ dans deux cas sur trois et en $\pi^0\pi^0$ dans le troisième.

Cette contamination est visible dans les données. Sur l'échantillon de validation non numérisé, 1,2 % des événements K^0 présentent une fraction électromagnétique exactement égale à l'unité, population strictement absente des pions et des protons (0,00 % dans les deux cas) : ce sont des gerbes purement électromagnétiques, signature attendue d'une désintégration $K^0_S \to \pi^0\pi^0$. L'effet reste marginal — le reste de la distribution suit celle des pions — mais il implique que la classe n'est pas un faisceau pur de K^0_L, et que les performances qui lui sont associées comportent une contribution, faible, d'événements dont la topologie n'est pas celle d'une gerbe de kaon. Ce domaine couvre à la fois les interactions de basse énergie, où les gerbes restent peu développées, et les régimes plus énergétiques, caractérisés par une activité hadronique plus étendue et plus fluctuante.

Plutôt que d'utiliser directement la liste exhaustive des hits du détecteur, nous construisons un ensemble de descripteurs physiques résumant les principales propriétés morphologiques de chaque événement. Ces variables sont extraites à l'aide de l'outil `ShowerAnalyzer` et regroupées en familles complémentaires :

— **Activité globale et information en seuils :** nombre total de hits, occupations associées aux trois seuils semi-digitaux (`Thr1`, `Thr2`, `Thr3`), multiplicité locale. Ces variables renseignent sur l'intensité globale de la gerbe et sur la densité locale des dépôts d'énergie.

— **Développement longitudinal :** plan de début de gerbe (`Begin`), barycentre en profondeur (`Zbary`), dispersion longitudinale (`Zrms`), position du maximum ou paramètres ajustés du profil longitudinal. Elles sont sensibles à la profondeur de première interaction et à l'évolution de la cascade dans l'absorbeur.

— **Développement transverse et compacité :** rayon effectif (`Radius`), densité locale (`Density`), excentricité, valeurs propres géométriques (λ_1, λ_2). Ces observables décrivent l'étalement latéral et l'anisotropie spatiale de la gerbe.

— **Structure locale :** nombre de clusters intra-couche, taille moyenne et maximale des clusters, présence éventuelle de segments quasi-linéaires. Elles caractérisent la fragmentation interne de l'activité.

— **Variables temporelles :** temps du premier hit (`tMin`), temps moyen (`tMean`), dispersion temporelle (`tSpread`). Elles peuvent refléter à la fois le temps de vol de la particule incidente et la dynamique temporelle de l'interaction hadronique.

Certaines de ces variables décrivent principalement la géométrie de la gerbe, d'autres son intensité locale ou sa chronologie ; leur combinaison fournit une représentation compacte, mais physiquement pertinente, de chaque événement. Lorsque l'étude inclut l'information temporelle, un *smearing* gaussien est appliqué afin de représenter une résolution instrumentale finie. La définition mathématique complète de chaque descripteur, ainsi que le détail de la préparation des données, sont donnés en Annexes A et B.1.

3.4 Protocole d'entraînement et métriques

L'évaluation repose sur trois sous-ensembles disjoints — entraînement, validation et test — obtenus par un découpage stratifié préservant les proportions des trois espèces. L'ensemble de validation sert à suivre l'apprentissage, à régler les hyperparamètres et à déclencher l'arrêt anticipé (*early stopping*) lorsque la performance cesse de s'améliorer ; l'ensemble de test n'intervient que pour l'évaluation finale. Cette organisation mesure la capacité de généralisation du modèle plutôt que son ajustement aux données d'entraînement. Le modèle est entraîné en mode multiclasse par minimisation de la fonction de coût *multi-logloss*.

Des tests de rééquilibrage des classes par *SMOTE* (*Synthetic Minority Over-sampling Technique*) ont également été menés. Les gains observés étant restés limités, et la génération d'événements synthétiques risquant d'introduire des corrélations artificielles, cette stratégie n'a pas été retenue dans la chaîne principale. Le détail du découpage, des hyperparamètres et de la procédure d'entraînement est donné en Annexe B.5.

Les performances sont quantifiées à l'aide de métriques complémentaires : **accuracy globale** et **accuracy équilibrée** (moyenne des taux de bonne classification par classe, moins sensible aux déséquilibres statistiques), **matrice de confusion**, **multi-logloss**, **courbes ROC one-vs-rest** et aire sous la courbe (AUC), et **histogrammes des probabilités prédites**. Leur usage conjoint est nécessaire : une accuracy élevée ne garantit pas une bonne calibration probabiliste, tandis que la matrice de confusion identifie précisément quelles espèces restent difficiles à distinguer. Dans le cas présent, la confusion résiduelle entre protons et pions constitue un indicateur plus informatif que l'accuracy seule.

3.5 Résultats de classification

Les performances du modèle LightGBM sont évaluées sur l'ensemble de test indépendant, non utilisé lors des phases d'apprentissage et de validation. Les résultats présentés reflètent donc la capacité réelle de généralisation du classificateur pour la séparation des trois espèces hadroniques étudiées. Le suivi de la fonction de coût au cours de l'entraînement, qui ne montre pas de signe de sur-ajustement, est reporté en Annexe B.5.

Matrice de confusion. La matrice de confusion normalisée obtenue sur l'échantillon de test est représentée Figure 3.1. Elle met en évidence des comportements sensiblement différents selon les espèces :

— **Pions π^-** : environ 48.8 % des événements sont correctement identifiés, tandis que ∼ 47.9 % sont confondus avec des protons ;

— **Protons** p : la séparation est meilleure, avec ~ 68.6 % d'identifications correctes, l'erreur dominante correspondant à une attribution vers la classe pion (~ 27.4 %) ;

— **Kaons neutres** K^0 : la classification est nettement plus performante, avec environ 86.0 % des événements correctement reconstruits.

Ces trois valeurs sont les *rappels* par classe, c'est-à-dire les termes diagonaux de la matrice normalisée par ligne. Leur moyenne non pondérée définit l'**accuracy équilibrée** :

$$\mathrm{BA} = \frac{1}{3}(48.8 + 68.6 + 86.0)\ \% = 67.8\,\%,$$

métrique de référence ici car indépendante des effectifs relatifs des trois classes dans l'échantillon de test. Le rappel des pions reste supérieur au niveau attendu d'une décision aléatoire entre trois classes (33 %), mais de peu : pour cette classe, le classificateur n'apporte qu'une information limitée, et les 47.9 % de pions attribués à la classe proton constituent à eux seuls la contribution dominante aux erreurs du modèle.

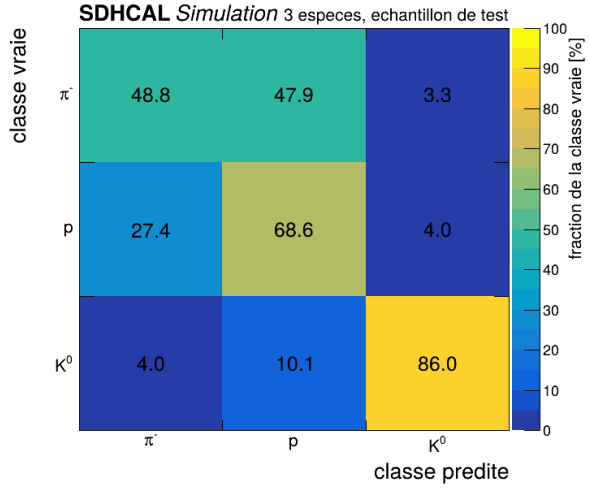


FIGURE 3.1. Matrice de confusion normalisée sur l'échantillon de test (pourcentages par ligne). Les classes sont ordonnées selon $\{\pi^-, p, K^0\}$.

Étude binaire pion/proton. Une configuration binaire, utilisée ensuite pour le routage des modèles d'énergie, a également été entraînée sur environ 2×10^5 événements par espèce entre 1 et 130 GeV. Répétée sur cinq graines, elle atteint une accuracy équilibrée de $61{,}3 \pm 0{,}1$ %, avec $49{,}7 \pm 0{,}2$ % de pions et $72{,}9 \pm 0{,}2$ % de protons correctement identifiés ; 50,3 % des pions sont classés comme protons et 27,1 % des protons comme pions. Cette asymétrie doit être conservée à l'esprit pour interpréter les biais de la chaîne complète.

Apport de l'information temporelle. Les variables temporelles ont été incluses après application d'une résolution effective de 100 ps. Elles apportent une information complémentaire sur l'initiation et le développement de la gerbe. Leur contribution propre n'est toutefois pas isolée dans les résultats retenus : l'interprétation repose donc principalement sur les observables semi-digitales et morphologiques, dont le rôle est établi par l'étude d'importance des variables.

L'intérêt potentiel d'une information temporelle fine a été étudié par CALICE sur l'AHCAL dans une tâche distincte de séparation de deux gerbes superposées [29]. Dans cette étude, l'ajout d'un temps simulé avec une résolution de 100 ps réduit d'environ 23 % la déviation absolue médiane de l'énergie de confusion pour GravNet et améliore, dans certaines configurations, de 15 à 20 points la fraction de gerbes reconstruites à l'intérieur de la résolution calorimétrique. PointNet ne présente pas le même gain, ce qui montre que l'apport du temps dépend de l'architecture et de la tâche. Ces résultats, obtenus avec un calorimètre analogique à scintillateurs et sans information temporelle exploitable dans les données de faisceau, ne valident ni la résolution temporelle supposée ici pour le SDHCAL ni un gain quantitatif sur le PID étudié dans ce mémoire. Ils motivent en revanche une ablation contrôlée des variables temporelles.

Interprétation physique. La séparation des K^0 a d'abord une cause élémentaire, annoncée au chapitre 1 : le K^0 est neutre. Il n'ionise pas et ne dépose donc rien avant sa première interaction nucléaire, là où un π^- ou un proton, chargés, laissent une trace au minimum d'ionisation dès la première couche. La variable `Begin`, qui repère le début de la gerbe, le montre directement sur l'échantillon à trois espèces :

TABLE 3.2. Couche de démarrage de la gerbe par espèce, sur $1{,}3 \times 10^5$ événements par espèce. L'écart interquartile mesure la variabilité du point de départ.

Espèce	`Begin` médian	Écart interquartile	Démarrage après la couche 10
π^-	0	1	4 %
p	0	1	4 %
K^0	6	10	29 %

Ce tableau rend compte des deux moitiés du résultat d'un seul coup. Le K^0 démarre six couches plus loin, avec une dispersion dix fois plus large, et près d'un tiers de ses gerbes s'amorcent au-delà de la couche 10 contre 4 % pour les espèces chargées : le classificateur dispose là d'un discriminant franc. Mais π^- et proton sont *rigoureusement indiscernables* sur cette même variable — mêmes médiane, même écart interquartile, même fraction tardive. Le verrou pion/proton et la facilité du K^0 ont donc une origine commune, et aucun modèle ne peut tirer de la profondeur de démarrage une information que les gerbes n'y ont pas mise.

S'y ajoute, au second ordre, une dynamique hadronique différente, le 1,2 % d'événements électromagnétiques identifiés plus haut étant trop peu nombreux pour en rendre compte. Dans les interactions se produisant dans l'absorbeur, les états finals sont très souvent dominés par la production de pions : leur faible masse les rend énergétiquement faciles à produire, les symétries approximatives de l'interaction forte — notamment l'isospin — et un espace de phase favorable renforcent cette dominance, et aucune création de quark étrange supplémentaire n'est requise. La production de kaons nécessite au contraire la création d'étrangeté ($s\bar{s}$) et implique des masses plus élevées : elle est donc statistiquement moins probable aux énergies considérées, et les cascades secondaires initiées par un K^0 diffèrent en moyenne de celles dominées par les pions. S'y ajoute le rôle des π^0, dont les fluctuations de production influencent directement la compacité locale, la densité d'activité et le développement longitudinal observés dans le calorimètre.

À l'inverse, protons et pions chargés interagissent tous deux par interaction forte sans dynamique d'étrangeté, et leurs gerbes restent largement dominées par les fluctuations de première interaction nucléaire et par la variabilité de la composante électromagnétique secondaire. Il en résulte un recouvre-

ment important dans l'espace des variables tabulaires utilisées ici. La confusion résiduelle pion/proton ne traduit donc pas une faiblesse particulière du modèle, mais la proximité physique réelle de leurs signatures. Il est par ailleurs probable que cette difficulté dépende de l'énergie incidente : à basse énergie, la faible multiplicité de hits accentue les fluctuations statistiques, tandis qu'à plus haute énergie certaines signatures morphologiques deviennent plus marquées — une étude différentielle par tranches d'énergie constituerait un prolongement naturel.

Probabilités prédites. Les histogrammes des probabilités de sortie (Figure 3.2) confirment ces tendances et renseignent sur le degré de confiance des prédictions. Les vrais K^0 reçoivent majoritairement des probabilités élevées pour leur classe correcte, avec une superposition limitée avec les distributions des pions et des protons. En revanche, les probabilités associées à la classe proton présentent un recouvrement significatif entre vrais protons et vrais pions : une fraction non négligeable des événements des deux classes reçoit des scores intermédiaires, traduisant une zone d'ambiguïté où la décision devient moins robuste. La confusion observée ne provient donc pas uniquement de limites algorithmiques, mais d'un recouvrement intrinsèque entre classes dans l'espace des variables utilisées. Ces distributions suggèrent enfin qu'une exploitation probabiliste des sorties — seuils ajustés, calibration des scores, sélection d'événements de haute pureté — constituerait une piste intéressante selon les besoins d'analyse.

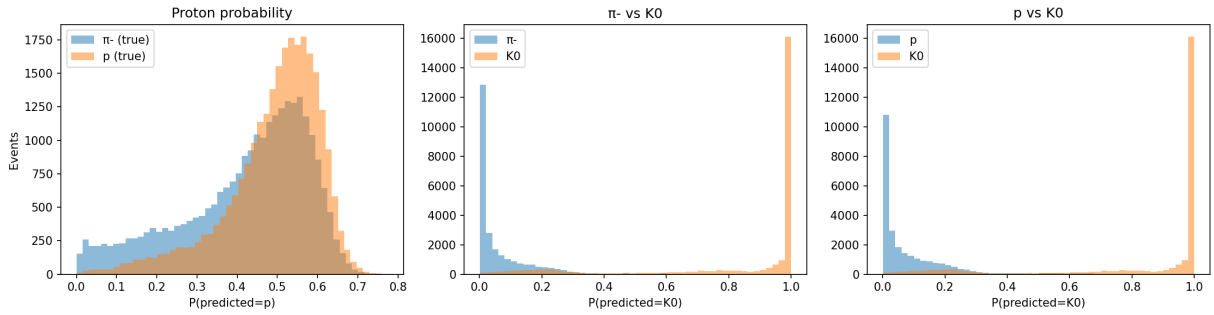


FIGURE 3.2. Histogrammes des probabilités prédites : (gauche) $P(\text{classe} = p)$ pour vrais π^- et vrais p ; (centre) $P(\text{classe} = K^0)$ pour vrais π^- et vrais K^0 ; (droite) $P(\text{classe} = K^0)$ pour vrais p et vrais K^0.

3.5.1 Variables discriminantes

Au-delà des performances globales, il est important d'identifier quelles observables portent l'information utile à la séparation, afin de comprendre les mécanismes physiques exploités par le modèle et de repérer d'éventuelles redondances. L'étude des corrélations linéaires entre variables d'entrée, présentée en Annexe F, montre que plusieurs observables transportent une information partiellement redondante — notamment au sein des variables décrivant l'activité globale et la compacité de la gerbe.

L'analyse des importances internes du modèle, estimées à partir du *gain* cumulé apporté par chaque variable lors des coupures successives, est présentée Figure 3.3.

Variables dominantes. La variable `Thr3`, correspondant au nombre de hits franchissant le seuil le plus élevé, apparaît comme la plus discriminante, nettement devant les autres : les régions les plus denses de la gerbe jouent donc un rôle central dans la séparation des espèces. Les variables `Density`

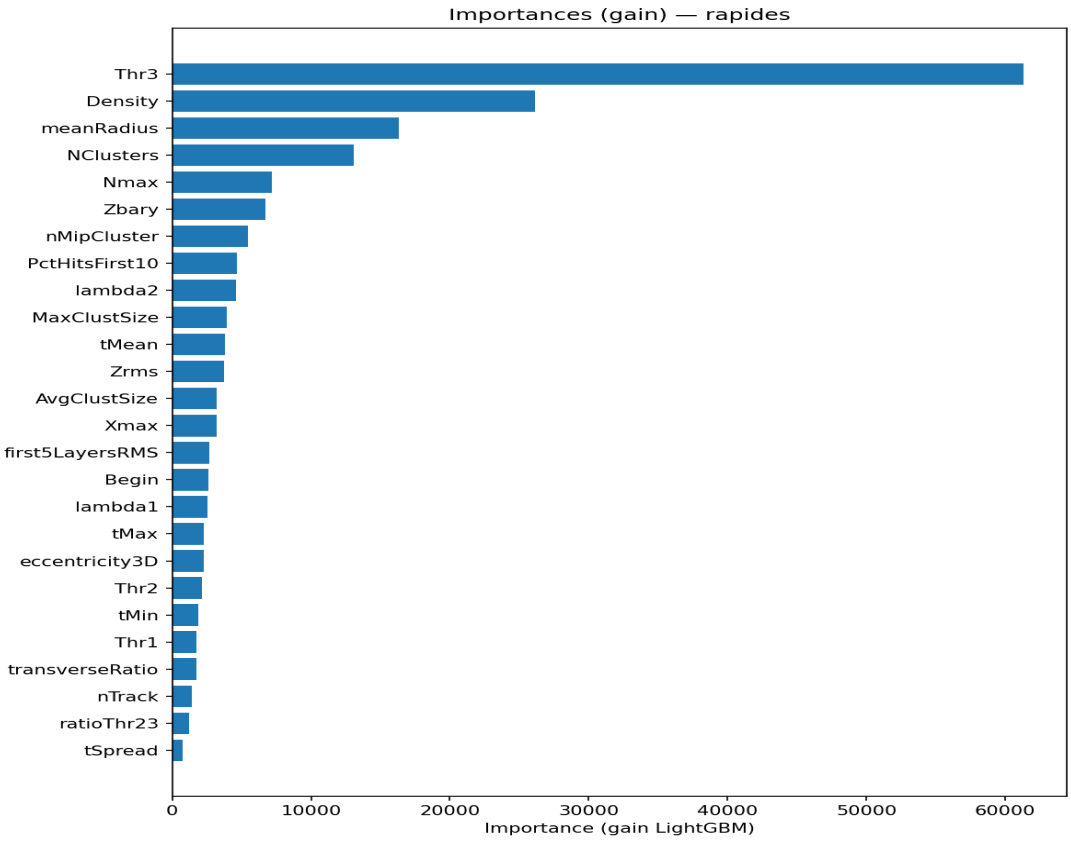


FIGURE 3.3. Importances des variables extraites du modèle LightGBM à partir du gain cumulé.

et `Radius` figurent également parmi les contributions les plus élevées, montrant que la compacité locale et l'extension transverse moyenne sont particulièrement informatives. Un second groupe regroupe `NClusters`, `Nmax`, `Zbary`, `nMipCluster` et `PctHitsFirst10`, qui traduisent la fragmentation de l'activité, la multiplicité locale et le développement longitudinal.

La séparation repose ainsi sur trois familles d'information : la **densité locale d'activité** (`Thr3`, `Density`), la **morphologie transverse** (`Radius`), et la **structuration longitudinale et la fragmentation** (`Zbary`, `NClusters`, `Nmax`). Ce constat est cohérent avec la physique des gerbes hadroniques dans un calorimètre hautement granulaire.

3.5.2 Limites et systématiques

Robustesse vis-à-vis des effets instrumentaux. La hiérarchie de variables décrite ci-dessus est physiquement plausible, mais elle a été établie dans des conditions de simulation idéalisées et doit être confirmée en conditions réalistes. Les performances reportées ne préjugent donc pas de celles qui seraient obtenues sur données réelles. Plusieurs non-idéalités sont susceptibles de dégrader la séparation, et leur impact n'a pas été quantifié dans ce travail : une résolution temporelle dégradée, des offsets de calibration entre couches, des variations des conditions de prise de données, des inefficacités locales ou un bruit électronique résiduel, ainsi que la présence de canaux défectueux ou instables. Ces effets touchent directement les observables les plus discriminantes — l'activité au seuil élevé et la densité locale dépendent de l'efficacité des chambres et de l'uniformité de la calibration. Une étude de sensibilité à ces non-idéalités constitue donc un préalable à toute transposition du classificateur vers

les données de faisceau.

Systématiques liées à la simulation. Comme toute approche supervisée entraînée sur simulation, les performances mesurées dépendent du réalisme du modèle physique utilisé pour générer les gerbes hadroniques. Ce point constitue la limite la plus structurante de ce travail : le classificateur apprend les régularités de la simulation, et rien ne garantit a priori que celles-ci se retrouvent dans les données. L'impact du choix de la liste de physique hadronique de Geant4 [23] n'a pas été évalué ici, pas plus que celui des paramètres de réponse du détecteur, des inefficacités instrumentales, ou de la modélisation temporelle des signaux. Une comparaison entre plusieurs configurations de simulation, puis une confrontation aux données de test faisceau, seraient nécessaires pour estimer l'incertitude systématique associée au classificateur — d'autant que la séparation des K^0 repose précisément sur des différences de production d'étrangeté, dont la modélisation varie selon les listes de physique.

Prolongements sur ce chapitre. Deux prolongements immédiats se dégagent de cette analyse : une étude d'ablation par groupes de variables (densité, longitudinal, transverse, temps), qui permettrait de vérifier que le pouvoir discriminant repose bien sur les observables identifiées et de tester explicitement l'impact du retrait des variables temporelles. L'interprétabilité du modèle pourrait par ailleurs être approfondie à l'aide de méthodes locales telles que SHAP, afin de passer d'une importance globale à une explication événement par événement. Les autres axes d'optimisation envisagés sont détaillés en Annexe B.5.

La principale limite de l'approche reste toutefois l'utilisation de variables agrégées : bien que physiquement motivées, elles ne restituent qu'une partie de la richesse spatiale et temporelle des hits bruts, ce qui motive l'exploration présentée dans la section suivante.

3.6 Étude exploratoire : approche GNN

Les descripteurs globaux utilisés jusqu'ici ne conservent qu'une partie de l'information spatiale et temporelle contenue dans la topologie fine des gerbes. Une étude exploratoire a donc été engagée à l'aide de réseaux de neurones graphiques (*Graph Neural Networks*, GNN) [30, 31, 7]. La comparaison quantitative retenue ici représente chaque événement par ses amas de pads et confronte une agrégation sans arêtes, de type PointNet, à un graphe de voisinage explicite. Leur principe est détaillé en Annexe C.

Des travaux récents confortent cette orientation tout en fournissant des points de comparaison méthodologiques. Sur un DHCAL binaire à RPWELL, des architectures GAT et DeepSets exploitant les coordonnées des amas et leur multiplicité reproduisent notamment une confusion importante entre pions et protons [32]. Pour la séparation de gerbes dans l'AHCAL, CALICE observe que DGCNN et GravNet tirent davantage parti des structures locales spatio-temporelles que PointNet [29]. Ces résultats suggèrent de comparer un modèle d'ensemble simple à des graphes statiques et dynamiques. Ils ne constituent toutefois pas une validation numérique directe : le milieu actif, le mode de lecture, les espèces, les cibles d'apprentissage et les plages d'énergie diffèrent de ceux de cette étude.

Cette piste, engagée en fin de stage, a d'abord permis de mettre en place la représentation des événements sous forme de graphes et une première chaîne d'apprentissage, sans comparaison quantitative contrôlée. La section suivante rapporte cette comparaison, menée depuis avec des échantillons, des découpages et des sélections identiques à ceux de l'approche tabulaire.

3.7 Approfondissement de la confusion pion/proton

Les sections précédentes établissent un résultat net et un verrou. Le résultat est la séparation des K^0, dont le rappel de 86 % s'explique par une dynamique d'étrangeté distincte. Le verrou est la confusion pion/proton, qui concentre à elle seule l'essentiel des erreurs et dont l'interprétation donnée plus haut — un recouvrement réel des signatures plutôt qu'une faiblesse du modèle — reste une hypothèse tant qu'elle n'a pas été mise à l'épreuve.

Deux objections pouvaient lui être opposées. La première est que les descripteurs tabulaires ne conservent qu'une partie de l'information topologique : un modèle lisant directement les hits pourrait voir ce qu'ils résument. La seconde est que le volume d'entraînement limitait la performance. Cette section répond à la première ; la littérature répond à la seconde.

Protocole. L'étude est menée sur deux productions Geant4 pion/proton indépendantes : une production continue de 2×10^5 événements par espèce entre 1 et 130 GeV pour l'entraînement, et une production à énergies fixes de 10^5 événements par espèce, couvrant vingt points de 5 à 100 GeV, réservée à l'évaluation. L'échantillon d'évaluation n'est donc pas prélevé dans celui d'entraînement : il provient d'une simulation distincte. Ces lots ne contenant pas de K^0, l'étude porte exactement sur le cas difficile.

Quatre classificateurs sont comparés sur les mêmes événements : le BDT et un perceptron, qui lisent les descripteurs de gerbe, face à un réseau de type PointNet et un réseau de graphes, qui lisent les amas de hits. Les amas sont formés par quatre-connexité dans chaque couche, selon la définition même de l'observable `NClusters` (Annexe A), ce qui divise par environ quatre le nombre d'objets à traiter — 753 hits deviennent 191 amas par événement — sans perdre l'information, puisque chaque amas conserve sa position, sa taille et sa composition en seuils.

Le premier modèle est conservé sous le nom *CNN* dans les fichiers et les figures. Il ne s'agit toutefois pas d'une convolution spatiale entre amas : deux convolutions 1×1 encodent chaque amas indépendamment, puis un maximum et une moyenne globaux produisent la représentation de l'événement. Cette construction invariante par permutation est **de type PointNet**, sans être une reproduction de l'architecture PointNet originale. Le second modèle est un **GNN** au sens strict : il construit un graphe k-NN et propage l'information par une couche d'attention `GATConv` puis deux couches `GraphConv`. L'Annexe C détaille les deux représentations et leurs différences.

La figure de mérite retenue est le rejet du proton à efficacité pion fixée, et non l'exactitude : celle-ci dépend du mélange π/p de l'échantillon de test, qui est un artefact de la génération, alors qu'un rejet cité à une efficacité donnée n'en dépend pas.

TABLE 3.3. Rejet du proton à 50 % d'efficacité pion, sur les 6027 événements que les quatre modèles ont tous prédits. Les deux réseaux au niveau des hits disposent de vingt fois moins d'événements d'entraînement.

Modèle	Entrée	$N_{\text{entr.}}$	AUC	Rejet $1/\varepsilon_p$
MLP	descripteurs de gerbe	176 000	0,679	4,07
BDT	descripteurs de gerbe	176 000	0,674	4,10
CNN de type PointNet	amas de hits	8 400	0,655	3,62
GNN	amas de hits	8 400	0,649	3,54

La valeur intégrée pourrait par ailleurs masquer une dépendance en énergie : un modèle meilleur seulement à basse énergie, là où la statistique pèse le plus, se confondrait avec un modèle uniformément

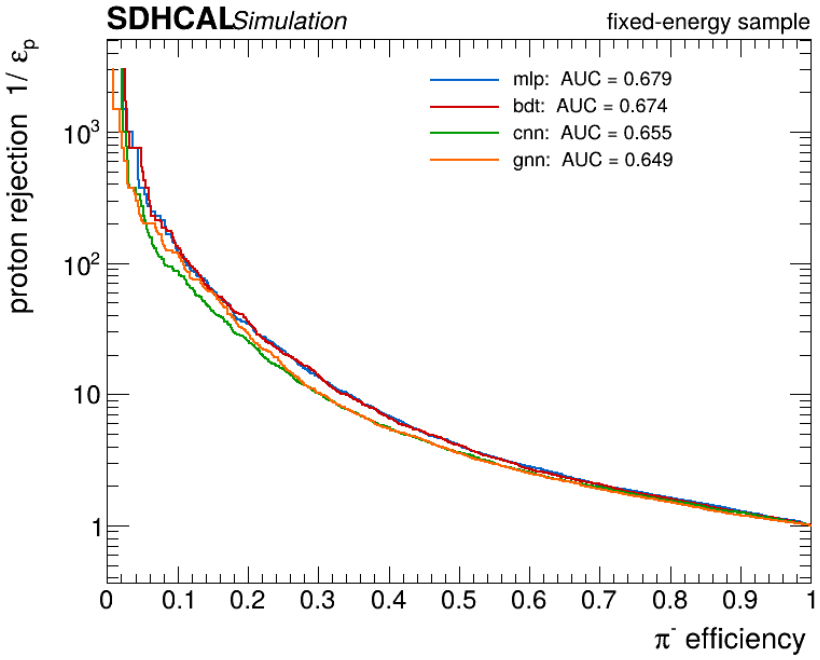


FIGURE 3.4. Rejet du proton en fonction de l'efficacité pion, pour les quatre classificateurs.

moyen. La Figure 3.5 écarte cette lecture.

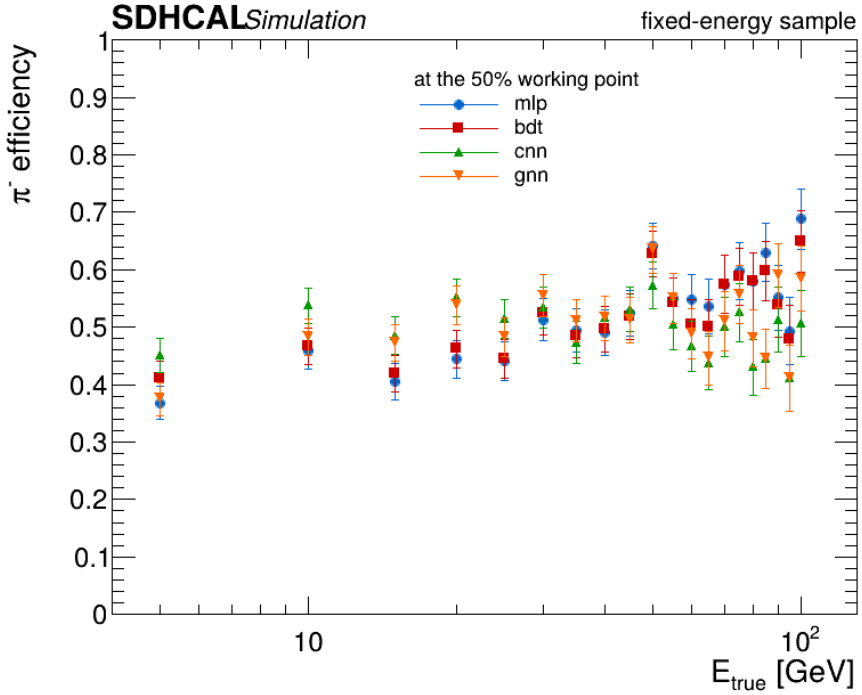


FIGURE 3.5. Efficacité pion au point de fonctionnement à 50 %, par tranche d'énergie vraie. Les barres sont binomiales. La séparation s'améliore lentement avec l'énergie, de ~0,40 à 5 GeV à ~0,60 à 100 GeV. Les barres par tranche, d'environ 0,05, sont trop larges pour y retrouver le classement intégré : aucun modèle ne doit donc son écart global à une région d'énergie particulière.

Lecture des écarts. Comparer quatre AUC sur 6 027 événements demande de savoir ce qu'un écart doit valoir pour compter. Deux sources d'incertitude interviennent. L'échantillon d'évaluation d'abord : un

bootstrap apparié, qui rééchantillonne les mêmes événements pour tous les modèles et élimine donc la part commune de la fluctuation, donne les écarts du Tableau 3.4. La graine d'initialisation ensuite : répété sur cinq graines, le MLP donne une AUC de $0{,}6589 \pm 0{,}0006$ et le BDT $0{,}6580 \pm 0{,}0015$ sur leur échantillon de validation interne.

TABLE 3.4. Écarts d'AUC par paire sur les 6 027 événements communs, par bootstrap apparié ($B = 2000$). L'incertitude ne couvre que l'échantillonnage ; la dispersion de graine, de l'ordre de 0,0016 pour les deux modèles tabulaires, s'y ajoute en quadrature.

Paire	ΔAUC	p
MLP − BDT	$+0{,}0053 \pm 0{,}0022$	0,02
BDT − CNN	$+0{,}0188 \pm 0{,}0047$	$< 0{,}001$
BDT − GNN	$+0{,}0252 \pm 0{,}0051$	$< 0{,}001$
CNN − GNN	$+0{,}0064 \pm 0{,}0048$	0,18

L'accès aux hits ne lève pas le verrou. Le MLP devance le BDT de 0,0053, soit environ deux écarts-types une fois la dispersion de graine ajoutée : l'écart est trop ténu pour les départager, et sur les descripteurs de gerbe un arbre renforcé et un réseau dense extraient en pratique la même information. La limite est donc dans les variables, non dans la classe de modèle.

Les deux réseaux lisant les hits, eux, ne font pas mieux : ils sont nettement en retrait, de quatre à cinq écarts-types, et ne se départagent pas entre eux. Cet écart ne démontre pas que les hits portent moins d'information que leur résumé, car ces réseaux ont vu vingt fois moins d'événements ; il borne seulement ce que leur lecture directe apporte, et cette borne est négative. La première objection est levée dans le sens de l'hypothèse : dans ces conditions, l'information topologique fine que les descripteurs résument ne livre pas de pouvoir séparateur supplémentaire.

Le volume d'entraînement n'est pas davantage en cause. C'est ici que la littérature tranche la seconde objection. L'étude DHCAL déjà citée [32] entraîne ses réseaux sur 2,4 millions d'événements, soit près de trois cents fois le budget employé ici, avec d'autres architectures et un autre détecteur. Elle rapporte une efficacité pion de 46 à 52 % et la même confusion dominante : 34 % des pions classés protons et 26 % des protons classés pions. Le plafond ne se déplace pas.

Conclusion. Le mécanisme est connu [33] : la conservation du nombre baryonique limite la production de π^0 dans les gerbes de protons, qui fluctuent donc moins, tandis qu'un $\pi^{\pm}$ incident en produit facilement. Le recouvrement des topologies est une propriété des gerbes hadroniques, non un défaut de statistique, de représentation ou de modèle. La confusion de 47,9 % rapportée à la section 3.5 doit en conséquence se lire comme une limite mesurée et corroborée, et non comme une marge de progression. Cette lecture a une conséquence directe sur la chaîne complète, développée au chapitre 5 : il n'est pas raisonnable d'attendre d'un meilleur classificateur qu'il améliore la reconstruction en énergie.

Chapitre 4

Reconstruction de l'énergie

4.1 Enjeux dans un calorimètre semi-digital

La reconstruction de l'énergie d'une gerbe hadronique est limitée par les fluctuations de la première interaction, de la fraction électromagnétique, des pertes invisibles et des fuites. Dans le SDHCAL, la lecture à trois seuils ajoute une discrétisation de la charge et une saturation locale dans les régions denses. En revanche, la forte granularité fournit des informations de forme susceptibles de corriger une partie de ces fluctuations.

Deux estimateurs sont comparés : une calibration paramétrique fondée sur les nombres de hits aux trois seuils, et une régression LightGBM exploitant un ensemble plus large de descripteurs de gerbe. Les comparaisons entre scénarios sont rassemblées au chapitre 5.

4.2 Données disponibles et protocole d'évaluation

L'étude utilise des simulations de pions, de protons et de K^0 entre 1 et 130 GeV. Pour l'étude binaire pion/proton, environ 2×10^5 événements par espèce sont disponibles. Les modèles sont évalués sur des événements distincts de ceux employés pour l'entraînement. Les performances énergétiques sont décrites par le biais relatif

$$\delta(E) = \frac{\langle E_{\mathrm{reco}} \rangle - E_{\mathrm{true}}}{E_{\mathrm{true}}} \tag{4.1}$$

et par la dispersion du résidu relatif autour de sa valeur moyenne. Une valeur positive de δ traduit une surestimation de l'énergie, une valeur négative une sous-réponse. La procédure historique de calcul de la largeur retient le cœur central de la distribution ; elle convient à la comparaison interne des scénarios, mais les valeurs correspondantes ne sont pas utilisées ici comme mesure absolue de $\sigma(E)/E$.

4.3 Méthode paramétrique par comptage de seuils

Pour chaque événement, N_1, N_2 et N_3 désignent les nombres de hits attribués aux trois seuils semi-digitaux, et $N_{\mathrm{hit}} = N_1 + N_2 + N_3$. L'estimateur utilisé est

$$E_{\mathrm{reco}} = \alpha(N_{\mathrm{hit}})N_1 + \beta(N_{\mathrm{hit}})N_2 + \gamma(N_{\mathrm{hit}})N_3, \tag{4.2}$$

avec des poids quadratiques en N_{hit}, par exemple

$$\alpha(N_{\mathrm{hit}}) = a_0 + a_1 N_{\mathrm{hit}} + a_2 N_{\mathrm{hit}}^2, \tag{4.3}$$

et des expressions analogues pour β et γ, soit neuf coefficients ajustés sur simulation. Cette paramétrisation reprend la forme introduite pour l'analyse des données de faisceau du prototype SDHCAL [9]. Dans cette étude expérimentale, les coefficients étaient déterminés sur une partie des données H2, choisies sans contamination proton significative, puis appliqués aux autres événements H2 et H6. Ici, la même structure fonctionnelle est conservée, mais les ajustements sont réalisés séparément sur les simulations de chaque espèce. Cette forme garde une interprétation directe des trois seuils, sans pouvoir exploiter toute l'information spatiale et temporelle du détecteur.

4.4 Ajustement des paramètres par minimisation d'une fonction pondérée

Pour une espèce donnée, les paramètres $\vec{\theta}$ sont obtenus en minimisant la fonction objectif

$$S(\vec{\theta}) = \sum_i \frac{\left[E_i^{\text{reco}}(\vec{\theta}) - E_i^{\text{true}}\right]^2}{E_i^{\text{true}}}. \tag{4.4}$$

Cette pondération limite la domination des événements de haute énergie dans l'ajustement. Dans l'analyse de référence [9], le choix conventionnel $\sigma_i = \sqrt{E_i}$ conduit algébriquement au même poids en $1/E_i$. La méthode est donc désignée par convention comme méthode « χ^2 » dans la suite. Dans l'implémentation présente, où le dénominateur n'est pas une variance mesurée événement par événement, S doit néanmoins être interprétée comme une fonction de moindres carrés pondérés, et non comme un test statistique d'adéquation.

Des calibrations distinctes peuvent ainsi être construites pour les pions, les protons et les kaons. Leur utilisation avec l'espèce vraie représente un cas idéal; dans une chaîne réaliste, le choix de la calibration dépend du PID. Les détails d'implémentation sont décrits en Annexe E.

4.5 Résultats de la méthode paramétrique

Les Figures 4.1 et 4.2 présentent la méthode paramétrique appliquée sans routage par PID. Elles montrent l'évolution de la réponse moyenne et la diminution de la dispersion relative lorsque l'énergie augmente.

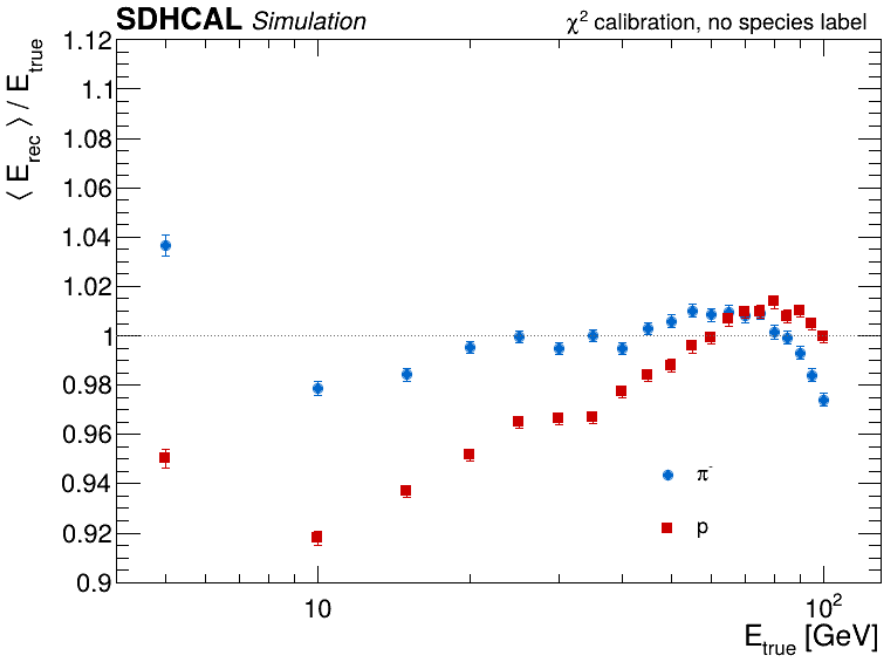


FIGURE 4.1. Linéarité et biais relatif de la calibration paramétrique.

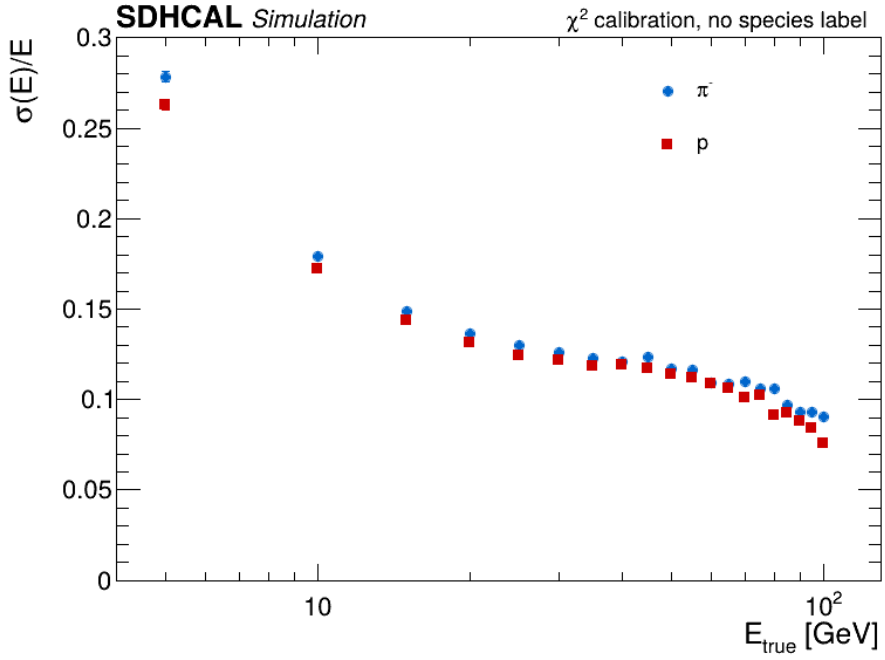


FIGURE 4.2. Indicateur de dispersion relative obtenu avec la calibration paramétrique.

4.6 Régression LightGBM

La seconde approche apprend directement E_{true} à partir des compteurs de seuils et de descripteurs de morphologie : activité totale, densité, développement longitudinal et extension transverse. Les modèles spécifiques à chaque espèce constituent le cas le plus favorable ; dans la chaîne complète, le classificateur sélectionne le modèle appliqué à l'événement.

Les résultats sont présentés Figures 4.3 et 4.4. Ils montrent que la régression fournit une réponse exploitable sur le domaine énergétique étudié.

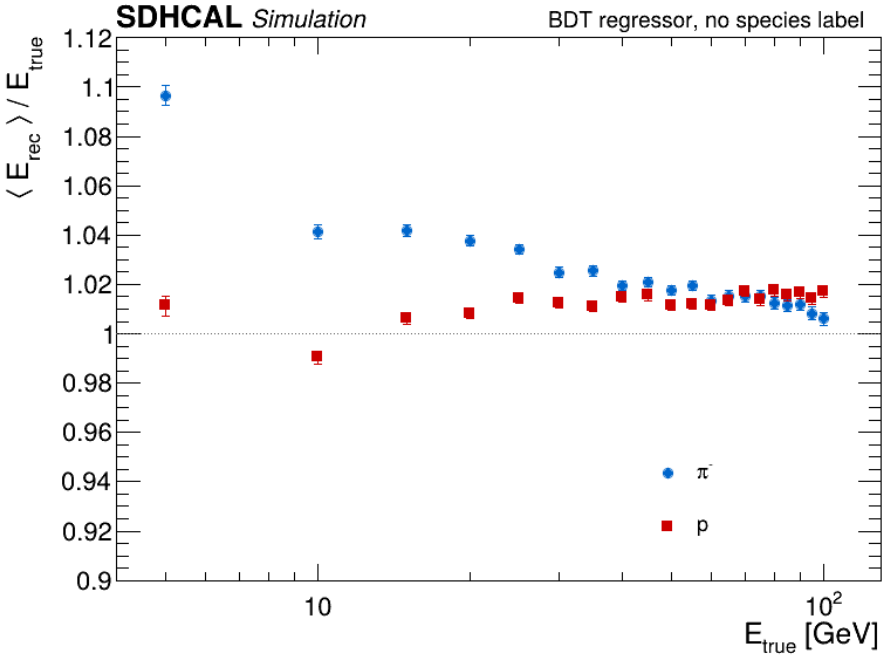


FIGURE 4.3. Linéarité et biais relatif de la régression LightGBM.

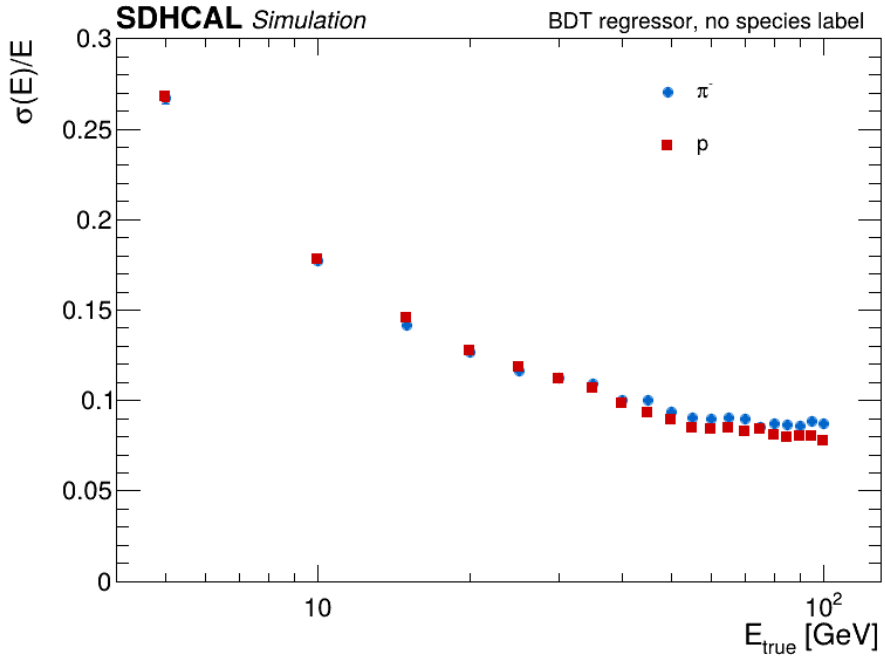


FIGURE 4.4. Indicateur de dispersion relative obtenu avec la régression LightGBM.

4.7 Comparaison et portée des résultats

La méthode paramétrique est compacte, rapide et interprétable ; la régression peut exploiter des corrélations plus riches, au prix d'une dépendance accrue à la simulation et au domaine d'entraînement.

Le choix de l'estimateur modifie surtout la linéarité, tandis que les différences de dispersion entre scénarios restent plus limitées. Le chapitre 5, établi à 20 et 80 GeV, compare ces effets sur un échantillon contenant plusieurs espèces.

4.7.1 Paramétrisation de la résolution

Une résolution calorimétrique est souvent ajustée par

$$\frac{\sigma(E)}{E} = \frac{a}{\sqrt{E/\mathrm{GeV}}} \oplus b. \tag{4.5}$$

Le terme de bruit c/E de l'équation 1.5 est omis, et cette omission n'est pas une simplification d'écriture. La chaîne de digitalisation employée ici (chapitre 2) enchaîne sélection temporelle, efficacité de détection, charge induite fluctuante, diffusion transverse et application des seuils, sans injecter de bruit électronique : aucun hit fortuit n'est produit, de sorte que c vaut exactement zéro par construction dans ces échantillons. L'ajuster reviendrait à ajouter un paramètre libre que les données ne contraignent pas. Sur détecteur réel, un bruit résiduel se traduirait par un nombre à peu près constant de hits fortuits, donc par une contribution relative en $1/E$; l'estimer demanderait des données de faisceau et des prises de données au repos, et ne peut pas se faire sur simulation seule.

Un ajustement fiable de a et b exige une estimation non biaisée de la largeur dans chaque tranche d'énergie ainsi que ses incertitudes. Ces conditions n'étaient pas réunies pour les courbes présentées plus haut, dont la largeur est extraite d'un cœur tronqué non corrigé ; les paramètres n'en sont donc pas tirés.

Elles le sont en revanche sur la production à énergies fixes décrite à la section 4.7.3, qui fournit vingt points d'énergie avec une statistique suffisante par point. Les résultats correspondants sont rassemblés au Tableau 4.2. Séparer les deux termes n'est pas une commodité d'écriture : a est fixé par les fluctuations d'échantillonnage du détecteur, tandis que b regroupe ce qui ne s'améliore pas avec la statistique — dispersion de calibration, fuites, non-compensation. Une résolution citée à une seule énergie confond les deux et masque *lequel* un estimateur a réellement amélioré.

4.7.2 La coupure de confinement et ce qu'elle impose

Tous les estimateurs comparés ci-dessous sont évalués sous une même sélection : seules sont retenues les gerbes ne déposant aucun hit dans la dernière couche instrumentée. La raison est que la calibration χ^2 est ajustée sous cette coupure, et l'évaluer sans elle reviendrait à l'appliquer hors du domaine où ses coefficients ont été déterminés. La coupure va donc à tous les bras de la comparaison ou à aucun.

Ce choix a un coût qu'il faut énoncer, car il conditionne la lecture de a et b. Avec une profondeur d'environ $6\,\lambda_I$ (chapitre 2), le confinement longitudinal se dégrade vite avec l'énergie :

TABLE 4.1. Fraction d'événements survivant à la coupure de confinement, sur la production à énergies fixes (10^4 événements générés par point).

E [GeV]	5	20	50	80	100
Survie	95,8 %	75,3 %	48,1 %	29,2 %	23,1 %

L'acceptance chute d'un facteur quatre sur la gamme. À 100 GeV, ne conserver que les gerbes entièrement contenues revient à sélectionner le quart qui s'amorce le plus tôt et se développe le plus compactement, c'est-à-dire précisément la population dont les fluctuations sont les plus faibles. Les résolutions citées aux hautes énergies sont donc meilleures que celles d'un lot non sélectionné, et deux conséquences en découlent.

D'une part, l'échantillon effectif n'est pas le même d'un point d'énergie à l'autre : l'ajustement de l'équation 4.5 porte sur des points dont la sélection varie de 96 % à 23 %. Les termes a et b qui en sortent caractérisent le couple détecteur–sélection, et non le détecteur seul ; ils ne sont pas directement comparables à des termes publiés sans cette coupure. D'autre part, l'acceptance dépend légèrement de l'espèce — à 100 GeV, 24,7 % pour les pions contre 21,5 % pour les protons — de sorte que le mélange π/p effectif dérive avec l'énergie, ce dont il faut tenir compte au chapitre 5.

La coupure reste néanmoins le choix le moins mauvais ici : la comparaison entre estimateurs, qui est l'objet de ce chapitre, se fait à sélection identique, et c'est elle qui porte les conclusions. Lever la coupure demanderait de réajuster la calibration sur le lot complet et de traiter explicitement les fuites, ce qui constitue une étude en soi.

4.7.3 Reconstruction au niveau des hits

Une extension naturelle consisterait à appliquer un réseau graphique directement aux hits semi-digitaux. Sur le prototype CMS HGCAL complété par l'AHCAL, un réseau à réduction dynamique (DRN) a été entraîné sur les amplitudes et les coordonnées des cellules, puis validé sur des données de faisceau de pions [34]. Le graphe y est reconstruit dans un espace latent, traité par des opérations de type EdgeConv, puis réduit hiérarchiquement avant la régression. Dans cette configuration analogique, le DRN améliore d'environ un facteur deux la résolution par rapport à une sommation pondérée et apprend en particulier à compenser une partie des fluctuations de la composante électromagnétique et des fuites.

Pour le SDHCAL, la transposition prudente consiste à conserver l'estimateur semi-digital comme échelle de référence et à apprendre une correction événementielle,

$$E_{\text{reco}} = E_{\text{SD}}\, C_\theta(G), \tag{4.6}$$

où G contient les positions, les seuils et les temps des hits. Cette construction préserve l'interprétation de la calibration à trois seuils tout en donnant accès à la morphologie fine de la gerbe. Les performances publiées pour HGCAL ne constituent cependant pas un objectif numérique : le détecteur est analogique, seuls les pions sont considérés, une partie du gain provient de la correction des fuites, et la largeur y est extraite par un ajustement gaussien du cœur de la distribution.

Mise en œuvre. Cette construction a été réalisée sur les deux productions pion/proton décrites à la section 3.7 : ajustement de la calibration χ^2 et entraînement du réseau sur la production continue, évaluation sur la production à énergies fixes. Le réseau prend en entrée les amas de hits — environ 191 par événement — et apprend $\log\left(E_{\text{vrai}}/E_{\chi^2}\right)$, c'est-à-dire le logarithme du facteur C_θ de l'équation 4.6.

L'architecture retenue n'est pas un réseau de graphes mais un encodeur d'ensemble invariant par permutation, de type DeepSets : chaque amas est encodé isolément, puis mis à jour par un résumé global de l'événement, sans qu'aucune arête ne soit construite. Ce choix suit l'étude DHCAL [32], qui

trouve ce modèle à la fois plus précis et nettement moins coûteux que l'attention sur un graphe de plus proches voisins. Il a une conséquence qu'il faut énoncer : le gain mesuré plus bas ne peut pas être attribué à la connectivité explicite entre amas, puisqu'il n'y en a aucune. Il vient de l'accès aux amas eux-mêmes, et de la capacité du modèle à pondérer leur contribution individuelle — ce qu'une somme de compteurs par seuil ne permet pas.

Les coefficients de la calibration servant de référence sont eux-mêmes ajustés hors échantillon, ce qui n'était pas le cas de ceux de la section 4.5 : sur les mêmes événements d'évaluation, ce seul changement ramène le biais du pion de −1,81 % à −0,07 % et celui du proton de −2,24 % à −0,46 %.

TABLE 4.2. Termes stochastique et constant de l'équation 4.5, résolution globale et écart maximal de la réponse à l'unité. Évaluation sur les 100 744 événements confinés de la production à énergies fixes, avec la même sélection pour tous les estimateurs.

Estimateur	$N_{\text{entr.}}$	a [%]	b [%]	σ/E	$\max\lvert\mathscr{R}-1\rvert$
Réseau sur amas, cible C_θ	79 451	45,5 ± 1,0	6,4 ± 0,2	0,1115	0,028
BDT, cible C_θ	176 000	53,7 ± 1,0	5,6 ± 0,3	0,1197	0,052
BDT, cible énergie	176 000	53,6 ± 1,1	5,6 ± 0,3	0,1199	0,054
Calibration χ^2	—	54,4 ± 1,2	7,0 ± 0,3	0,1295	0,031

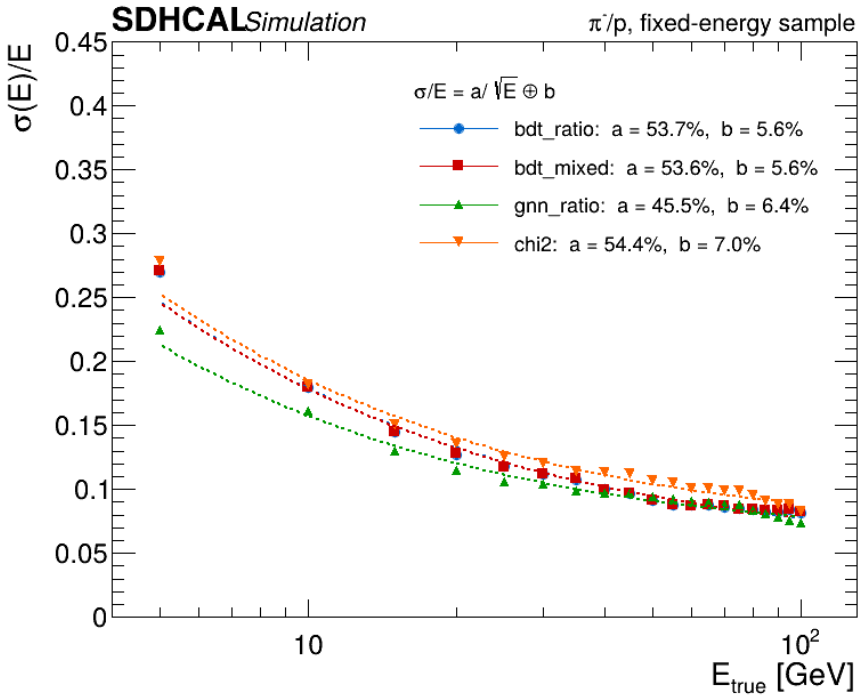


FIGURE 4.5. Résolution en énergie des estimateurs comparés. Les traits discontinus représentent l'ajustement de l'équation 4.5.

Ce que la colonne σ/E ne dit pas. La résolution globale du tableau est obtenue en regroupant tous les événements de la production à énergies fixes, qui compte vingt points également peuplés à la génération. Ce n'est donc pas « la résolution du SDHCAL » mais celle d'un spectre plat, et la distinction n'est pas rhétorique : en repondérant les mêmes points par un spectre en $1/E$, puis en $1/E^2$, la valeur du réseau sur amas passe de 0,103 à 0,144 puis 0,190, et celle de la calibration χ^2 de 0,119 à 0,171 puis 0,231. L'écart atteint presque un facteur deux.

C'est la même objection que celle opposée à l'exactitude au chapitre 3 — une figure de mérite ne doit pas dépendre de la composition de l'échantillon de test — et elle vaut ici aussi. Deux choses la désamorcent toutefois. Le *classement* des estimateurs est inchangé sous les trois pondérations, de sorte que les comparaisons de ce chapitre sont robustes. Et les termes a et b, eux, sont ajustés point par point et ne dépendent pas du spectre : ce sont eux qu'il faut citer pour caractériser un estimateur, la colonne σ/E ne servant qu'à situer l'ordre de grandeur sur ce lot précis.

Le terme stochastique est un plancher, sauf au niveau des hits. La calibration χ^2 et les deux variantes du BDT sont compatibles autour de 54 %, dans leurs incertitudes : aucun estimateur fondé sur les descripteurs de gerbe ne déplace ce terme, ce qui est cohérent avec son interprétation comme propriété de l'échantillonnage du détecteur. Le réseau lisant les amas l'abaisse à $45{,}5 \pm 1{,}0$ %, soit huit points, très au-delà des incertitudes.

Les deux familles n'améliorent pas le même terme. L'avantage du BDT sur la calibration χ^2 réside entièrement dans le terme *constant* (5,6 % contre 7,0 %, environ quatre écarts-types), c'est-à-dire dans le traitement de la calibration et des fuites. Celui du réseau réside dans le terme *stochastique*, c'est-à-dire dans la compensation, événement par événement, du partage entre composantes électromagnétique et hadronique — précisément le mécanisme invoqué pour le DRN de HGCAL. Ce sont deux effets distincts, qu'une résolution globale confond.

Le gain tient à l'information, non à la formulation. La forme 4.6 est *nécessaire* au réseau : entraîné directement sur $\log E$, il plafonne à $\sigma/E = 0{,}203$ avec un terme stochastique de 78 %, et surtout une réponse dérivant de 1,21 à 5 GeV à 0,81 à 100 GeV. Ce tassement vers la moyenne de l'échantillon améliore artificiellement la résolution apparente aux extrémités de la gamme tout en détruisant la linéarité, ce que seul le suivi de la réponse (Figure 4.6) permet de détecter.

Elle n'est pas pour autant *suffisante*. Appliquée au BDT sur descripteurs de gerbe, la même cible ne change rien : $a = 53{,}7 \pm 1{,}0$ % contre $53{,}6 \pm 1{,}1$ %. La formulation a donc permis au réseau d'exploiter une information que les descripteurs ne portent pas ; elle ne l'a pas créée. C'est, dans ce travail, l'argument le plus direct en faveur des méthodes au niveau des hits — et il contraste avec le constat de la section 3.7, où le même accès aux hits n'apporte rien à l'identification.

Réserves. Le réseau a été entraîné sous contrainte de temps de calcul et dispose de deux fois moins d'événements que le BDT ; la comparaison lui est donc défavorable sur ce point, ce qui renforce plutôt la conclusion. La dispersion de graine n'a été établie que pour le BDT, où la résolution vaut $0{,}1200 \pm 0{,}0008$ sur cinq graines : l'écart au réseau y est très supérieur. La comparaison de $a = 45{,}5$ % aux valeurs publiées sur DHCAL [32] doit tenir compte de détecteurs, de gammes d'énergie et de définitions du cœur différents, et toutes les valeurs de ce chapitre sont celles d'un échantillon confiné (section 4.7.2).

Enfin, l'estimateur de dispersion lui-même repose sur une hypothèse. La largeur est extraite du cœur central à 90 % puis corrigée du facteur de troncature gaussien ; cette correction est exacte pour un cœur gaussien, ce que les résidus hadroniques ne sont pas tout à fait. Sur des distributions à queues lourdes, l'incertitude associée est sous-estimée d'environ un quart. Les écarts discutés plus haut — 0,009 entre familles d'estimateurs, 0,0002 entre sources d'étiquette au chapitre 5 — se situent l'un très au-dessus et l'autre très en dessous de cette marge, de sorte qu'aucune conclusion n'en dépend. Il reste

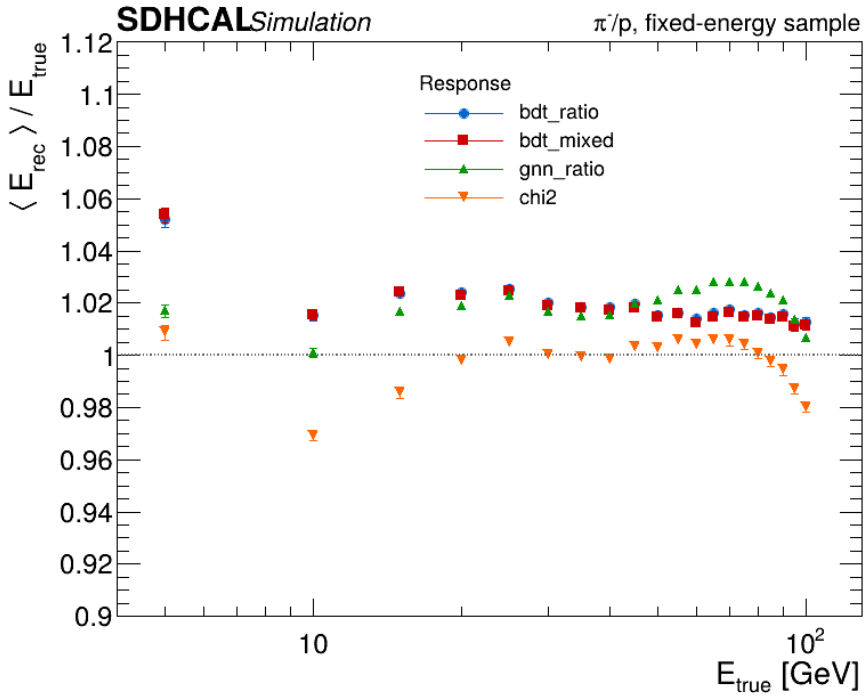


FIGURE 4.6. Réponse moyenne $\langle E_{\text{rec}} \rangle / E_{\text{vrai}}$ des estimateurs entraînés sur la cible C_θ, comparée à la calibration χ^2. Les trois estimateurs appris restent plats à +1 à +2 % sur l'essentiel de la gamme, l'écart le plus fort étant le +5 % des BDT au premier point ; la calibration χ^2 présente une pente résiduelle, de −3 % à 10 GeV à −2 % à 100 GeV.

à vérifier, sur ce détecteur, si une connectivité explicite entre amas ajoute quoi que ce soit à l'encodeur d'ensemble employé ici : la question n'a pas été tranchée faute de temps de calcul.

4.8 Limites et systématiques

Les résultats reposent entièrement sur simulation. Leur transfert aux données réelles dépend de la modélisation des interactions hadroniques, du bruit, des inefficacités, de la calibration des chambres et des fuites. Une validation expérimentale demanderait donc de confronter les distributions d'entrée et les performances à des données de faisceau, en conservant le même protocole d'entraînement et d'évaluation.

L'étude CALICE sur données de faisceau fournit une base concrète pour cette évaluation [9]. Elle considère comme sources systématiques le choix de la fonction d'ajustement des distributions d'énergie (gaussienne ou Crystal Ball), la variation des coupures de sélection, le biais de sélection estimé sur simulation, la correction de la réponse au cours du spill et l'incertitude sur l'énergie du faisceau. Une reprise de ce travail devrait au minimum adapter ces variations à la chaîne simulée, puis ajouter celles liées à la liste de physique Geant4, aux paramètres de digitalisation et au domaine d'entraînement des modèles. L'analyse des mélanges d'espèces est développée au chapitre suivant.

Chapitre 5

Analyse sur échantillons mixtes

5.1 Motivation et scénarios comparés

Lorsque l'espèce incidente n'est pas connue, l'utilisation d'une calibration spécialisée exige d'abord une décision de PID. Une erreur de classification route alors l'événement vers un estimateur inadapté et peut déplacer l'échelle d'énergie. Trois scénarios sont comparés :

(i) une calibration paramétrique déterminée sur les pions puis appliquée à toutes les espèces, notée χ^2 **pion vers tous** ;

(ii) le classificateur BDT suivi de la calibration paramétrique de la classe prédite, noté **BDT +** χ^2 ;

(iii) le même classificateur suivi d'une régression d'énergie BDT spécifique à la classe prédite, noté **BDT + BDT**.

Le premier scénario est une référence simple correspondant à l'application universelle de la calibration pion. Il ne constitue pas une borne inférieure mathématique et ne doit pas être interprété comme le meilleur estimateur possible sans PID. Les deux autres scénarios incluent les erreurs du classificateur.

5.2 Chaîne PID + régression BDT

Dans cette chaîne, chaque événement est classé puis traité par le régresseur associé à la classe prédite. Les résultats de linéarité et de dispersion sont donnés Figures 5.1 et 5.2.

5.3 Chaîne PID + méthode paramétrique

Le scénario BDT + χ^2 utilise le même routage, mais applique ensuite la calibration analytique de l'équation 4.2. Les figures correspondantes sont reportées en Annexe E.4. Cette séparation entre classification et calibration conserve une interprétation simple de l'estimateur, mais reste directement sensible aux confusions entre espèces.

5.4 Référence pion appliquée à toutes les espèces

La référence χ^2 pion vers tous applique une unique calibration à l'ensemble du mélange, sans décision de PID. Les résultats sont donnés Figures 5.4 et 5.5. Ils illustrent le biais introduit lorsque la réponse d'une espèce est reconstruite avec une calibration déterminée sur une autre.

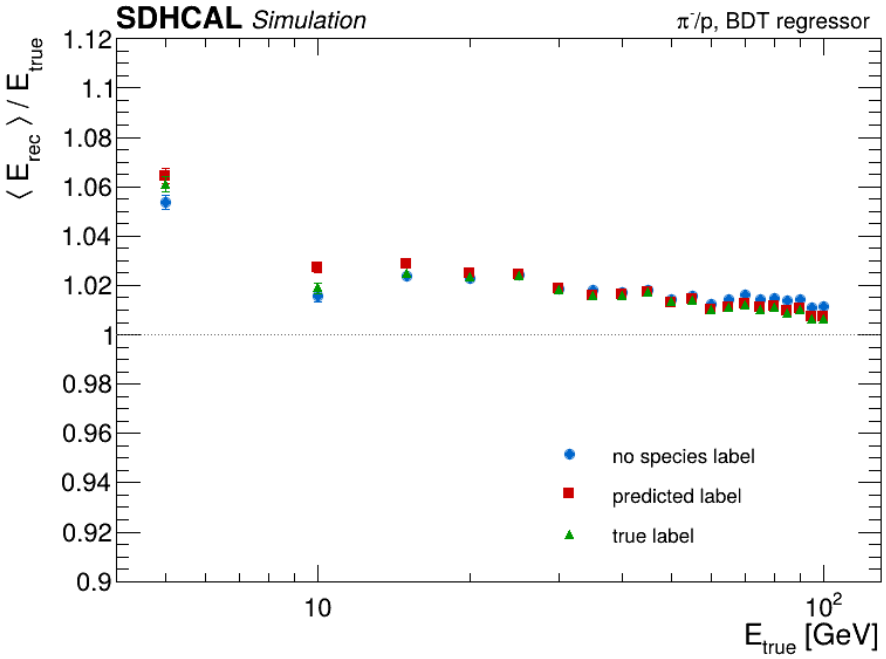


FIGURE 5.1. Réponse moyenne du régresseur BDT selon la source de l'étiquette d'espèce. Les trois courbes sont confondues : l'étiquette, même exacte, ne déplace pas la réponse.

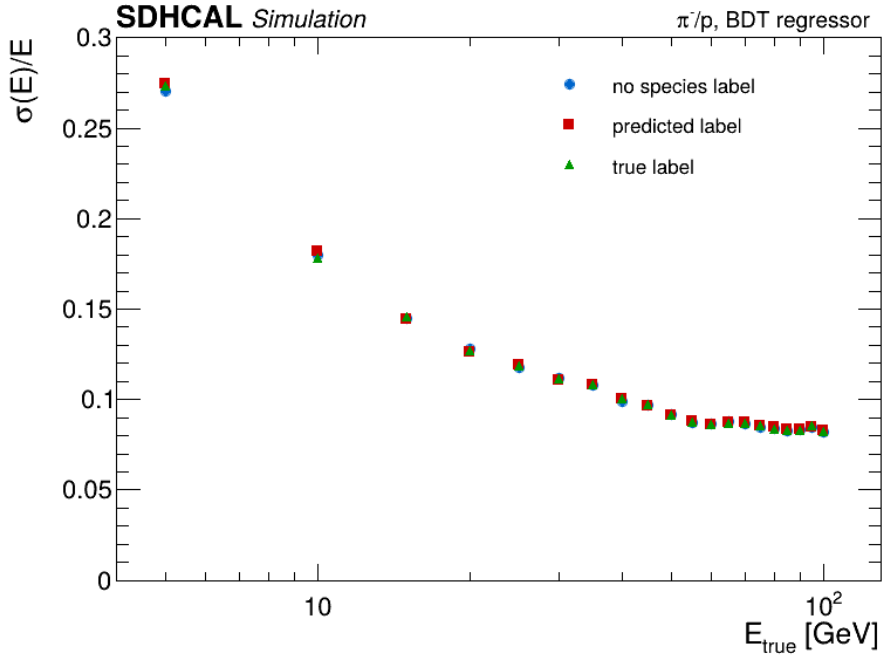


FIGURE 5.2. Résolution du régresseur BDT selon la source de l'étiquette d'espèce. Les trois courbes se superposent sur toute la gamme.

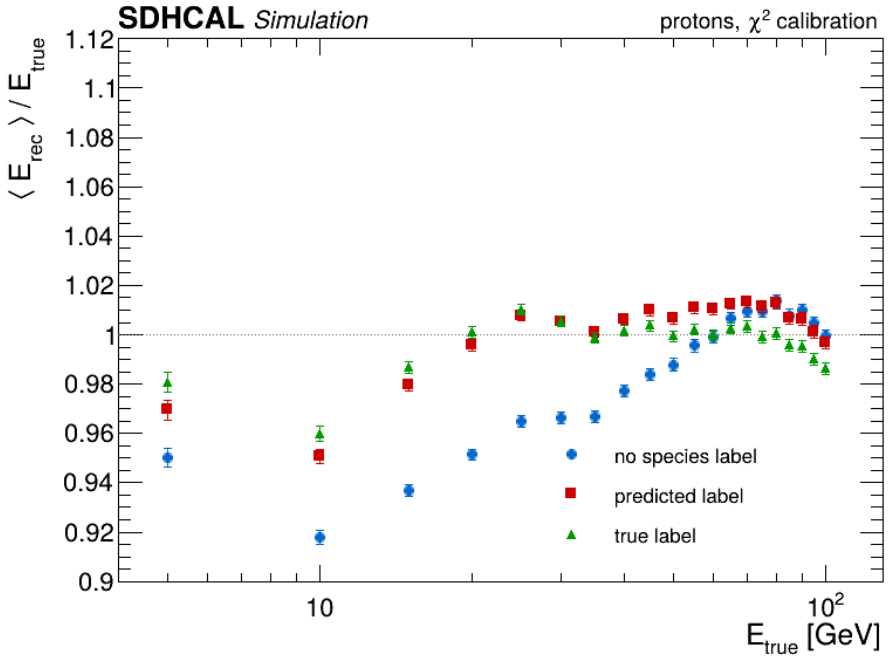


FIGURE 5.3. Réponse moyenne pour les *protons* seuls, avec la calibration χ^2. Sans étiquette d'espèce, le proton est reconstruit environ 5 % trop bas à 5 GeV et l'écart ne se referme qu'au-dessus de 50 GeV ; l'étiquette, prédite ou vraie, ramène la réponse au voisinage de l'unité sur toute la gamme. C'est l'effet que le routage corrige, et il est porté par cette seule espèce.

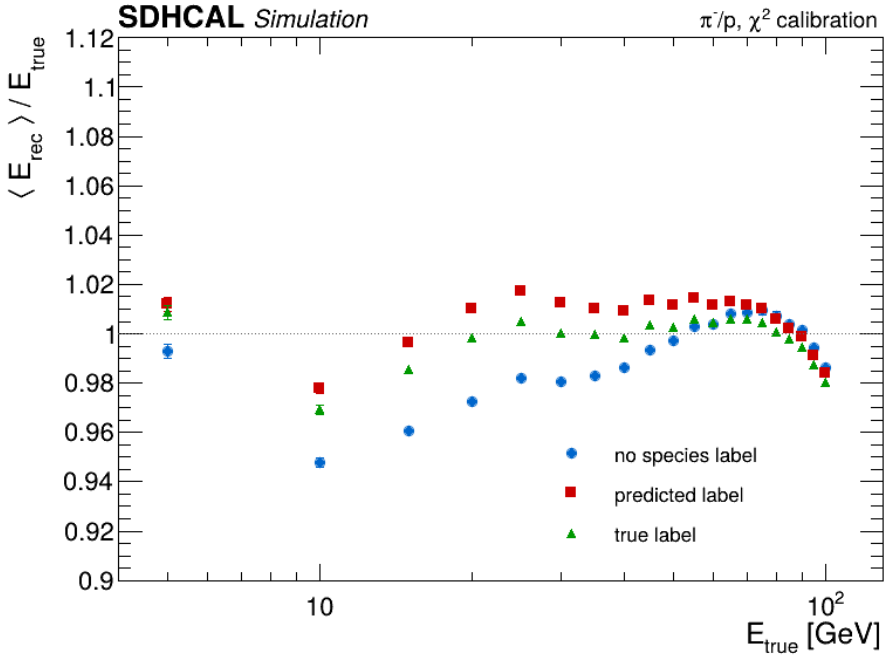


FIGURE 5.4. Réponse moyenne de la calibration χ^2 selon la source de l'étiquette d'espèce. Ici l'étiquette compte : sans elle, les coefficients du pion s'appliquent au proton.

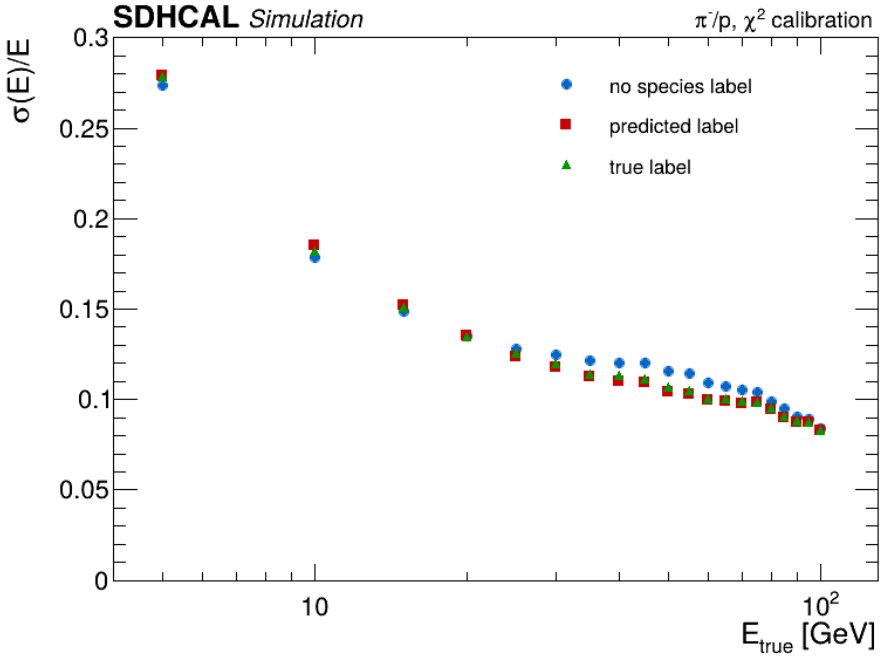


FIGURE 5.5. Résolution de la calibration χ^2 selon la source de l'étiquette d'espèce.

5.5 Comparaison quantitative à 20 et 80 GeV

Le Tableau 5.1 rassemble les biais calculés à partir des prédictions événement par événement, à deux énergies qui encadrent la gamme utile. Il porte sur les deux espèces chargées : l'approfondissement décrit plus bas repose sur des productions pion/proton, et les échantillons à trois espèces exploités au chapitre 3 relèvent d'une production antérieure, dont les tables par événement n'ont pas été conservées.

TABLE 5.1. Biais relatif $\delta(E)$ en pourcentage à 20 et 80 GeV, sous la coupure de confinement, avec des coefficients de calibration ajustés hors échantillon. Les incertitudes valent 0,2 à 0,3 point.

	π^-		p	
Scénario	20	80	20	80
χ^2 pion vers tous	−0,5	+0,1	−4,9	+1,4
BDT + χ^2	+2,5	−0,1	−0,4	+1,3
BDT + BDT	+3,8	+1,0	+1,2	+1,3

L'effet du routage n'est pas le même aux deux bouts de la gamme, et c'est le fait marquant. À 20 GeV, il corrige franchement le proton : la calibration pion appliquée à toutes les espèces le reconstruit 4,9 % trop bas, l'étiquette prédite ramène cet écart à 0,4 %. Le prix est un déplacement du pion, de −0,5 % à +2,5 %, parce que l'ajustement par espèce redistribue l'erreur d'échelle au lieu de la supprimer.

À 80 GeV, en revanche, les trois scénarios se rejoignent entre −0,1 et +1,4 %, et la calibration pion universelle n'est plus la moins bonne. L'avantage du routage est donc concentré à basse énergie, là où les coefficients dépendent le plus de l'espèce ; il s'efface là où les gerbes sont assez développées pour que les compteurs aux trois seuils suffisent.

Les courbes de dispersion diminuent avec l'énergie et restent proches entre les scénarios, comme le montrent les Figures 5.2 et 5.5. L'effet le plus net du PID dans cette comparaison concerne donc le contrôle de l'échelle d'énergie, et seulement en dessous de quelques dizaines de GeV. Cette dépendance en énergie prépare la section 5.7, où la comparaison à un régresseur réellement inclusif montre que même ce gain résiduel ne survit pas au changement d'estimateur.

5.6 Limites de l'analyse

Cette comparaison ne permet pas d'isoler séparément le gain d'un PID parfait, le coût des erreurs de classification et le gain propre à chaque régresseur, car toutes les combinaisons correspondantes n'ont pas été étudiées. Elle ne compare pas non plus les chaînes à un estimateur inclusif optimisé sans PID. Il serait donc excessif de conclure que le PID surpasse systématiquement toute méthode indépendante de l'espèce.

La stabilité des résultats vis-à-vis de la composition du mélange et des incertitudes systématiques de simulation reste à étudier. Les résultats établissent néanmoins une tendance cohérente : l'information d'espèce peut réduire certains biais de calibration, tandis que les dispersions restent dominées par les fluctuations intrinsèques des gerbes.

5.7 Lever la réserve : le gain vient-il du PID ou du régresseur ?

La première de ces limites est la plus gênante, car elle porte sur la conclusion elle-même : si la seule référence sans identification est une calibration pion appliquée aux protons, tout estimateur qui tient compte de l'espèce paraîtra meilleur, qu'il ait ou non appris quoi que ce soit de la morphologie des gerbes. Les deux productions pion/proton de la section 3.7 permettent de séparer les deux effets, en croisant la *source de l'étiquette* — aucune, prédite, vraie — avec le *régresseur* qui la consomme. La cellule décisive est celle qui manquait au protocole initial : un régresseur inclusif, entraîné sur le mélange sans jamais recevoir l'espèce.

TABLE 5.2. Biais moyen et résolution globale selon la source de l'étiquette d'espèce et le régresseur. Même coupure de confinement partout, sur 100 744 événements, ramenés à 100 678 pour les deux lignes à étiquette prédite, où le classificateur n'en couvre pas quelques-uns ; l'écart, de 0,07 %, est sans effet sur les quantités citées. Les coefficients de calibration sont ajustés hors échantillon.

Étiquette	Régresseur	Biais moyen [%]	σ/E
aucune (référence pion)	χ^2	−1,36	0,1342
prédite (BDT)	χ^2	+0,60	0,1287
vraie	χ^2	−0,27	0,1295
aucune (régresseur inclusif)	BDT	+2,00	0,1199
prédite (BDT)	BDT	+2,02	0,1201
vraie	BDT	+1,88	0,1199

Les trois premières lignes reproduisent le résultat du chapitre : à régresseur paramétrique fixé, passer d'une calibration pion universelle à une calibration routée par espèce fait gagner 0,005 en résolution, et l'étiquette prédite suffit — elle fait même marginalement mieux que l'étiquette vraie, ce qui indique que l'écart entre les deux dernières lignes n'est plus significatif à cette statistique.

Les trois dernières lignes renversent la lecture, et l'énoncé est ici littéral. Dès que le régresseur est un BDT entraîné sur le mélange, l'étiquette ne porte plus rien : sans aucune étiquette la résolution vaut 0,1199, avec l'étiquette prédite 0,1201, avec l'étiquette *vraie* 0,1199. Les trois valeurs sont confondues, à comparer à des incertitudes de 0,0003 et surtout à la dispersion de graine du BDT lui-même, $0{,}1200 \pm 0{,}0008$ sur cinq graines (section 4.7.3). Une identification parfaite ne vaut donc pas davantage qu'aucune identification. Le changement de régresseur, lui, vaut 0,009 — un ordre de grandeur au-dessus.

L'interprétation est que les descripteurs de gerbe utilisés par le régresseur contiennent déjà l'information d'espèce dont il a besoin : ce sont en grande partie ceux-là mêmes sur lesquels le classificateur s'appuie (section 3.3). Router explicitement revient alors à lui fournir une projection appauvrie de ce qu'il lit déjà. Le gain attribué au PID au paragraphe précédent était celui du remplacement d'une calibration universelle inadaptée, non celui de la connaissance de l'espèce.

Deux réserves subsistent. Le biais résiduel de +2 % de la chaîne BDT n'est pas imputable aux erreurs d'identification, puisqu'il vaut déjà +2,00 % sans aucune étiquette et +1,88 % avec l'étiquette vraie : il appartient au régresseur. Et ce constat est établi pour un mélange pion/proton équilibré ; une composition fortement asymétrique, ou l'ajout d'une espèce que le régresseur n'a pas vue à l'entraînement, pourrait rendre l'étiquette utile à nouveau.

Conclusion générale

Ce mémoire étudie deux problèmes couplés dans le SDHCAL : l'identification de l'espèce hadronique et la reconstruction de son énergie. La granularité du détecteur et sa lecture semi-digitale donnent accès à la densité et à la morphologie des gerbes, mais la stochasticité des interactions hadroniques limite la séparation des espèces et la précision énergétique.

Pour le **PID multiclasse**, le modèle LightGBM atteint une accuracy équilibrée de 67.8 %. Les rappels sont de 48.8 % pour les pions, 68.6 % pour les protons et 86.0 % pour les K^0. La difficulté principale est la confusion pion/proton : 47.9 % des pions sont classés comme protons. Dans l'étude binaire employée pour la reconstruction d'énergie, répétée sur cinq graines, l'accuracy équilibrée vaut $61{,}3 \pm 0{,}1$ %, avec $49{,}7 \pm 0{,}2$ % de pions et $72{,}9 \pm 0{,}2$ % de protons correctement identifiés. L'analyse des variables montre que la séparation repose principalement sur l'activité au troisième seuil, la densité locale et la morphologie de la gerbe.

Pour la **reconstruction d'énergie**, deux familles d'estimateurs ont été étudiées : la calibration paramétrique fondée sur les compteurs aux trois seuils et une régression BDT exploitant davantage de descripteurs. L'apport du PID se lit surtout sur le biais, et seulement à basse énergie. Pour les protons à 20 GeV, le biais passe de $-4{,}9$ % avec la calibration pion universelle à $-0{,}4$ % avec BDT + χ^2. À 80 GeV, les trois scénarios se rejoignent entre $-0{,}1$ et $+1{,}4$ % et le routage ne départage plus rien. Les courbes de dispersion sont proches entre scénarios ; elles ne permettent pas d'attribuer au PID un gain absolu de résolution avec la même précision que pour le biais.

Ces résultats ne démontrent pas à eux seuls qu'un routage par PID surpasse tout estimateur inclusif : la référence employée ici est une calibration pion appliquée à toutes les espèces, et non un modèle sans PID optimisé sur le mélange. Ils indiquent néanmoins que la connaissance, même imparfaite, de l'espèce peut corriger une partie des décalages d'échelle dus à une calibration universelle.

Trois de ces conclusions ont été reprises sur deux productions pion/proton indépendantes, qui permettent d'entraîner et d'évaluer sur des échantillons disjoints par construction.

Sur le **PID** (section 3.7), le plafond mesuré n'est pas une marge de progression : une étude indépendante sur DHCAL [32], entraînée sur près de trois cents fois plus d'événements, retrouve la même confusion π/p dominante, dont le mécanisme est connu [33]. La confusion de 47,9 % rapportée ici doit donc se lire comme une limite physique des topologies de gerbe.

Sur le **couplage** (section 5.7), la réserve formulée au paragraphe précédent se trouve justifiée, et sa levée renverse la lecture. Comparé à un régresseur inclusif réellement optimisé — et non à une calibration pion appliquée à toutes les espèces —, le routage par identification n'apporte plus rien, au sens littéral : la résolution vaut 0,1199 sans aucune étiquette d'espèce, 0,1201 avec l'étiquette prédite et 0,1199 avec l'étiquette *vraie*, pour une dispersion de graine de 0,0008. Le gain attribué au PID était celui d'une calibration universelle inadaptée, non celui de la connaissance de l'espèce.

Sur l'**énergie** enfin (section 4.7.3), la décomposition $\sigma/E = a/\sqrt{E} \oplus b$ montre que les estimateurs fondés sur les variables de gerbe, BDT comme calibration χ^2, partagent le même terme stochastique

d'environ 54 % et ne diffèrent que par le terme constant. Un encodeur d'ensemble travaillant sur les amas de hits, sans aucune arête, abaisse ce terme stochastique à $45{,}5 \pm 1{,}0$ %, et une expérience de contrôle établit que ce gain tient à l'information exploitée et non à la formulation de la cible. C'est, dans cette analyse, le principal argument en faveur des méthodes au niveau des hits.

La portée de ces résultats reste celle d'une étude sur simulation. Une validation sur données de faisceau et une évaluation des incertitudes liées au modèle hadronique, à la réponse du détecteur et à la composition des échantillons seront nécessaires avant toute conclusion expérimentale.

Perspectives

La perspective qui ouvrait cette section — mesurer séparément l'estimateur inclusif, le gain d'une identification parfaite et le coût des erreurs de classification — a été traitée section 5.7, à sélection et échantillon identiques. Sa réponse est négative et appelle une question différente : puisque le régresseur inclusif égale le routage idéal, l'information d'espèce que le routage apporterait est déjà contenue dans les descripteurs qu'il lit. Reste à savoir si cela tient encore hors des conditions testées — un mélange fortement asymétrique, une espèce absente de l'entraînement, ou des données de faisceau où les descripteurs sont plus bruités que dans la simulation.

Le PID pion/proton reste le principal verrou. Des performances par tranche d'énergie, une calibration des probabilités et une étude d'ablation systématique des groupes de variables permettraient de mieux comprendre la séparation. Pour la reconstruction, un modèle inclusif prenant les probabilités de classes comme entrées éviterait un routage discontinu et pourrait exploiter l'incertitude du PID.

L'approche GNN demeure une piste exploratoire pour utiliser directement les hits. Les études récentes sur DHCAL et AHCAL indiquent qu'un modèle d'ensemble comme DeepSets constitue une référence pertinente et que le bénéfice du temps dépend fortement de l'architecture et de la tâche [32, 29]. La validation sur données de faisceau d'un réseau dynamique pour la reconstruction de pions dans HGCAL motive aussi l'apprentissage d'une correction graphique de l'estimateur semi-digital [34]. Une reprise devra donc comparer DeepSets, le graphe statique actuel et un graphe dynamique à données, découpages et résolutions temporelles identiques, afin d'établir si la connectivité explicite apporte une information supplémentaire par rapport aux variables construites.

Enfin, toute conclusion expérimentale exige une confrontation aux données de faisceau et une étude des systématiques : liste de physique Geant4, bruit, inefficacités, calibrations, stabilité temporelle et composition du faisceau. C'est à cette condition que les méthodes développées pourront être intégrées de manière crédible à une chaîne de reconstruction de type *Particle Flow* [5].

Annexe A

Descripteurs de gerbe : définitions

A.1 Principe et inventaire

Toutes les analyses de ce mémoire reposent sur des variables physiques dérivées des hits enregistrés dans le SDHCAL. Ces *descripteurs de gerbe* sont calculés par un outil dédié développé en `C++`, `ShowerAnalyzer`, dont le rôle est de transformer la description brute d'un événement — une liste de hits élémentaires

$$(I_i,\ J_i,\ K_i,\ x_i,\ y_i,\ z_i,\ t_i,\ \mathrm{thr}_i)$$

— en un ensemble réduit d'observables caractérisant la composition en seuils semi-digitaux, la topologie spatiale, le développement longitudinal, la compacité transverse, la structure temporelle et les éventuelles sous-structures internes. Ces variables constituent les entrées des modèles de PID et de reconstruction d'énergie.

Les fichiers simulés sont lus au format `ROOT`, chaque événement fournissant les indices de cellule `I`, `J`, l'indice de couche `K`, les positions `x`, `y`, `z`, le temps du hit, le seuil franchi, ainsi que la vérité Monte-Carlo `particle1PDG`. Les variables calculées sont ajoutées comme nouvelles branches d'un arbre enrichi, qui alimente ensuite les analyses.

Le pipeline produit les observables suivantes :

`Thr1`	`Thr2`	`Thr3`	`Begin`
`Radius`	`Density`	`NClusters`	`ratioThr23`
`Zbary`	`Zrms`	`PctHitsFirst10`	`PlanesWithClusmore2`
`AvgClustSize`	`MaxClustSize`	`lambda1`	`lambda2`
`N1`	`N2`	`N3`	`tMin`
`tMax`	`tMean`	`tSpread`	`Nmax`
`z0_fit`	`Xmax`	`lambda`	`nTrackSegments`
`eccentricity3D`	`nHitsTotal`	`sumThrTotal`	

Les sections suivantes définissent chaque famille : formule, notation employée dans le code, et sens physique.

A.2 Variables liées aux seuils semi-digitaux

Le SDHCAL repose sur une lecture *semi-digitale* à trois seuils, permettant de distinguer différents niveaux de charge déposée dans une cellule active. Chaque hit est associé à une valeur discrète $\mathrm{thr}_i \in \{1,2,3\}$ correspondant à un dépôt faible, intermédiaire ou élevé. Cette information constitue une approximation de la densité locale d'ionisation, donc indirectement de l'intensité du dépôt d'énergie. Les variables construites à partir de ces seuils sont rassemblées dans le Tableau A.1.

TABLE A.1. Descripteurs construits à partir de la lecture semi-digitale à trois seuils. N_{hits} désigne le nombre total de hits de l'événement.

Variable	Définition	Sens physique
`N1`, `N2`, `N3`	$N_j = \#\{i \mid \text{thr}_i = j\}$	Répartition brute des hits selon leur intensité.
`nHitsTotal`	$N_{\text{hits}} = N_1 + N_2 + N_3$	Activité globale de la gerbe.
`Thr1`, `Thr2`, `Thr3`	$100 \times N_j / N_{\text{hits}}$	Composition relative de la gerbe, indépendante de la multiplicité totale.
`ratioThr23`	$\frac{\texttt{Thr2} + \texttt{Thr3}}{\texttt{Thr1}}$	Variable de dureté : compare les hits « énergétiques » aux hits de faible amplitude. Une valeur élevée traduit une gerbe plus dense, des dépôts plus localisés, une composante électromagnétique plus marquée ou une interaction hadronique plus violente.
`sumThrTotal`	$N_1 + 2N_2 + 3N_3$	Estimateur simple de l'énergie visible totale, supérieur au simple comptage N_{hits} car il valorise les hits de seuil élevé.

Ces variables conservent l'information spécifique au mode semi-digital du SDHCAL et permettent de distinguer les gerbes diffuses riches en seuil 1, les gerbes compactes présentant un excès de seuils 2 et 3, les événements peu énergétiques contenant peu de hits, et les dépôts saturés à haute énergie. Dans les modèles d'apprentissage supervisé présentés dans ce mémoire, N_1, N_3 et `sumThrTotal` figurent parmi les variables les plus importantes pour la reconstruction d'énergie.

A.3 Descripteurs longitudinaux

Le développement longitudinal d'une gerbe hadronique constitue une source majeure d'information physique : la profondeur de première interaction, la vitesse de croissance de la cascade et son étalement dans le détecteur diffèrent selon la particule incidente et son énergie. Le `ShowerAnalyzer` calcule les observables du Tableau A.2 à partir de l'indice de couche K, utilisé comme proxy de la coordonnée en profondeur.

Ces variables longitudinales sont centrales pour l'identification pion/proton, la séparation des espèces neutres et chargées, la reconstruction d'énergie et la détection de fuites longitudinales à haute énergie. Dans les modèles LightGBM étudiés, `Begin`, `Zbary` et `PctHitsFirst10` apparaissent régulièrement parmi les descripteurs les plus informatifs.

A.4 Descripteurs transverses et géométriques

Au-delà du développement longitudinal, la forme transverse contient une information importante : deux particules de même énergie peuvent produire des signatures spatiales très différentes — gerbe compacte, diffuse, allongée, fragmentée ou multi-cœur. Les observables correspondantes sont définies dans le Tableau A.3.

Le rayon effectif s'appuie sur un axe de gerbe reconstruit au préalable : les barycentres des premières couches actives sont ajustés par deux droites $x(z) = a_1 z + b_1$ et $y(z) = a_2 z + b_2$, qui définissent la trajectoire moyenne. La distance transverse de chaque hit à cet axe, $d_i^2 = (x_i - x_0)^2 + (y_i - y_0)^2$, fournit ensuite le rayon quadratique moyen.

Ces variables permettent de distinguer une gerbe hadronique compacte d'une interaction diffuse, de repérer les événements contenant plusieurs sous-gerbes, de caractériser la direction dominante du

TABLE A.2. Descripteurs du développement longitudinal. $h(K)$ désigne le nombre de hits enregistrés dans la couche K.

Variable	Définition	Sens physique
`Zbary`	$\frac{1}{N_{\text{hits}}}\sum_i K_i$	Profondeur moyenne de dépôt. Une valeur faible indique un développement précoce, une valeur élevée une interaction plus tardive ou une pénétration plus profonde.
`Zrms`	$\sqrt{\frac{1}{N_{\text{hits}}}\sum_i (K_i - Z_{\text{bary}})^2}$	Largeur longitudinale de la gerbe : dépôt concentré (faible valeur) ou gerbe étendue et fluctuante (grande valeur).
`Begin`	$\min L$ tel que $h(L+k) \geq 4,\ k = 0..3$	Profondeur de première interaction hadronique, estimée par la première séquence de quatre couches consécutives contenant chacune au moins quatre hits ; valeur sentinelle 48 si aucune séquence n'est trouvée. Particulièrement discriminante : les pions interagissent souvent plus tôt, les protons peuvent pénétrer davantage, et les fluctuations hadroniques modulent fortement cette profondeur.
`PctHitsFirst10`	$100 \times \frac{\#\{i \mid 0 \leq K_i \leq 9\}}{N_{\text{hits}}}$	Part initiale de la gerbe. Une valeur élevée signale une interaction rapide, un fort dépôt initial ou une composante électromagnétique marquée.

TABLE A.3. Descripteurs transverses et géométriques. $\mathbf{C}$ désigne la matrice de covariance transverse des hits et $(e_1 \leq e_2 \leq e_3)$ les valeurs propres de la covariance complète sur (x, y, z).

Variable	Définition	Sens physique
`Radius`	$\sqrt{\frac{1}{N_{\text{hits}}}\sum_i d_i^2}$	Écartement moyen des hits autour de l'axe de gerbe : petite valeur pour une gerbe étroite et collimatée, grande valeur pour une gerbe diffuse ou fortement latérale.
`lambda1`, `lambda2`	valeurs propres de $\mathbf{C}$, $\lambda_1 \geq \lambda_2$	Forme du dépôt dans le plan transverse : $\lambda_1 \simeq \lambda_2$ pour une forme circulaire, $\lambda_1 \gg \lambda_2$ pour une structure allongée, deux valeurs faibles pour une gerbe compacte.
`eccentricity3D`	$\frac{e_3}{e_1 + e_2 + e_3}$	Anisotropie tridimensionnelle, comprise entre 1/3 et 1 : la borne inférieure correspond au cas isotrope $e_1 = e_2 = e_3$, la valeur 1 à une structure quasi linéaire. Sur l'échantillon, le minimum observé vaut 0,38 et la médiane 0,84.

dépôt et d'améliorer la reconstruction d'énergie via la corrélation entre forme et confinement.

A.5 Densité locale et structure en amas

La seule multiplicité des hits ne suffit pas à décrire une gerbe : deux événements de même nombre total de coups peuvent présenter des organisations internes très différentes — dépôt compact, structure fragmentée, zones vides, sous-cœurs multiples. Deux mécanismes sont utilisés pour capturer cette information.

La **densité locale pondérée** considère, pour chaque hit i, les cellules voisines dans un carré 3×3 de la même couche ($|I_j - I_i| \leq 1$, $|J_j - J_i| \leq 1$, $K_j = K_i$). Chaque voisin contribue avec un poids dépendant du seuil franchi, $w = 1$, 45.45 et 136.36 pour les seuils 1, 2 et 3 respectivement, ce qui reflète la charge typique associée à chaque niveau.

Le **clustering intra-couche** traite chaque couche active comme une grille 2D indépendante et regroupe les hits adjacents en amas par 4-connexité, $(\Delta I, \Delta J) \in \{(\pm 1, 0), (0, \pm 1)\}$, le regroupement étant réalisé par exploration de graphe. Les variables extraites sont rassemblées dans le Tableau A.4.

TABLE A.4. Descripteurs de densité locale et de structure en amas. $\mathcal{V}(i)$ désigne le voisinage 3×3 du hit i dans sa couche, n_c le nombre de hits de l'amas c.

Variable	Définition	Sens physique
`Density`	$\frac{\sum_i C_i}{\sum_i w(\text{thr}_i)}, \quad C_i = \sum_{j \in \mathcal{V}(i)} w(\text{thr}_j)$	Densité locale moyenne : valeur élevée pour des zones denses et un cœur marqué, faible pour une gerbe diffuse. Sensible aux concentrations locales d'énergie ; elle s'est révélée importante dans plusieurs modèles de PID et de régression.
`NClusters`	$\sum_K N_{\text{clusters}}(K)$	Fragmentation globale de la gerbe.
`MaxClustSize`	$\max_c n_c$	Taille du plus gros cœur local.
`AvgClustSize`	$\frac{1}{N_{\text{clusters}}} \sum_c n_c$	Taille typique des amas.
`PlanesWithClusmore2`	nombre de couches à ≥ 2 amas	Multiplicité de sous-structures dans une même couche.

Ces observables séparent les gerbes compactes dominées par un seul cœur des topologies fragmentées, des interactions secondaires multiples et des événements mal contenus, qui montrent souvent plusieurs amas dispersés. Un proton produit typiquement une gerbe plus dense et structurée, un pion davantage de fluctuations et de sous-amas. Dans les arbres boostés utilisés ici, `AvgClustSize`, `MaxClustSize` et `Density` figurent régulièrement parmi les variables utiles, car elles relient directement morphologie locale et nature de la particule incidente.

A.6 Variables temporelles

La simulation fournit une information temporelle hit par hit, complémentaire de la topologie spatiale : temps de vol de la particule incidente, chronologie du développement hadronique, composantes retardées dues aux neutrons secondaires, étalement temporel de la gerbe. Quatre observables simples en sont extraites (Tableau A.5).

TABLE A.5. Descripteurs temporels. N_t désigne le nombre de hits temporellement valides.

Variable	Définition	Sens physique
`tMin`	$\min_i(t_i)$	Premier hit de l'événement : sensible au temps de vol initial, donc à la masse de la particule à impulsion donnée, et corrélé à la profondeur de première interaction. Figure parmi les variables les plus importantes de l'étude PID.
`tMax`	$\max_i(t_i)$	Hit le plus tardif : sensible aux composantes lentes — diffusion neutronique, interactions secondaires retardées, traînes temporelles longues.
`tMean`	$\frac{1}{N_t} \sum_i t_i$	Position moyenne de la distribution temporelle.
`tSpread`	`tMax` − `tMin`	Durée totale de l'activité : faible pour un dépôt rapide et compact, grande pour une activité étalée dans le temps.

Les différences pion/proton observées dans ce travail peuvent provenir en partie de l'écart de masse $m_p \gg m_\pi$, qui produit à énergie comparable des temps de vol distincts. Une réserve importante s'attache toutefois à ces variables : la résolution temporelle native de la simulation est extrêmement fine, et un *smearing* gaussien a été appliqué dans plusieurs analyses afin d'introduire une résolution effective

finie. Une étude CALICE de séparation de gerbes dans l'AHCAL montre que l'information temporelle peut modifier sensiblement les performances d'un modèle graphique, avec un effet dépendant de l'architecture [29]. Elle ne permet cependant pas de quantifier l'effet de `tMin` sur le PID du SDHCAL. Ce point doit être établi ici par une comparaison contrôlée, sur les mêmes événements, avec et sans variables temporelles et pour plusieurs résolutions simulées.

A.7 Profil longitudinal et ajustement de Gaisser–Hillas

Au-delà de `Begin` ou `Zbary`, la forme longitudinale peut être modélisée finement. Un profil est reconstruit couche par couche en sommant les seuils, $E(K) \propto \sum_{i \in K} \mathrm{thr}_i$, le seuil semi-digital servant de proxy du dépôt d'énergie. Un point de départ est estimé au préalable comme la première couche présentant une activité soutenue sur plusieurs plans successifs, ce qui écarte les hits isolés, les pré-coups marginaux et les fluctuations non représentatives ; le profil peut ensuite être lissé par moyenne glissante. Il est ajusté par une fonction inspirée du formalisme de Gaisser–Hillas :

$$E(z) = N_{\max} \left(\frac{z - z_0}{X_{\max} - z_0} \right)^{\frac{X_{\max} - z_0}{\lambda}} \exp\left(\frac{X_{\max} - z}{\lambda} \right),$$

où z est la profondeur et z_0 le point de départ effectif. Les quatre paramètres ajustés constituent les variables extraites (Tableau A.6).

TABLE A.6. Variables issues de l'ajustement de Gaisser–Hillas du profil longitudinal.

Variable	Paramètre	Sens physique
`Nmax`	$N_{\max}$	Amplitude maximale du profil : corrélée à l'énergie incidente et sensible à la compacité du cœur de gerbe.
`z0_fit`	z_0	Origine effective de la cascade ; affine l'information portée par `Begin`.
`Xmax`	$X_{\max}$	Position du maximum longitudinal : précoce pour une interaction rapide, tardive pour un développement plus profond.
`lambda`	λ	Extension de la gerbe : contrôle la largeur et la décroissance après le maximum.

Ces paramètres condensent la structure complète du profil et servent à l'identification, à la reconstruction d'énergie et à la séparation des gerbes compactes et étalées. L'ajustement reste toutefois instable lorsque peu de couches sont actives, à basse énergie, lorsque la gerbe est tronquée par fuite ou lorsque plusieurs sous-cascades se superposent ; dans ces cas, les variables plus robustes (`Begin`, `Zbary`, `PctHitsFirst10`) restent plus performantes. Dans les analyses LightGBM, leur pouvoir prédictif s'est révélé secondaire par rapport à `tMin`, `sumThrTotal`, N_1, N_3 ou `Density`, tout en apportant une information complémentaire sur la morphologie profonde.

A.8 Recherche de segments quasi-linéaires

Une gerbe hadronique n'est pas uniquement un dépôt diffus : elle peut contenir des structures localement rectilignes — traces de secondaires chargés, fragments pénétrants, trajectoire résiduelle du primaire, sous-cascades collimatées. La granularité du SDHCAL permet de les identifier géométriquement, ce que quantifie la variable `nTrackSegments`.

La procédure comporte quatre étapes. Les hits de chaque couche sont d'abord regroupés par 8-connexité ($|\Delta I| \leq 1$, $|\Delta J| \leq 1$), chaque amas fournissant un barycentre (x_c, y_c, z_c). Les amas trop volumineux ou situés dans des zones trop denses sont ensuite écartés, afin de ne pas confondre le cœur de gerbe avec une trajectoire isolée : seuls les petits amas compacts, spatialement séparés du cœur, sont conservés. Une **transformée de Hough** est alors appliquée aux barycentres restants, projetés dans les plans (z, x) et (z, y), chaque maximum significatif de l'accumulateur correspondant à une trajectoire candidate. Les candidats sont enfin validés selon leur extension sur plusieurs couches, leur continuité, l'absence de grands trous, la faiblesse des résidus autour de la droite ajustée et leur non-concentration dans les seules premières couches. Le nombre de structures validées définit `nTrackSegments`.

Une valeur élevée signale plusieurs secondaires chargés énergétiques, une interaction riche en fragments ou une composante pénétrante importante ; une valeur faible correspond à une gerbe dense sans trajectoire nette, à un dépôt fortement diffus ou à une énergie plus basse. Les protons produisent typiquement des topologies plus structurées, les pions davantage de fluctuations diffuses, et les événements neutres montrent moins de traces initiales nettes.

Cette reconstruction reste difficile dans une gerbe dense — confusion avec le cœur hadronique, superposition de trajectoires, inefficacités locales, sensibilité aux paramètres de clustering. Il s'agit donc d'un indicateur morphologique, non d'un traqueur dédié : moins dominant que les variables temporelles ou de comptage, il enrichit néanmoins les modèles supervisés testés.

A.9 Corrections apportées à l'implémentation

Les définitions ci-dessus sont celles que l'analyse suppose. Une relecture de `ShowerAnalyzer.cpp` menée après la première campagne de production a montré que trois d'entre elles n'étaient pas celles effectivement calculées. Les écarts sont consignés ici parce qu'ils affectent les valeurs numériques citées dans les chapitres antérieurs à la reprise, et parce qu'aucun n'avait provoqué d'erreur à l'exécution : chacun produisait une variable d'apparence parfaitement acceptable.

`eccentricity3D` **: valeur propre inversée.** ROOT retourne les valeurs propres par ordre *décroissant*. Le code indexait l'élément `(2)` du vecteur en croyant y lire e_3, le plus grand, et y lisait en fait le plus petit. La variable calculée était donc $e_{\min} / \sum e_i$ au lieu de la définition du Tableau A.3, soit une mesure de *compacité* là où une mesure d'*allongement* était attendue, bornée par 1/3 au lieu de 1. Sa médiane sur l'échantillon passe de 0,060 à 0,833 après correction. L'implémentation prend désormais explicitement le maximum des trois valeurs propres, sans hypothèse sur leur ordre.

Ajustement de Gaisser–Hillas : paramètres non contraints. L'ajustement était lancé sans bornes et sans vérification du code de retour, de sorte qu'un échec convergeait vers des valeurs arbitraires enregistrées comme des mesures. Le cas dominant portait sur $X_{\max}$, qui atteignait 6167 mm dans un détecteur long d'environ 1250 mm. Trois corrections ont été appliquées : $X_{\max}$ est contraint à rester dans l'intervalle en profondeur réellement mesuré, le statut de l'ajustement est contrôlé et un échec écrit une valeur sentinelle plutôt qu'un nombre, et la profondeur des couches est lue dans la géométrie au lieu d'être reconstruite à partir d'un pas supposé uniforme. La borne supérieure de la boucle, restée à la couche 29 d'une version antérieure du détecteur, a par ailleurs été portée à la couche 47. L'effet se lit

sur la corrélation entre $N_{\max}$ et l'énergie primaire, qui vaut +0,79 après correction, et sur $X_{\max}$, qui croît de 243 à 404 mm sur la gamme 5–100 GeV, comme l'attend un développement logarithmique.

Condition morte. Un test `thr < 0.1` portait sur un entier valant 1, 2 ou 3 et ne pouvait jamais être vrai. La branche qu'il gardait n'avait donc jamais été exécutée ; elle a été supprimée plutôt que réparée, aucune des variables publiées n'en dépendant.

Deux points relevés lors de la même relecture ne modifient pas les variables mais le coût de la production : l'ajustement allouait un `TGraph` et un `TF1` par événement sans les libérer, et la recherche de couche dans la table du profil insérait les clés absentes au lieu de les consulter. Tous les résultats de la reprise (sections 3.7 et 4.7.3) sont issus de productions régénérées après ces corrections ; ceux des chapitres 3 à 5 proviennent de la production initiale.

A.10 Hiérarchie des variables et tableau récapitulatif

Toutes ces variables ne contribuent pas avec la même intensité aux tâches étudiées. Pour la **séparation pion/proton**, les plus discriminantes dans les modèles LightGBM sont `tMin` (temps de vol), `Begin` (profondeur de première interaction), `Density` (compacité locale), `PctHitsFirst10` (activité précoce), `Zbary` (profondeur moyenne) et `AvgClustSize` (structure locale) : elles reflètent respectivement la cinématique de la particule incidente, la chronologie de l'interaction et la topologie interne de la cascade. Pour la **reconstruction d'énergie**, ce sont `sumThrTotal`, N_1, N_3, `nHitsTotal` et `Density` qui dominent, c'est-à-dire les observables directement liées à la quantité totale de signal et à sa concentration. Les descripteurs géométriques (`lambda1`, `lambda2`, `eccentricity3D`) et les paramètres de l'ajustement de Gaisser–Hillas jouent un rôle complémentaire, tandis que `nTrackSegments` reste le plus secondaire.

Le Tableau A.7 rassemble l'ensemble des descripteurs, leur signification physique et leur usage principal.

Variable	Signification physique	Usage principal
Variables de seuils semi-digitaux		
`N1, N2, N3`	Nombre de hits aux trois seuils	Reconstruction d'énergie
`Thr1, Thr2, Thr3`	Fractions relatives des seuils	PID / Morphologie
`sumThrTotal`	Somme pondérée des seuils	Énergie
`ratioThr23`	Dureté moyenne du dépôt	PID
`nHitsTotal`	Multiplicité totale	Énergie
Descripteurs longitudinaux		
`Begin`	Première interaction visible	PID
`Zbary`	Profondeur moyenne de la gerbe	PID + Énergie
`Zrms`	Largeur longitudinale	PID
`PctHitsFirst10`	Fraction précoce des hits	PID
`Xmax`	Position du maximum longitudinal	Morphologie
`Nmax`	Intensité maximale de la gerbe	Énergie
`lambda`	Largeur du profil longitudinal	Morphologie
Descripteurs transverses		
`Radius`	Rayon transverse effectif	PID
`lambda1, lambda2`	Axes principaux du dépôt	Morphologie
`eccentricity3D`	Allongement spatial global	Topologie
Densité et amas		
`Density`	Compacité locale pondérée	PID + Énergie
`NClusters`	Nombre total d'amas	Topologie
`AvgClustSize`	Taille moyenne des amas	PID
`MaxClustSize`	Taille du plus grand amas	Morphologie
`PlanesWithClusmore2`	Plans contenant plusieurs amas	Fragmentation
Variables temporelles		
`tMin`	Premier hit temporel	PID + Énergie
`tMax`	Dernier hit observé	Morphologie
`tMean`	Temps moyen de la gerbe	Complémentaire
`tSpread`	Durée totale de l'activité	PID
Sous-structures internes		
`nTrackSegments`	Segments quasi-linéaires reconstruits	Topologie avancée

TABLE A.7. Résumé des principaux descripteurs calculés par `ShowerAnalyzer` et de leur intérêt physique dans les analyses présentées dans ce mémoire.

Chaque observable possède ainsi une interprétation reliée aux mécanismes d'interaction hadronique, tout en fournissant un espace d'entrée compact et robuste pour les méthodes supervisées. Cette construction illustre qu'un calorimètre hautement granulaire ne se limite pas à mesurer une énergie totale : il fournit une image quadridimensionnelle de l'événement, exploitable soit par des variables construites manuellement comme ici, soit directement par des approches de type CNN ou GNN (section 3.6).

Annexe B

Configuration du classificateur PID

Cette annexe décrit la mise en œuvre du classificateur hadronique supervisé du chapitre 3 : jeux de données, prétraitement, protocole d'apprentissage et hyperparamètres.

B.1 Jeux de données et variables d'entrée

Le classificateur est entraîné sur des fichiers simulés au format `ROOT`, enrichis par les variables calculées avec `ShowerAnalyzer` (Annexe A). Trois échantillons sont utilisés, un par espèce, contenant chacun environ 1.3×10^5 événements d'énergie primaire distribuée uniformément entre 1 GeV à 130 GeV ; ils sont concaténés pour former l'ensemble global d'apprentissage.

L'identité vraie de la particule est fournie par la variable `particlePDG`. Les codes retenus, -211, 2212 et 311, correspondent respectivement à π^-, p et K^0, et sont convertis en labels entiers 0, 1 et 2 pour l'apprentissage.

Les 26 variables d'entrée sont issues de l'analyse topologique et calorimétrique des gerbes :

$$\begin{aligned}\mathscr{X} = \big[&\texttt{Thr1}, \texttt{Thr2}, \texttt{Thr3}, \texttt{Begin}, \texttt{Radius}, \texttt{Density}, \texttt{NClusters}, \texttt{ratioThr23},\\ &\texttt{Zbary}, \texttt{Zrms}, \texttt{PctHitsFirst10}, \texttt{PlanesWithClusmore2}, \texttt{AvgClustSize}, \texttt{MaxClustSize},\\ &\texttt{lambda1}, \texttt{lambda2}, \texttt{tMin}, \texttt{tMax}, \texttt{tMean}, \texttt{tSpread}, \texttt{Nmax}, \texttt{z0_fit},\\ &\texttt{Xmax}, \texttt{lambda}, \texttt{nTrackSegments}, \texttt{eccentricity3D}\big].\end{aligned}$$

Elles décrivent la composition en seuils et l'activité locale, le développement longitudinal, la compacité transverse, la fragmentation en amas, la structure temporelle et la présence éventuelle de traces secondaires internes. Cette représentation condense l'information brute hit par hit en un nombre limité de variables discriminantes.

B.2 Nettoyage et prétraitement

Les tableaux extraits des fichiers `ROOT` sont d'abord inspectés pour éliminer les valeurs non physiques : les infinis positifs et négatifs sont remplacés par des valeurs manquantes, les lignes incomplètes supprimées et le tableau réindexé, ce qui évite la propagation d'erreurs numériques pendant l'apprentissage. Seuls les événements correspondant aux trois codes PDG retenus sont conservés ; les autres particules éventuellement présentes dans les arbres d'entrée sont exclues.

Un **smearing temporel** est ensuite appliqué. La résolution temporelle native de la simulation étant irréaliste, un bruit gaussien $\varepsilon \sim \mathcal{N}(0, \sigma^2)$, avec $\sigma = 0.1$ ns (soit 100 ps), est ajouté aux variables `tMin`, `tMax` et `tSpread`. Cette prescription fournit une échelle instrumentale réaliste pour l'étude, sans chercher ici

à isoler quantitativement la contribution propre de chaque observable temporelle.

Aucune normalisation explicite n'est nécessaire : les méthodes fondées sur des arbres de décision sont insensibles à l'échelle absolue des variables, contrairement aux réseaux de neurones ou aux méthodes à distance. Le pipeline travaille donc directement sur les observables physiques brutes.

B.3 Protocole d'apprentissage

Le protocole d'entraînement conditionne la validité des performances reportées : il doit garantir qu'aucune information de l'échantillon d'évaluation n'a influencé le modèle, directement ou indirectement.

Découpage en trois ensembles

Les données sont séparées en trois sous-ensembles disjoints, selon un découpage **stratifié** qui conserve les proportions relatives des trois classes. Dans un premier temps, 20 % des événements sont extraits aléatoirement pour constituer l'échantillon de **test** indépendant. Les 80 % restants sont ensuite redivisés pour en extraire un ensemble de **validation** représentant 20 % de cette portion, soit 16 % du total. La répartition finale est donc :

$$\text{train} = 64\%, \qquad \text{validation} = 16\%, \qquad \text{test} = 20\%.$$

L'ensemble d'entraînement ajuste les paramètres internes du modèle. L'ensemble de validation sert pendant l'apprentissage à surveiller la convergence et à déclencher l'arrêt anticipé. L'ensemble de test n'est utilisé qu'une seule fois, à la fin, pour estimer les performances reportées au chapitre 3 ; il n'intervient ni dans l'entraînement, ni dans le choix des hyperparamètres. Le découpage repose sur une graine fixée (`random_state` = 42), ce qui garantit la reproductibilité exacte des ensembles d'un lancement à l'autre.

Absence de fuite d'information

Cette séparation stricte est ce qui protège les résultats d'un artefact de sur-apprentissage. Deux précautions la complètent. D'une part, le rééquilibrage des classes par SMOTE, décrit ci-dessous, est appliqué **uniquement à l'ensemble d'entraînement** : les ensembles de validation et de test restent tels quels, faute de quoi des événements synthétiques interpolés pollueraient l'estimation des performances. D'autre part, l'arrêt anticipé étant piloté par la validation, cet ensemble participe indirectement à la sélection du modèle et ne peut donc pas servir à mesurer la généralisation — d'où la nécessité du troisième ensemble, le test, qui reste totalement isolé.

Fonction de coût et arrêt anticipé

Le modèle prédit pour chaque événement i un vecteur de probabilités $\mathbf{p}_i = (p_{i1}, \ldots, p_{iK})$ avec $\sum_k p_{ik} = 1$. L'apprentissage minimise la **cross-entropy multiclasse** :

$$\mathscr{L} = -\frac{1}{N} \sum_{i=1}^{N} \sum_{k=1}^{K} y_{ik} \log(p_{ik}),$$

où $y_{ik} = 1$ si l'événement i appartient à la classe k et 0 sinon. Cette perte pénalise fortement les prédictions confiantes mais incorrectes ; sa minimisation augmente la probabilité attribuée à la vraie classe et améliore la calibration des sorties. Dans le contexte pion/proton, elle revient à apprendre les régions de l'espace des observables où les deux signatures se chevauchent partiellement.

L'entraînement est interrompu lorsque la perte de validation ne s'améliore plus pendant **50 itérations consécutives**, le modèle conservé étant celui de meilleure performance sur validation. Cette procédure sélectionne automatiquement le nombre d'arbres, évite une complexification inutile et limite le sur-apprentissage. La Figure B.1 montre l'évolution des pertes d'entraînement et de validation : les deux courbes décroissent régulièrement et restent proches, la perte de validation se stabilisant autour de ~ 0.61 sans divergence marquée — signe d'un apprentissage stable.

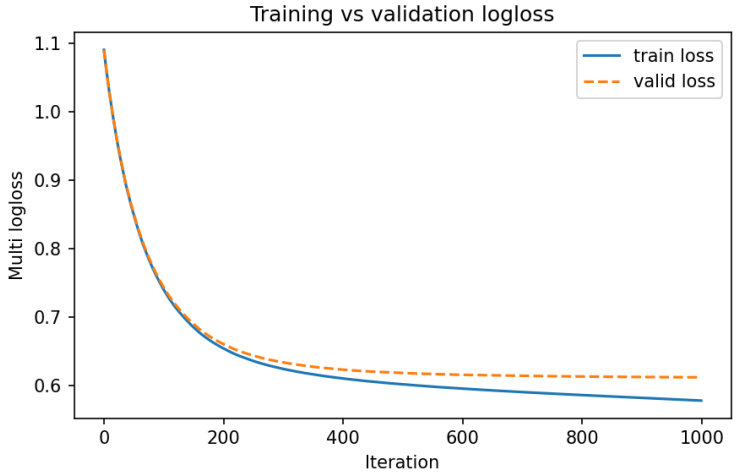


FIGURE B.1. Évolution de la fonction de coût *multi-logloss* sur les ensembles d'entraînement et de validation au cours de l'apprentissage LightGBM.

B.4 Rééquilibrage des classes par SMOTE

Les échantillons simulés étant de tailles comparables, de légères fluctuations peuvent néanmoins apparaître après nettoyage et découpage. La méthode **SMOTE** (*Synthetic Minority Over-sampling Technique*) génère des exemples supplémentaires dans les régions peu peuplées de l'espace des variables : pour une observation minoritaire $\mathbf{x}_i$, un voisin proche $\mathbf{x}_j$ de même classe est sélectionné, puis un point synthétique est construit par interpolation,

$$\mathbf{x}_{\text{new}} = \mathbf{x}_i + \lambda(\mathbf{x}_j - \mathbf{x}_i), \qquad \lambda \in [0,1],$$

ce qui renforce la densité de la classe minoritaire sans duplication d'événements existants. Le procédé améliore en principe la stabilité de l'apprentissage et le rappel des classes minoritaires, tout en réduisant le biais vers la classe majoritaire.

Les données simulées étant ici relativement équilibrées, SMOTE relève davantage de la précaution méthodologique que de la correction indispensable. Les gains mesurés étant restés limités, et la génération d'événements synthétiques risquant d'introduire des corrélations artificielles ou de modifier localement la structure statistique des données, cette stratégie n'a pas été retenue dans la chaîne

principale.

B.5 Modèle et hyperparamètres

Le classificateur repose sur `LightGBM`, méthode d'agrégation séquentielle d'arbres de décision où chaque nouvel arbre corrige les erreurs résiduelles du modèle courant. Ses performances dépendent fortement du choix des hyperparamètres, qui contrôlent conjointement la capacité d'apprentissage et la régularisation. Les valeurs retenues sont données au Tableau B.1.

TABLE B.1. Hyperparamètres retenus pour le classificateur LightGBM.

Paramètre	Valeur	Rôle
`learning_rate`	0.01	Amplitude de correction de chaque nouvel arbre ; une valeur faible améliore la généralisation.
`n_estimators`	1000	Nombre maximal d'arbres construits (borné en pratique par l'arrêt anticipé).
`num_leaves`	63	Nombre maximal de feuilles par arbre ; contrôle la finesse des séparations.
`max_depth`	-1	Profondeur non contrainte explicitement.
`min_child_samples`	30	Nombre minimal d'événements dans une feuille terminale.
`subsample`	0.8	Fraction d'événements tirée à chaque itération.
`colsample_bytree`	0.8	Fraction de variables candidates par arbre.
`reg_alpha`	0.1	Pénalisation L_1.
`reg_lambda`	0.1	Pénalisation L_2.

Ce jeu privilégie un compromis entre pouvoir de séparation, robustesse au bruit statistique, temps d'entraînement raisonnable et stabilité entre différents découpages. Une recherche automatique par grille (`GridSearchCV`) est également disponible dans le script, mais n'a été utilisée que lors de campagnes d'optimisation spécifiques.

Plusieurs axes d'optimisation restent envisageables et n'ont pas été explorés systématiquement : ajustement fin des hyperparamètres, pondération spécifique des classes ou des erreurs de classification, calibration des probabilités de sortie (*Platt scaling*, régression isotonique), entraînement conditionné par tranches d'énergie, validation croisée sur plusieurs découpages, et optimisation directe de métriques équilibrées plutôt que de la seule accuracy. L'apprentissage par intervalles d'énergie paraît particulièrement pertinent, les signatures hadroniques évoluant sensiblement entre basse et haute énergie.

B.6 Métriques d'évaluation

Les performances sont évaluées exclusivement sur l'ensemble de test. L'**accuracy** mesure la fraction d'événements correctement classés, Accuracy $= \frac{1}{N_{\text{test}}} \sum_i \mathbf{1}(\hat{y}_i = y_i)$, où y_i est la vraie classe et $\hat{y}_i$ la classe prédite. La **matrice de confusion**, $C_{ij} = \#(\text{vraie classe} = i,\ \text{prédite} = j)$, normalisée ligne par ligne pour donner des probabilités conditionnelles, identifie précisément les confusions π^- / p, les confusions avec les K^0 et les asymétries entre classes. L'**AUC ROC one-vs-rest** caractérise la capacité de séparation de chaque classe à seuil variable, et les **histogrammes des probabilités prédites** renseignent sur le degré de confiance des décisions. L'accuracy équilibrée, moyenne non pondérée des rappels par classe, complète l'accuracy globale en la rendant insensible aux effectifs relatifs — c'est la métrique de référence retenue au chapitre 3.

Annexe C

Classification hadronique par réseaux sur amas

Cette annexe détaille les deux réseaux lisant les amas calorimétriques dans l'étude pion/proton de la section 3.6. Le premier, appelé *CNN* dans le code et les figures, est un encodeur d'ensemble de type PointNet sans connectivité explicite. Le second est un réseau de neurones graphique (GNN) qui propage l'information entre amas voisins. Cette distinction est essentielle : seul le second exploite des arêtes explicites. Leur comparaison ne mesure toutefois pas l'effet des seules arêtes, car leurs encodeurs diffèrent également.

C.1 Données et prétraitement des nœuds

Les résultats comparatifs du chapitre portent sur la séparation binaire pion/proton. Les fichiers d'entrée sont des tableaux `CSV` où chaque ligne représente initialement un hit avec ses coordonnées spatiales, son temps et le seuil semi-digital franchi. Avant l'apprentissage, les pads quatre-connexes d'une même couche sont regroupés en amas. Chaque amas devient un objet d'entrée pour les deux réseaux.

Le lot continu de 2×10^5 événements par espèce fournit l'échantillon d'apprentissage. Les événements exportés sont découpés de façon stratifiée en 70 % pour l'ajustement, 10 % pour la validation interne et 20 % pour le test interne. Le découpage est effectué au niveau des **événements**, jamais au niveau des hits ou des amas. Une seconde production, à énergies fixes, est réservée à l'évaluation externe utilisée dans la comparaison du chapitre. Le temps reçoit un bruit gaussien de largeur 0,1 ns avant la construction des amas ; il n'est pas discrétisé.

Chaque amas est décrit par huit composantes : son centroïde spatial (x, y, z), le temps de son premier hit, les fractions de pads aux trois seuils et $\log(1 + N_{\text{pads}})$. Les coordonnées sont transformées par un `RobustScaler` et le temps par un `QuantileTransformer`, tous deux ajustés *uniquement* sur l'échantillon d'entraînement. La taille et les fractions de seuil ne sont pas standardisées.

C.2 Construction du graphe

Pour le GNN, chaque événement est converti en graphe reliant les amas selon un critère de proximité spatiale et de causalité longitudinale. L'orientation effective du graphe transmis au réseau fait l'objet d'une réserve précisée plus bas. Le CNN de type PointNet ne construit aucune arête.

Pour chaque nœud i, on retient ses $k = 8$ plus proches voisins au sens de la distance sur coordonnées normalisées,

$$d_{ij}^2 = (x'_i - x'_j)^2 + (y'_i - y'_j)^2 + (z'_i - z'_j)^2,$$

parmi les seuls amas situés en amont du développement : la **contrainte causale** $z_j < z_i$ intervient dans la sélection des voisins. Une **fenêtre temporelle** $|t_i - t_j| \leq \Delta t$, avec $\Delta t = 2.0$ ns, élimine les connexions trop éloignées en temps. Des boucles propres sont ajoutées à tous les nœuds.

Réserve sur l'orientation effective. La description ci-dessus est celle du critère de sélection ; elle n'est pas celle du graphe finalement transmis au réseau. Les exécutions ayant produit les résultats cités activent conjointement la contrainte causale et une symétrisation du graphe, appliquée après la sélection des voisins. Or cette symétrisation rétablit chaque arête dans les deux sens. Sur un événement de contrôle de soixante nœuds, le graphe causal seul ne contient aucune arête remontant en profondeur, tandis que le graphe causal *et* symétrisé en contient exactement la moitié — la contrainte $z_j < z_i$ est donc intégralement annulée.

L'effet n'est pas pour autant nul : la contrainte modifie l'ensemble des paires *sélectionnées* par le k-NN, de sorte que le graphe obtenu diffère de celui qu'aurait produit une construction non causale (888 arêtes contre 616 sur le même événement de contrôle). Ce qui est perdu est l'orientation, non la sélection. Les performances rapportées pour le GNN doivent donc se lire comme celles d'un graphe de voisinage local non orienté : l'apport propre d'une orientation longitudinale reste à mesurer, et demanderait de désactiver la symétrisation.

C.3 Architecture et entraînement

GNN. Le vecteur d'entrée est projeté dans un espace latent de dimension $d_{\text{hidden}} = 128$ par une couche linéaire suivie d'une activation `GELU`. Une couche `GATConv` à quatre têtes d'attention est suivie de deux couches `GraphConv`. Les deux premières convolutions sont associées à une `GraphNorm` ; les activations sont des `GELU` et du `Dropout` est appliqué entre les couches. Une connexion résiduelle relie la sortie de la dernière `GraphConv` à celle de la précédente. L'implémentation utilisée ici ne comporte pas de `TAGConv`.

CNN de type PointNet. Deux convolutions unidimensionnelles de noyau 1 projettent successivement les huit variables de chaque amas dans le même espace latent de dimension 128. Comme le noyau vaut 1, chaque amas est encodé indépendamment des autres. La seule agrégation entre amas intervient ensuite dans le pooling global. Ce modèle est donc plus justement décrit comme *PointNet-like* que comme un CNN spatial ; cette appellation ne signifie pas qu'il reproduit toutes les composantes de PointNet.

Les embeddings de nœuds sont convertis en une représentation unique de l'événement par concaténation de deux agrégations,

$$\mathbf{g} = [\text{MaxPool}(\mathbf{h}),\ \text{MeanPool}(\mathbf{h})]\,,$$

le *max pooling* captant les signatures locales dominantes et le *mean pooling* l'activité moyenne. Cette même agrégation est utilisée par les deux architectures. Un perceptron final avec activation `GELU` et `Dropout`(0.3) produit deux logits, correspondant au pion et au proton.

L'apprentissage minimise une entropie croisée binaire à deux logits, pondérée pour équilibrer les deux classes,

$$\mathscr{L} = -\frac{1}{N}\sum_{i=1}^{N} \log p_\theta(y_i \mid G_i),$$

où G_i désigne l'ensemble ou le graphe d'amas de l'événement i, selon l'architecture, et y_i sa classe vraie. L'optimisation utilise `AdamW` avec un taux initial $\mathrm{lr} = 10^{-3}$ et une décroissance des poids $\lambda_{\mathrm{wd}} = 10^{-4}$. Le workflow comparatif utilise des mini-lots de 64 pour le CNN et de 32 pour le GNN, au maximum 40 et 30 époques respectivement. Un scheduler `ReduceLROnPlateau` réduit le taux lorsque la perte de validation stagne. Le meilleur checkpoint est celui qui maximise l'**AUC de validation** ; l'arrêt anticipé emploie une patience de 8 époques pour le CNN et de 6 pour le GNN.

C.4 Résultats, limites et perspectives

Les deux modèles sont évalués par accuracy, accuracy équilibrée, AUC et matrice de confusion sur leur test interne. Pour la comparaison avec les modèles tabulaires, le meilleur checkpoint est ensuite appliqué à la production externe à énergies fixes ; le score utilisé est la probabilité pion. L'étude reste exploratoire, notamment parce que les réseaux sur amas ont été entraînés sur beaucoup moins d'événements que les modèles tabulaires.

Trois axes d'amélioration se dégagent. Le **volume statistique** est le levier le plus direct : la performance d'un modèle profond dépend fortement de la taille de l'échantillon. La **richesse des variables d'entrée** vient ensuite : les modèles exploitent la position, le temps, la taille et la composition en seuils des amas, mais pas les descripteurs globaux issus de `ShowerAnalyzer`. La **topologie du graphe**, enfin, repose ici sur un unique schéma k-NN à $k = 8$; des graphes dynamiques recalculés à chaque couche, un rayon fixe en distance physique, une connectivité hiérarchique entre couches ou des arêtes pondérées par distance constituent autant d'alternatives non explorées.

Trois références récentes fournissent un cadre concret pour cette comparaison. Dans une étude de DHCAL binaire, DeepSets obtient une reconstruction d'énergie compétitive avec une complexité nettement inférieure à celle d'un GAT, ce qui en fait une référence simple à tester avant d'augmenter la sophistication du graphe [32]. Pour l'AHCAL, les modèles DGCNN et GravNet exploitent mieux que PointNet les corrélations locales, notamment lorsque le temps est ajouté aux hits [29]. Enfin, la reconstruction de pions dans le prototype CMS HGCAL montre qu'un réseau à réduction dynamique, fondé sur EdgeConv et un regroupement hiérarchique des nœuds, peut apprendre une correction événementielle validée sur données de faisceau [34].

Une reprise devrait donc confronter, sur des partitions événementielles strictement identiques, au minimum une agrégation de type DeepSets, le graphe statique actuel et un graphe dynamique. Pour la reconstruction d'énergie, le premier objectif à tester serait un facteur correctif appliqué à l'estimateur semi-digital, plutôt qu'une prédiction entièrement indépendante de celui-ci. Chaque entraînement devrait être répété avec plusieurs graines ; le coût mémoire, le temps d'inférence et l'effet du nombre de nœuds devraient être enregistrés, et une ablation du temps réalisée à plusieurs résolutions. Les performances externes ne doivent pas être reprises comme références numériques, car ces travaux utilisent d'autres détecteurs, d'autres modes de lecture et d'autres objectifs d'apprentissage.

C.5 Tableau récapitulatif

TABLE C.1. Résumé des deux réseaux sur amas utilisés pour le PID pion/proton.

Élément	**Description**
Objectif	Classification supervisée binaire des pions et des protons.
Type de données	Événements SDHCAL représentés comme ensembles ou graphes d'amas.
Nœuds	Amas de pads quatre-connexes dans une même couche.
Features des nœuds	Coordonnées, temps transformé, fractions aux trois seuils et logarithme de la taille.
Dimension d'entrée	8 variables par amas.
Construction des arêtes	Voisinage k-NN avec $k = 8$, sélection sous contrainte de profondeur et fenêtre temporelle $\Delta t = 2.0$, graphe symétrisé.
Prétraitement	`RobustScaler` pour l'espace, `QuantileTransformer` pour le temps.
Architecture	CNN/PointNet-like : deux convolutions 1×1 sans arêtes. GNN : projection linéaire + `GATConv` + deux `GraphConv`.
Pooling global	Concaténation `global max pool` + `global mean pool`.
Classifieur final	MLP avec `Dropout`(0.3) et sortie à deux classes.
Fonction de coût	Entropie croisée pondérée, à deux logits.
Optimiseur	`AdamW`, taux initial 10^{-3}, weight decay 10^{-4}.
Régularisation	Scheduler `ReduceLROnPlateau` + early stopping sur l'AUC (patience 8 pour le CNN, 6 pour le GNN).
Découpage des données	70 % entraînement, 10 % validation, 20 % test.
Métriques	AUC, accuracy équilibrée, accuracy, matrice de confusion et rejet du proton.
Forces	Comparaison contrôlée entre une agrégation sans arêtes et un graphe de voisinage explicite.
Limites	Statistique d'entraînement inférieure à celle des modèles tabulaires ; graphe symétrisé malgré la sélection causale.
Perspective	PID avancé, correction graphique de l'estimateur d'énergie, Particle Flow, modèles spatio-temporels.

Annexe D

Régression de l'énergie avec LightGBM

Cette annexe décrit la mise en œuvre de la régression supervisée utilisée au chapitre 4 pour estimer l'énergie incidente à partir des descripteurs de gerbe. Deux modèles indépendants sont entraînés, l'un pour les pions π^-, l'autre pour les protons p, afin d'adapter la régression aux différences de développement des cascades. Le protocole général — découpage en trois ensembles, arrêt anticipé, absence de fuite d'information — est identique à celui du classificateur PID et détaillé en Annexe B.3 ; seules les spécificités de la régression sont reprises ici.

D.1 Données et variables d'entrée

Les données proviennent de fichiers `ROOT` générés par la simulation du SDHCAL puis enrichis par les descripteurs de l'Annexe A. Chaque événement contient l'énergie vraie de la particule primaire, $E_{\text{true}} =$ `primaryEnergy`, ainsi que l'ensemble des observables géométriques, topologiques, semi-digitales et temporelles. Les variables retenues en entrée sont regroupées au Tableau D.1.

Table D.1. Variables d'entrée de la régression d'énergie et interprétation physique.

Catégorie	Variables	Interprétation
Morphologie	`Radius`, `meanRadius`, `Zrms`	extension spatiale de la gerbe
Début / profondeur	`Begin`, `Xmax`, `Zbary`	position longitudinale
Densité	`Density`, `nhitDensity`	compacité locale
Seuils	`N3`, `sumThrTotal`, `ratioThr23`	contenu énergétique semi-digital
Clusters	`nCluster`, `MaxClustSize`	structure interne
Temps	`tMean`, `tMax`	développement temporel
Forme globale	`eccentricity3D`, `lambda1`, `lambda2`	anisotropie de la gerbe

Le choix de ces variables repose sur leur sens physique vis-à-vis du dépôt d'énergie : certaines traduisent la quantité totale d'interactions visibles, d'autres permettent de corriger indirectement les fluctuations de développement de gerbe. L'approche multivariable exploite simultanément ces corrélations non linéaires, ce qu'une calibration analytique simple ne peut reproduire.

Le prétraitement suit la même logique qu'en Annexe B.2 : les événements contenant des valeurs non définies (`NaN`) ou infinies dans au moins une variable sont supprimés, ce qui évite les erreurs d'apprentissage, les divisions non physiques et les biais liés aux événements mal reconstruits. Le découpage sépare d'abord 80 % des événements pour l'apprentissage et 20 % pour le test, une fraction de validation étant ensuite extraite de l'ensemble d'apprentissage. L'ensemble de test n'intervient jamais dans l'optimisation des hyperparamètres.

D.2 Apprentissage en espace logarithmique

La reconstruction directe de l'énergie sur une large plage dynamique pose plusieurs difficultés : dispersion croissante avec l'énergie, asymétrie des distributions résiduelles, et poids relatif plus fort des erreurs aux basses énergies. La cible de régression n'est donc pas E mais sa transformée logarithmique,

$$y = \log(E_{\text{true}}),$$

le modèle apprenant $\hat{y} = f(\mathbf{x})$, l'énergie reconstruite étant obtenue par transformation inverse $E_{\text{reco}} = \exp(\hat{y})$.

Ce choix réduit la dynamique entre faibles et hautes énergies, homogénéise les erreurs relatives, stabilise l'apprentissage et diminue l'influence des événements extrêmes. Son intérêt physique est direct : une erreur absolue constante sur $\log E$ correspond approximativement à une erreur relative constante sur E, c'est-à-dire au comportement attendu d'une résolution calorimétrique. L'entraînement minimise une perte quadratique en espace logarithmique, complétée par une métrique personnalisée évaluant la résolution relative après retour dans l'espace physique, ce qui oriente l'optimisation vers une performance physiquement pertinente et non seulement vers une précision numérique.

D.3 Modèle et hyperparamètres

Le régresseur repose sur un `LGBMRegressor`, adapté à la reconstruction calorimétrique par sa capacité à modéliser des dépendances non linéaires complexes, à exploiter les corrélations entre descripteurs, à gérer des variables hétérogènes avec peu de prétraitement et à fournir des importances de variables. La configuration retenue figure au Tableau D.2.

TABLE D.2. Hyperparamètres retenus pour la régression d'énergie.

Paramètre	Valeur
`learning_rate`	0.05
`n_estimators`	2000
`num_leaves`	127
`max_depth`	illimité (−1)
`subsample`	0.8
`colsample_bytree`	0.8
`min_child_samples`	20
`reg_lambda`	0.1

Ces valeurs assurent une bonne capacité d'apprentissage tout en limitant le sur-ajustement. Une recherche automatique par grille (`GridSearchCV`) sur le nombre de feuilles, la profondeur, le taux d'apprentissage et le nombre d'arbres est disponible mais n'a été utilisée que lors de campagnes d'optimisation spécifiques. Comme pour le classificateur, l'ensemble de validation sert à surveiller la convergence et à déclencher l'arrêt anticipé, deux métriques étant suivies : la perte quadratique (`l2`) et la métrique de résolution relative. La graine aléatoire est fixée pour garantir la reproductibilité.

D.4 Métriques d'évaluation

Les performances sont évaluées sur l'ensemble de test. La **racine de l'erreur quadratique moyenne** mesure l'écart absolu typique et pénalise fortement les grandes erreurs :

$$\mathrm{RMSE} = \sqrt{\frac{1}{N}\sum_{i=1}^{N}\left(E_i^{\mathrm{reco}} - E_i^{\mathrm{true}}\right)^2}.$$

L'**erreur absolue moyenne** $\mathrm{MAE} = \frac{1}{N}\sum_i |E_i^{\mathrm{reco}} - E_i^{\mathrm{true}}|$ est plus robuste aux valeurs extrêmes, et le **coefficient de détermination** $R^2 = 1 - \sum(y_i - \hat{y}_i)^2 / \sum(y_i - \bar{y})^2$ quantifie la fraction de variance expliquée.

La quantité de base est le résidu relatif $r_i = (E_i^{\mathrm{reco}} - E_i^{\mathrm{true}})/E_i^{\mathrm{true}}$. Le biais et la résolution doivent être distingués :

$$\delta = \langle r \rangle, \qquad \frac{\sigma(E)}{E} = \sqrt{\frac{1}{N}\sum_i (r_i - \langle r \rangle)^2}.$$

La chaîne utilisée pendant l'étude enregistrait également la RMS autour de zéro, $\sqrt{\langle r^2 \rangle}$, qui combine ces deux contributions selon $\langle r^2 \rangle = \delta^2 + \sigma_r^2$. Les courbes de largeur fondées sur le cœur tronqué des distributions sont donc interprétées comme des indicateurs comparatifs, tandis que le biais est étudié séparément à partir de la moyenne de r.

Ces métriques globales sont complétées par des études différentielles en fonction de l'énergie incidente — linéarité, biais relatif et résolution par intervalle — qui constituent les résultats reportés au chapitre 4. Le pipeline produit automatiquement les courbes d'apprentissage, le profil de linéarité, la courbe de résolution, la déviation relative et l'importance des variables, et sauvegarde les modèles entraînés ainsi que les paramètres et performances de chaque campagne, ce qui assure la traçabilité des résultats d'une exécution à l'autre.

Annexe E

Reconstruction d'énergie par méthode paramétrique χ^2

Cette annexe détaille la mise en œuvre de la méthode paramétrique du chapitre 4 : sélection des événements, procédure numérique de minimisation et calcul de l'énergie reconstruite. Le principe et la formulation étant exposés au corps du mémoire (section 4.3), seuls les éléments d'implémentation sont repris ici.

E.1 Sélection des événements et prétraitement

Les fichiers d'entrée contiennent des échantillons simulés de pions négatifs et de protons dans la plage $1 \leq E_{\text{true}} \leq 130$ GeV ; seuls les événements de cet intervalle sont conservés pour la minimisation.

Une attention particulière est portée aux gerbes présentant une **fuite longitudinale** importante : les événements possédant au moins un hit dans la dernière couche instrumentée sont rejetés. Ce critère supprime les interactions insuffisamment contenues, pour lesquelles une partie de l'énergie quitte le calorimètre et biaiserait la calibration. C'est un point important pour l'interprétation des résultats : la calibration est donc établie sur des gerbes bien contenues, alors que l'échantillon d'évaluation, lui, ne l'est pas nécessairement aux plus hautes énergies.

Pour chaque événement retenu, seules quatre grandeurs sont nécessaires — N_1, N_2, N_3 et l'énergie primaire simulée E_{true} — le nombre total de hits étant reconstruit par $N_{\text{hit}} = N_1 + N_2 + N_3$. Ce prétraitement évite que les événements mal contenus dégradent l'ajustement, garantit un domaine énergétique homogène et limite la calibration aux observables strictement nécessaires : la méthode reste ainsi volontairement simple, robuste et directement interprétable.

E.2 Procédure numérique avec `TMinuit`

L'optimisation des neuf paramètres $(a_0, a_1, a_2, b_0, b_1, b_2, c_0, c_1, c_2)$ est réalisée avec la classe `TMinuit` de `ROOT` [24], historiquement très utilisée en physique des hautes énergies pour les ajustements multi-paramétriques non linéaires. Les paramètres sont initialisés à des valeurs de départ différentes selon l'espèce considérée, ce qui améliore la convergence en plaçant l'algorithme dans une région réaliste de l'espace des paramètres ; chaque coefficient est défini avec une valeur initiale, un pas numérique d'exploration et, le cas échéant, des bornes.

La minimisation utilise l'algorithme `MIGRAD`, méthode quasi-newtonienne exploitant les gradients locaux de la fonction objectif S. À convergence, `TMinuit` fournit les valeurs optimales des paramètres, leurs incertitudes estimées, la valeur minimale $S_{\min}$ et un indicateur d'état de la matrice de covariance. Le code récupère également le statut `istat`, interprété comme suit : 0 pour une matrice de covariance

indisponible, 1 pour une approximation grossière, 2 pour une matrice définie positive et 3 pour une estimation fiable et précise — une valeur élevée signalant donc une convergence robuste.

Ce choix d'outil est adapté au problème : le nombre de paramètres reste modéré, la fonction objectif est continue, les résultats sont physiquement interprétables et la méthode reste rapide sur de grands échantillons. Les corrélations entre coefficients ajustés, accessibles via la matrice de covariance, méritent une attention particulière : les neuf paramètres n'étant pas indépendants, l'interprétation individuelle de chacun reste limitée.

E.3 Calcul de l'énergie reconstruite

Une fois les paramètres optimisés, la reconstruction s'applique événement par événement. Pour chaque interaction, le nombre total de hits N_{hit} est calculé, puis les coefficients dépendant de la multiplicité,

$$\alpha = a_0 + a_1 N_{\text{hit}} + a_2 N_{\text{hit}}^2, \qquad \beta = b_0 + b_1 N_{\text{hit}} + b_2 N_{\text{hit}}^2, \qquad \gamma = c_0 + c_1 N_{\text{hit}} + c_2 N_{\text{hit}}^2,$$

avant d'obtenir $E_{\text{reco}} = \alpha N_1 + \beta N_2 + \gamma N_3$.

Cette écriture attribue un poids distinct aux hits selon leur seuil — dépôts les plus faibles au seuil 1, zones plus denses au seuil 2, cœur énergétique de la gerbe au seuil 3 — la dépendance en N_{hit} ajustant automatiquement ces pondérations lorsque la taille de la gerbe croît avec l'énergie. La méthode est très rapide en inférence : après calibration, aucune minimisation supplémentaire n'est requise, la reconstruction se réduisant à quelques évaluations polynomiales suivies d'une combinaison linéaire.

E.4 Chaîne PID + reconstruction paramétrique

Les figures E.1 et E.2 complètent la section 5.3 : elles présentent la linéarité et la résolution obtenues sur échantillon mixte lorsque l'identification par PID est suivie de la reconstruction paramétrique. Les valeurs commentées dans le corps du mémoire en sont extraites.

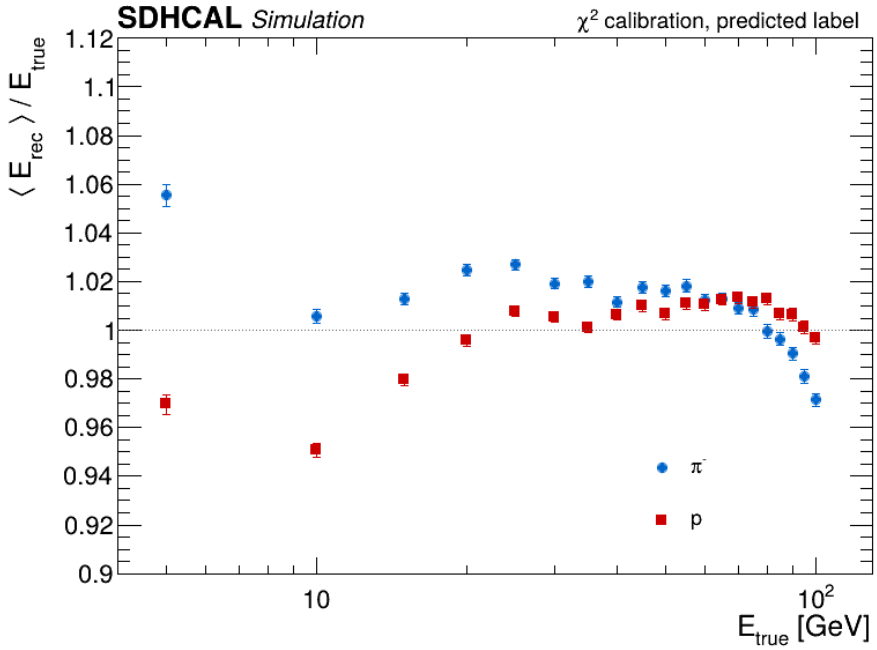


FIGURE E.1. Linéarité et biais relatif de la chaîne PID + méthode paramétrique sur échantillon mixte.

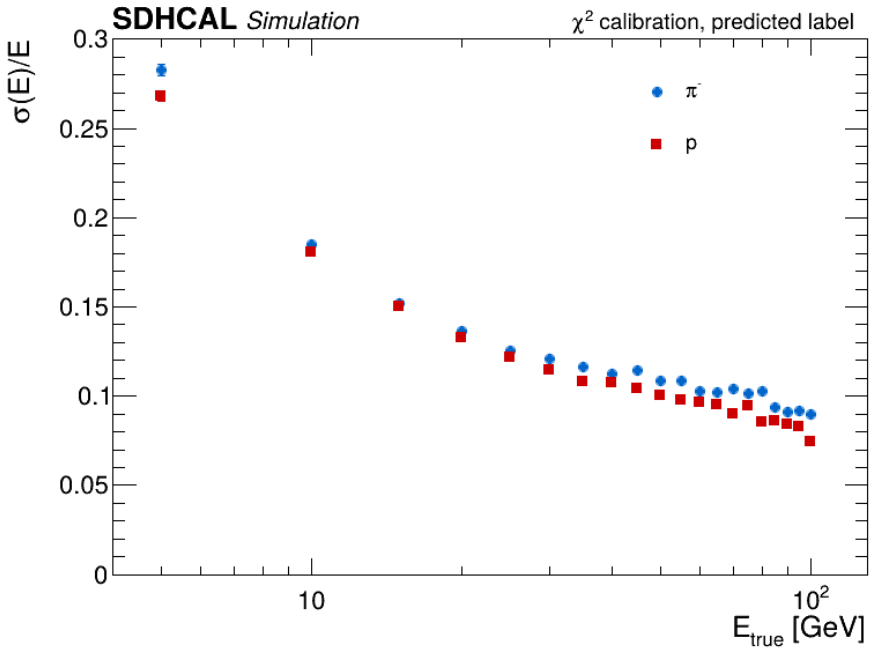


FIGURE E.2. Résolution relative de la chaîne PID + méthode paramétrique sur échantillon mixte.

E.5 Forces et limites de la méthode

Cette approche est rapide, robuste, interprétable et peu coûteuse en calcul : une modélisation relativement simple suffit à obtenir des performances crédibles sur une large gamme énergétique, ce qui confirme la pertinence intrinsèque du concept semi-digital pour la calorimétrie hadronique. Elle reste cependant limitée face à la richesse réelle des données disponibles — géométrie fine des gerbes, densités locales, corrélations spatiales, signatures temporelles, fluctuations événement par événement — dont elle n'exploite aucune. C'est pourquoi elle constitue la référence de comparaison des approches supervisées plutôt qu'une fin en soi.

E.6 Tableau récapitulatif

TABLE E.1. Résumé de la méthode paramétrique de reconstruction d'énergie par ajustement χ^2.

Élément	**Description**
Type de méthode	Calibration analytique semi-digitale fondée sur les compteurs de hits aux trois seuils.
Variables principales	N_1, N_2, N_3, avec $N_{\text{hit}} = N_1 + N_2 + N_3$.
Formule de reconstruction	$E_{\text{reco}} = \alpha N_1 + \beta N_2 + \gamma N_3$.
Dépendance des coefficients	α, β, γ paramétrés par des polynômes quadratiques en N_{hit}.
Nombre de paramètres	9 paramètres libres : $(a_0, a_1, a_2, b_0, b_1, b_2, c_0, c_1, c_2)$.
Optimisation	Minimisation numérique avec `TMinuit` via l'algorithme `MIGRAD`.
Échantillons utilisés	Événements simulés de π^- et protons entre 1 et 130 GeV.
Prétraitement	Rejet des événements présentant des hits dans la dernière couche instrumentée (fuite longitudinale).
Observables de sortie	Linéarité, biais relatif, résolution $\sigma(E)/E$, distributions reconstruites.
Forces	Rapide, robuste, interprétable, faible coût de calcul.
Limites	N'utilise pas la topologie détaillée des gerbes ni les corrélations complexes.
Rôle dans ce mémoire	Méthode baseline de référence comparée aux approches LightGBM.

Annexe F

Compléments sur le détecteur et l'identification hadronique

Cette annexe regroupe des éléments écartés du corps du mémoire : les caractéristiques de l'électronique de lecture du prototype, le tableau comparatif des signatures calorimétriques attendues pour les trois espèces étudiées, et les corrélations entre variables d'entrée des modèles d'apprentissage.

F.1 Électronique de lecture et acquisition

L'électronique de lecture est intégrée au plus près des chambres grâce aux ASICs HARDROC [35], conçus pour les détecteurs gazeux hautement segmentés. Chaque ASIC gère plusieurs dizaines de canaux et dispose d'une mémoire locale permettant de stocker les informations avant la lecture.

Cette architecture embarquée réduit le câblage externe et rend possible l'instrumentation d'un très grand nombre de canaux. Le système peut fonctionner en mode déclenché ou en mode sans déclenchement, selon les conditions expérimentales.

Une stratégie de *power pulsing* peut également être utilisée afin de réduire la consommation électrique pendant les périodes sans faisceau, un point important pour les futurs collisionneurs linéaires.

F.2 Signatures calorimétriques attendues

Le Tableau F.1 détaille, espèce par espèce, les signatures moyennes attendues dans le SDHCAL à partir des différences physiques discutées à la section 3.1. Ces tendances sont statistiques : les fortes fluctuations des gerbes hadroniques font que les distributions correspondantes se recouvrent largement événement par événement, ce qui est précisément la difficulté que doit surmonter le classificateur.

TABLE F.1. Comparaison qualitative des signatures calorimétriques moyennes attendues dans le SDHCAL.

Caractéristique	**Pion π^-**	**Proton p**	**Kaon neutre K^0**
Signal d'ionisation avant gerbe	Oui	Oui	Non
Fraction électromagnétique moyenne	Élevée	Plus faible	Variable
Profondeur de première interaction	Plutôt précoce	Plutôt précoce	Plus variable
Développement longitudinal	Relativement précoce	Plus profond	Variable
Extension transverse	Modérée	Plus large	Variable
Fluctuations événement/événement	Importantes	Importantes	Très importantes

F.3 Corrélations entre variables d'entrée

La Figure F.1 présente la matrice de corrélation de Pearson calculée sur l'ensemble des variables d'entrée des modèles d'apprentissage, tous événements confondus. Plusieurs groupes cohérents s'y dessinent, qui correspondent aux familles de descripteurs définies en Annexe A.

Les variables d'**activité globale et de compacité** — `Thr1`, `Thr2`, `Thr3`, `NClusters`, `Nmax`, `AvgClustSize`, `MaxClustSize` et `Density` — présentent des corrélations modérées à fortes, ce qui est attendu puisqu'elles mesurent toutes, sous des formes différentes, l'intensité locale ou globale de la gerbe. Les descripteurs **longitudinaux** (`Begin`, `Zbary`, `Zrms`, `Xmax`, `z0_fit`) sont positivement corrélés entre eux, décrivant conjointement la position de départ et l'évolution de la cascade en profondeur. Les variables de **forme géométrique** (λ_1, λ_2, `eccentricity3D`) sont liées par leur rôle commun dans la description de l'anisotropie spatiale. Les variables **temporelles** (`tMin`, `tMean`, `tSpread`), enfin, ne sont que faiblement à modérément corrélées entre elles, mais montrent certains liens avec les variables longitudinales — ce qui suggère une connexion entre chronologie du signal et profondeur d'initiation de la gerbe.

Cette organisation indique que plusieurs variables transportent une information partiellement redondante. Une sélection plus compacte des observables — en conservant un représentant robuste par groupe corrélé, par exemple `Thr3` ou `Nmax`, `Density` ou `NClusters` — pourrait donc être envisagée sans perte majeure de performance, avec le bénéfice d'une dimension réduite, d'un entraînement plus rapide et d'une interprétation physique plus lisible.

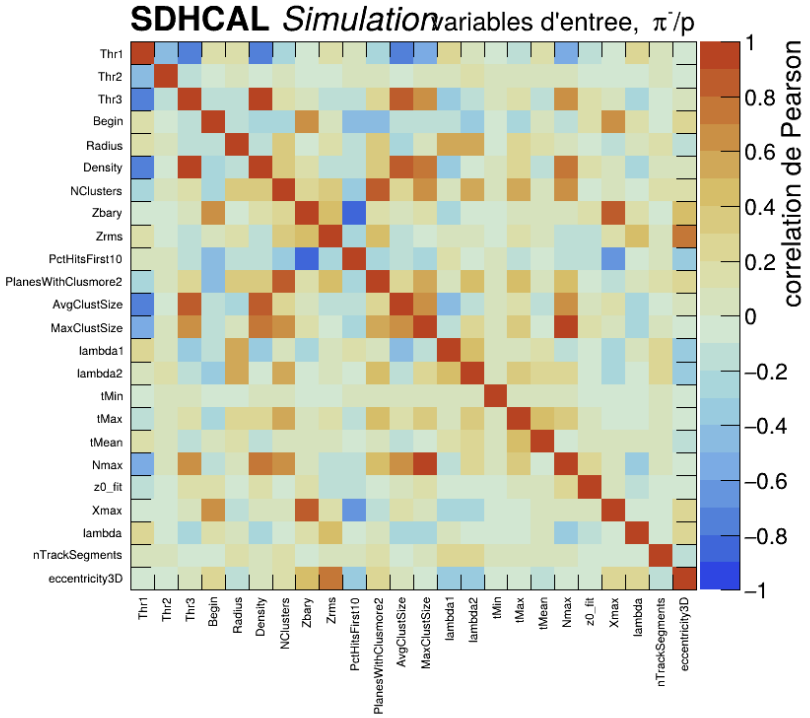


FIGURE F.1. Matrice de corrélation de Pearson des vingt-quatre variables d'entrée effectivement utilisées par la classification. Deux variables présentes dans une version antérieure de cette figure, `ratioThr23` et `tSpread`, en ont été retirées : étant des transformations monotones d'une seule colonne, elles n'apportent rien à un modèle fondé sur des arbres.

Bibliographie

[1] David J. GRIFFITHS. *Introduction to Elementary Particles*. 2nd. Wiley-VCH, 2008.

[2] F. HALZEN et A. D. MARTIN. *Quarks and Leptons : An Introductory Course in Modern Particle Physics*. Wiley, 1984.

[3] M. E. PESKIN et D. V. SCHROEDER. *An Introduction to Quantum Field Theory*. Westview Press, 1995.

[4] S. Navas et AL. « Review of Particle Physics ». In : *Physical Review D* 110 (2024), p. 030001. DOI : 10.1103/PhysRevD.110.030001.

[5] M. A. THOMSON. « Particle Flow Calorimetry and the PandoraPFA Algorithm ». In : *Nuclear Instruments and Methods in Physics Research A* 611 (2009), p. 25-40. DOI : 10.1016/j.nima.2009.09.009.

[6] A. Hoecker et AL. « TMVA - Toolkit for Multivariate Data Analysis ». In : *PoS ACAT* 040 (2007). arXiv : physics/0703039.

[7] H. QU et L. GOUSKOS. « ParticleNet : Jet Tagging via Particle Clouds ». In : *Physical Review D* 101 (2020), p. 056019. DOI : 10.1103/PhysRevD.101.056019.

[8] M. Abdughani et AL. « Probing stop pair production at the LHC with graph neural networks ». In : *Journal of High Energy Physics* 08 (2019), p. 055. DOI : 10.1007/JHEP08(2019)055.

[9] CALICE COLLABORATION. « First results of the CALICE SDHCAL technological prototype ». In : *Journal of Instrumentation* 11.04 (2016), P04001. DOI : 10.1088/1748-0221/11/04/P04001. arXiv : 1602.02276 [physics.ins-det].

[10] Hans BICHSEL. « Straggling in thin silicon detectors ». In : *Reviews of Modern Physics* 60 (1988), p. 663-699. DOI : 10.1103/RevModPhys.60.663.

[11] Glenn F. KNOLL. *Radiation Detection and Measurement*. Wiley, 2010.

[12] Richard WIGMANS. *Calorimetry : Energy Measurement in Particle Physics*. Oxford University Press, 2000.

[13] William R. LEO. *Techniques for Nuclear and Particle Physics Experiments*. Springer, 1994.

[14] C. W. FABJAN et F. GIANOTTI. « Calorimetry for particle physics ». In : *Reviews of Modern Physics* 75 (2003), p. 1243-1286. DOI : 10.1103/RevModPhys.75.1243.

[15] Walter HEITLER. *The Quantum Theory of Radiation*. 3rd. Oxford University Press, 1954.

[16] Bruno ROSSI. *High-Energy Particles*. Prentice Hall, 1952.

[17] CALICE COLLABORATION. « Construction and Commissioning of a Technological Prototype of a Semi-Digital Hadronic Calorimeter ». In : *Journal of Instrumentation* 10 (2015), P10039. DOI : 10.1088/1748-0221/10/10/P10039.

[18] ILC COLLABORATION. *International Linear Collider Technical Design Report*. 2013. arXiv : 1306.6327.

[19] J. S. MARSHALL et M. A. THOMSON. « The Pandora Software Development Kit for Pattern Recognition ». In : *European Physical Journal C* 75 (2015), p. 439. DOI : 10.1140/epjc/s10052-015-3659-3.

[20] M. Bedjidian et AL. « Performance of Glass Resistive Plate Chambers for a High Granularity Semi-Digital Hadron Calorimeter ». In : *Journal of Instrumentation* 6 (2011), P02001. DOI : 10.1088/1748-0221/6/02/P02001.

[21] CALICE COLLABORATION. « Description and stability of a RPC-based calorimeter in electromagnetic and hadronic shower environments ». In : *Journal of Instrumentation* 17.07 (2022), P07034. DOI : 10.1088/1748-0221/17/07/P07034.

[22] S. Agostinelli et AL. « GEANT4 : A Simulation Toolkit ». In : *Nuclear Instruments and Methods A* 506 (2003), p. 250-303. DOI : 10.1016/S0168-9002(03)01368-8.

[23] J. Allison et AL. « Recent Developments in Geant4 ». In : *Nuclear Instruments and Methods A* 835 (2016), p. 186-225. DOI : 10.1016/j.nima.2016.06.125.

[24] R. BRUN et F. RADEMAKERS. « ROOT : An Object Oriented Data Analysis Framework ». In : *Nuclear Instruments and Methods A* 389 (1997), p. 81-86. DOI : 10.1016/S0168-9002(97)00048-X.

[25] D. E. RUMELHART, G. E. HINTON et R. J. WILLIAMS. « Learning representations by back-propagating errors ». In : *Nature* 323 (1986), p. 533-536. DOI : 10.1038/323533a0.

[26] Ian GOODFELLOW, Yoshua BENGIO et Aaron COURVILLE. *Deep Learning*. MIT Press, 2016.

[27] T. HASTIE, R. TIBSHIRANI et J. FRIEDMAN. *The Elements of Statistical Learning*. Springer, 2009.

[28] G. Ke et AL. « LightGBM : A Highly Efficient Gradient Boosting Decision Tree ». In : *NeurIPS*. 2017.

[29] CALICE COLLABORATION. « Shower Separation in Five Dimensions for Highly Granular Calorimeters Using Machine Learning ». In : *arXiv preprint* (2024). arXiv : 2407.00178 [physics.ins-det].

[30] F. Scarselli et AL. « The Graph Neural Network Model ». In : *IEEE Transactions on Neural Networks* 20 (2009), p. 61-80. DOI : 10.1109/TNN.2008.2005605.

[31] J. Shlomi et AL. « Graph Neural Networks in Particle Physics ». In : *Machine Learning : Science and Technology* 2 (2021), p. 021001. DOI : 10.1088/2632-2153/abbf9a.

[32] M. BORYSOVA et al. « Exploring DHCAL design and performance with Graph Neural Networks ». In : *arXiv preprint* (2025). arXiv : 2501.00128 [hep-ex].

[33] N. AKCHURIN et al. « On the differences between high-energy proton and pion showers and their signals in a non-compensating calorimeter ». In : *Nucl. Instrum. Meth. A* 408 (1998), p. 380-396.

[34] M. Aamir et AL. « Using graph neural networks to reconstruct charged pion showers in the CMS High Granularity Calorimeter ». In : *Journal of Instrumentation* 19.11 (2024), P11025. DOI : 10.1088/1748-0221/19/11/P11025. arXiv : 2406.11937 [physics.ins-det].

[35] F. Dulucq et AL. « HARDROC : Readout Chip for Calorimeters ». In : *IEEE Nuclear Science Symposium Conference Record*. 2010, p. 1678-1683. DOI : 10.1109/NSSMIC.2010.5873944.