


Université Claude Bernard Lyon 1




Institut de Physique des Deux Infinis de Lyon (IP2I)

# Identification des particules hadroniques et reconstruction de l'énergie dans un calorimètre SDHCAL à l'aide de méthodes d'apprentissage automatique

RAPPORT DE STAGE

Année universitaire 2024–2025

Mohamed Yanis IDIR

Master Physique Subatomique

**Encadré par :**

Pr. Imad Laktineh, Université Lyon 1
Pr. Gérald Grenier, Université Lyon 1

# Table des matières

**Résumé** **iv**

**Remerciements** **v**

**Introduction** **1**

**1 Interactions particule–matière et développement des gerbes** **5**
1.1 Interaction des particules avec la matière . . . 5
1.1.1 Particules chargées . . . 5
1.1.2 Hadrons et neutrons . . . 5
1.2 Gerbes électromagnétiques . . . 6
1.3 Gerbes hadroniques . . . 6
1.3.1 Développement et longueur d'interaction . . . 6
1.3.2 Fraction électromagnétique et rapport $h/e$ . . . 7
1.3.3 Énergie invisible, fuites et résolution . . . 7
1.3.4 Structure temporelle et profils spatiaux . . . 8

**2 Le calorimètre SDHCAL** **9**
2.1 Concept et géométrie du prototype . . . 9
2.2 Détection dans les GRPC et lecture semi-digitale . . . 9
2.3 Simulation et digitalisation . . . 10
2.4 Validation expérimentale et performances de référence . . . 10

**3 Identification hadronique dans le SDHCAL par apprentissage supervisé** **11**
3.1 Enjeux physiques et signatures attendues . . . 11
3.2 Stratégie : pourquoi un apprentissage supervisé . . . 12
3.3 Données simulées et descripteurs physiques . . . 13
3.4 Protocole d'entraînement et métriques . . . 13
3.5 Résultats de classification . . . 14
3.5.1 Variables discriminantes . . . 16
3.5.2 Limites et systématiques . . . 17
3.6 Étude exploratoire : approche GNN . . . 18

**4 Reconstruction de l'énergie** **19**
4.1 Enjeux dans un calorimètre semi-digital . . . 19
4.2 Données disponibles et protocole d'évaluation . . . 19
4.3 Méthode paramétrique par comptage de seuils . . . 19
4.4 Ajustement des paramètres par minimisation d'une fonction pondérée . . . 20

4.5 Résultats de la méthode paramétrique . . . 20
4.6 Régression LightGBM . . . 20
4.7 Comparaison et portée des résultats . . . 20
4.7.1 Paramétrisation de la résolution . . . 20
4.8 Limites et systématiques . . . 23

**5 Analyse sur échantillons mixtes** **24**
5.1 Motivation et scénarios comparés . . . 24
5.2 Chaîne PID + régression BDT . . . 24
5.3 Chaîne PID + méthode paramétrique . . . 24
5.4 Référence pion appliquée à toutes les espèces . . . 24
5.5 Comparaison quantitative à 20 et 80 GeV . . . 27
5.6 Limites de l'analyse . . . 27

**Conclusion générale** **28**

**Perspectives** **29**

**A Descripteurs de gerbe : définitions** **30**
A.1 Principe et inventaire . . . 30
A.2 Variables liées aux seuils semi-digitaux . . . 30
A.3 Descripteurs longitudinaux . . . 31
A.4 Descripteurs transverses et géométriques . . . 31
A.5 Densité locale et structure en amas . . . 32
A.6 Variables temporelles . . . 33
A.7 Profil longitudinal et ajustement de Gaisser–Hillas . . . 34
A.8 Recherche de segments quasi-linéaires . . . 34
A.9 Hiérarchie des variables et tableau récapitulatif . . . 35

**Annexes** **30**

**B Configuration du classificateur PID** **38**
B.1 Jeux de données et variables d'entrée . . . 38
B.2 Nettoyage et prétraitement . . . 38
B.3 Protocole d'apprentissage . . . 39
B.4 Rééquilibrage des classes par SMOTE . . . 40
B.5 Modèle et hyperparamètres . . . 41
B.6 Métriques d'évaluation . . . 41

**C Classification hadronique par réseau de neurones graphique** **42**
C.1 Données et prétraitement des nœuds . . . 42
C.2 Construction du graphe . . . 42
C.3 Architecture et entraînement . . . 43
C.4 Résultats, limites et perspectives . . . 43
C.5 Tableau récapitulatif . . . 45

**D Régression de l'énergie avec LightGBM** **46**
D.1 Données et variables d'entrée . . . 46
D.2 Apprentissage en espace logarithmique . . . 47
D.3 Modèle et hyperparamètres . . . 47
D.4 Métriques d'évaluation . . . 48

**E Reconstruction d'énergie par méthode paramétrique $\chi^2$** **49**
E.1 Sélection des événements et prétraitement . . . 49
E.2 Procédure numérique avec `TMinuit` . . . 49
E.3 Calcul de l'énergie reconstruite . . . 50
E.4 Chaîne PID + reconstruction paramétrique . . . 50
E.5 Forces et limites de la méthode . . . 53
E.6 Tableau récapitulatif . . . 53

**F Compléments sur le détecteur et l'identification hadronique** **54**
F.1 Électronique de lecture et acquisition . . . 54
F.2 Signatures calorimétriques attendues . . . 54
F.3 Corrélations entre variables d'entrée . . . 55

# Résumé

La mesure précise de l'énergie des hadrons constitue un enjeu majeur de la physique des hautes énergies. Contrairement aux gerbes électromagnétiques, relativement stables et bien modélisées, les gerbes hadroniques présentent d'importantes fluctuations événement par événement, liées notamment à la fraction électromagnétique, aux pertes d'énergie invisibles ainsi qu'aux fuites longitudinales et latérales. Ces effets dégradent la linéarité de la réponse calorimétrique et limitent la résolution en énergie.

Le *Semi-Digital Hadron CALorimeter* (SDHCAL) propose une approche originale fondée sur une très haute granularité spatiale associée à une lecture semi-digitale à trois seuils. Une telle architecture permet d'accéder finement à la topologie des gerbes hadroniques et ouvre des perspectives intéressantes aussi bien pour l'identification des particules que pour la reconstruction de leur énergie.

Dans ce travail, une chaîne d'analyse complète a été développée et appliquée à des échantillons simulés de pions, protons et kaons neutres longs. L'identification hadronique repose principalement sur des arbres de décision boostés (*Boosted Decision Trees*, BDT), tandis qu'une étude exploratoire de réseaux de neurones graphiques (GNN) a également été menée. Pour la reconstruction de l'énergie, deux approches ont été comparées : une méthode paramétrique fondée sur une minimisation pondérée des écarts entre énergie reconstruite et énergie vraie, et une régression supervisée par BDT exploitant un ensemble enrichi de descripteurs de gerbe.

Les performances ont ensuite été étudiées dans plusieurs scénarios combinant identification des particules et reconstruction d'énergie. Le classificateur multiclasse atteint une accuracy équilibrée de 67.8 %, avec une séparation nettement meilleure des $K_L^0$ que des pions et des protons. L'introduction du PID agit surtout sur le biais de reconstruction : à 80 GeV, la chaîne BDT + BDT maintient le biais des trois espèces en dessous de 1 %. Les différences de dispersion entre scénarios restent plus limitées.

Cette étude met en évidence l'intérêt d'exploiter conjointement la morphologie des gerbes, l'information semi-digitale et l'identification de l'espèce. Ses performances reposent toutefois sur la simulation ; leur transfert à une mesure expérimentale nécessitera une confrontation aux données de faisceau et une étude dédiée des incertitudes systématiques.

**Mots-clés :** SDHCAL, calorimétrie hadronique, identification des particules, reconstruction d'énergie, apprentissage automatique.

# Remerciements

Je tiens à exprimer ma profonde gratitude à mes encadrants de stage, le Pr. Imad Laktineh et le Pr. Gérald Grenier, pour la confiance qu'ils m'ont accordée, la qualité de leur accompagnement scientifique et la pertinence de leurs conseils. J'ai énormément appris à leurs côtés ; leur exigence, leur disponibilité et leur bienveillance ont été déterminantes tout au long de ce travail.

Je souhaite également adresser mes remerciements chaleureux aux doctorants William Vaginey et Tanguy Pasquier, qui m'ont guidé au quotidien, répondu avec patience à mes nombreuses questions et partagé de précieux conseils pratiques.

Enfin, je remercie l'ensemble de l'équipe « Particules » ainsi que tout l'IP2I pour leur accueil, leurs échanges stimulants et l'excellente ambiance de travail, qui ont rendu ce stage particulièrement enrichissant et agréable.

# Introduction

La mesure précise de l'énergie des hadrons demeure l'un des défis historiques de la calorimétrie en physique des hautes énergies. Contrairement aux gerbes électromagnétiques, relativement bien comprises et caractérisées par des fluctuations modérées, les gerbes hadroniques présentent une variabilité importante d'un événement à l'autre. La fraction électromagnétique, l'énergie invisible liée aux processus nucléaires, ainsi que les fuites longitudinales et latérales dégradent directement la linéarité de réponse et la résolution énergétique des calorimètres hadroniques. Ces limitations constituent un enjeu majeur pour les détecteurs de nouvelle génération.

**Quelles particules, quelle mesure.** Le *Modèle Standard* constitue le cadre théorique de référence pour décrire les particules élémentaires et trois des quatre interactions fondamentales [1, 2]. Les particules qu'il décrit sont représentées Figure 1. Dans le contexte de la calorimétrie hadronique, les objets effectivement observés ne sont toutefois pas les quarks eux-mêmes : le confinement de couleur interdit de les observer isolément [3], et les états finals sont constitués de hadrons — baryons ($qqq$) et mésons ($q\bar{q}$) — dont l'interaction avec la matière absorbante repose sur des processus nucléaires inélastiques complexes.

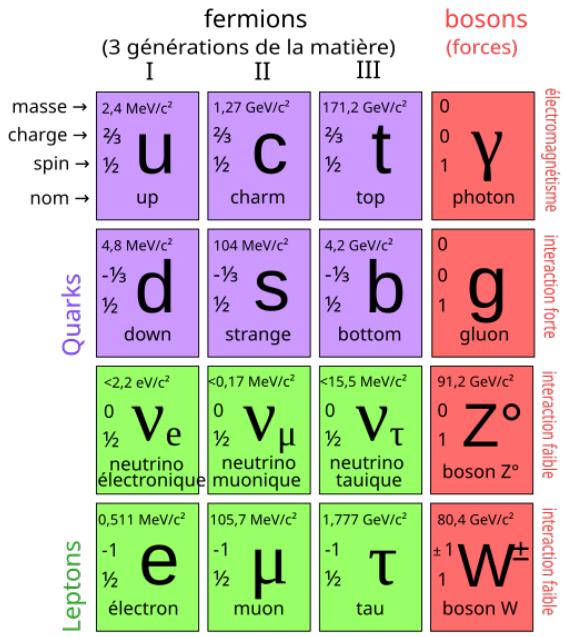



**FIGURE 1.** Particules élémentaires décrites par le Modèle Standard [4].

Ce travail porte sur trois espèces hadroniques représentatives, choisies pour leurs signatures calorimétriques distinctes : les pions chargés $\pi^-$, les protons $p$ et les kaons neutres longs $K_L^0$. Leurs propriétés fondamentales et les conséquences calorimétriques qui en découlent sont rassemblées au Tableau 3.1,

au chapitre 3.

**Pourquoi la résolution énergétique est le verrou.** Dans les expériences de physique des hautes énergies, une fraction importante de l'énergie finale est transportée par des hadrons organisés en jets, et la mesure de ces jets repose de manière déterminante sur les calorimètres hadroniques. Or les gerbes hadroniques présentent des fluctuations importantes liées aux processus nucléaires inélastiques, à l'énergie invisible et aux fuites, ce qui dégrade la résolution énergétique. Ces limitations constituent la motivation centrale du développement de calorimètres à haute granularité.

Dans les approches de type *Particle Flow Algorithm* (PFA) [5], la mesure des jets repose sur la combinaison optimale des différents sous-détecteurs. Dans ce cadre, le calorimètre hadronique (HCAL) occupe une place centrale : sa granularité, sa capacité de séparation spatiale et la qualité de sa reconstruction énergétique conditionnent fortement la performance globale du détecteur.

C'est dans cette perspective qu'a été développé le *Semi-Digital Hadron CALorimeter* (SDHCAL), au sein de la collaboration CALICE. Ce concept associe une segmentation spatiale très fine, reposant sur des cellules centimétriques, à une lecture semi-digitale sur trois seuils codés sur deux bits. Une telle architecture permet de conserver une information calorimétrique riche tout en maîtrisant le volume de données et la consommation électronique. La haute granularité obtenue ouvre également la voie à une analyse détaillée de la morphologie des gerbes, aussi bien pour l'identification de particules (*Particle Identification*, PID) que pour la reconstruction d'énergie.

Parallèlement, les méthodes d'apprentissage automatique (*Machine Learning*) occupent désormais une place croissante en physique des particules. Après les premières approches multivariées popularisées notamment via TMVA [6], des techniques plus récentes telles que les arbres de décision boostés, les réseaux convolutionnels ou les réseaux de neurones graphiques ont démontré leur capacité à exploiter efficacement la complexité des données issues des détecteurs modernes [7, 8].

Le présent travail s'inscrit dans cette dynamique et propose une chaîne d'analyse complète appliquée à un prototype SDHCAL simulé, intégrant à la fois **l'identification hadronique** et la **reconstruction de l'énergie**. Deux approches de reconstruction énergétique sont étudiées :

(i) une méthode paramétrique fondée sur la minimisation d'un $\chi^2$ utilisant les compteurs multi-seuils $(N_1, N_2, N_3)$ ;

(ii) une régression supervisée par arbres de décision boostés (*Boosted Decision Trees*, BDT), exploitant un ensemble étendu de descripteurs de gerbe.

L'identification des particules repose également sur un classifieur BDT, complété par une étude exploratoire basée sur les réseaux de neurones graphiques (GNN).

**Motivation du PID dans les données de type faisceau.** Dans les études expérimentales de calorimétrie hadronique, la calibration du détecteur est généralement réalisée à partir de faisceaux dominés par des pions, qui constituent une espèce abondante et relativement bien contrôlée. Cette calibration pion sert ensuite de référence pour reconstruire l'énergie des gerbes hadroniques. Toutefois, en pratique, les faisceaux utilisés lors des tests ne sont pas parfaitement purs : ils présentent des contaminations non négligeables en protons, électrons ou muons, dont la proportion peut varier avec l'énergie et les conditions expérimentales. Lors des tests du prototype SDHCAL au SPS, le faisceau de pions positifs de la ligne H6 était ainsi contaminé par des protons au-delà de 20 GeV, la contamination atteignant

45 à 60 % entre 50 et 100 GeV — en l'absence de détecteur Cherenkov permettant de séparer les deux espèces [9]. Sans dispositif d'identification dédié en amont du calorimètre, l'espèce incidente n'est donc pas connue événement par événement.

Or, les différentes particules hadroniques n'interagissent pas de manière identique dans le calorimètre. Les protons, par exemple, présentent une longueur d'interaction plus courte que celle des pions dans l'acier — 16,8 cm contre 20,4 cm [9] — de sorte qu'ils amorcent leur gerbe plus tôt en moyenne et subissent moins de fuites longitudinales, ce qui modifie le développement de la gerbe et son confinement. De même, la fraction électromagnétique, fortement liée à la production de $\pi^0$, peut fluctuer différemment selon l'espèce incidente. L'application d'une calibration unique, dérivée des pions, à un échantillon contenant un mélange de particules introduit ainsi un biais potentiel dans la reconstruction de l'énergie.

Dans ce contexte, l'identification des particules apparaît comme un levier essentiel pour améliorer les performances du détecteur. En distinguant les espèces incidentes à partir de la topologie de leur gerbe, il devient possible d'appliquer des calibrations spécifiques à chaque type de particule, ou à défaut de mieux contrôler les effets de mélange. Cette approche permet de rapprocher les conditions expérimentales réelles d'un scénario idéal dans lequel l'espèce incidente serait parfaitement connue, et constitue une motivation centrale du développement de méthodes de PID dans le SDHCAL.

**Trois scénarios de référence.** Afin de quantifier l'impact de cette information, les performances de reconstruction sont étudiées selon trois configurations représentatives :

(i) **Référence pion universelle** : calibration paramétrique déterminée sur les pions et appliquée à toutes les espèces ; cette référence simple n'est pas une borne inférieure générale, car elle n'est pas optimisée comme estimateur inclusif ;

(ii) **PID + calibration paramétrique** : routage des événements selon la classe prédite, puis application de la calibration analytique correspondante ;

(iii) **PID + régression BDT** : même routage, suivi d'un modèle de régression spécifique à la classe prédite.

Une reconstruction utilisant directement l'espèce vraie de la simulation constitue par ailleurs un cas idéal utile pour interpréter les méthodes, mais elle ne correspond pas à une chaîne expérimentale accessible. La comparaison retenue permet surtout d'évaluer dans quelle mesure le PID réduit les biais dus à l'application d'une calibration unique à un mélange d'espèces.

**Objectifs du travail.** Les objectifs principaux de cette étude sont les suivants :

1. **Extraire des observables discriminantes** et robustes pour le PID et la reconstruction d'énergie, en s'appuyant sur la topologie des gerbes ;
2. **Comparer approches paramétrique et supervisée** en termes de linéarité, de biais et de résolution ;
3. **Quantifier l'apport du PID** sur la performance énergétique dans des échantillons mixtes ;
4. **Explorer les approches fondées sur les graphes** pour les calorimètres hautement granulaires.

**Organisation du mémoire.** Le manuscrit est organisé comme suit. Le chapitre 1 rappelle les mécanismes d'interaction particule–matière et le développement des gerbes, en insistant sur les grandeurs

qui gouvernent la réponse d'un calorimètre hadronique. Le chapitre 2 présente le prototype SDHCAL, sa lecture semi-digitale et sa chaîne de simulation. Le chapitre 3 est consacré à l'identification hadronique par apprentissage supervisé, et le chapitre 4 à la reconstruction de l'énergie par les deux approches comparées. Le chapitre 5 réunit les deux volets sur des échantillons mixtes, avant la conclusion. Les détails de mise en œuvre — calcul des descripteurs, configuration des modèles et procédures numériques — sont reportés en annexe.

# Chapitre 1

# Interactions particule–matière et développement des gerbes

Selon leur nature, leur charge et leur énergie, les particules incidentes déposent leur énergie par ionisation, rayonnement ou interactions nucléaires, donnant naissance à des cascades secondaires appelées **gerbes**. Ce chapitre rappelle les grandeurs qui gouvernent ce développement et qui seront remobilisées pour interpréter la réponse du SDHCAL.

## 1.1 Interaction des particules avec la matière

### 1.1.1 Particules chargées

Dans un milieu, une particule chargée perd principalement de l'énergie par **ionisation** et **excitation** des atomes. La dépendance moyenne du pouvoir d'arrêt suit la loi de Bethe–Bloch [10, 4] :

$$\left\langle -\frac{\mathrm{d}E}{\mathrm{d}x} \right\rangle = K z^2 \frac{Z}{A} \frac{1}{\beta^2} \left[ \frac{1}{2} \ln\left( \frac{2 m_e c^2 \beta^2 \gamma^2 T_{\max}}{I^2} \right) - \beta^2 - \frac{\delta}{2} \right], \tag{1.1}$$

où $K = 4\pi N_A r_e^2 m_e c^2$, $z$ est la charge de la particule incidente, $Z/A$ le rapport charge/masse du milieu, $I$ le potentiel moyen d'excitation, $T_{\max}$ l'énergie maximale transférable à un électron libre et $\delta$ le terme de correction de densité [4].

Cette expression présente un *minimum d'ionisation* pour $\beta\gamma \simeq 3$–$4$ (régime de la particule au minimum d'ionisation, MIP). Dans la gamme d'énergies considérée pour le SDHCAL (1–130 GeV), l'ionisation domine pour les hadrons et les muons, ce qui justifie l'usage du MIP comme unité de calibration et motive la lecture multi-seuils pour caractériser la densité locale de dépôt. Le *bremsstrahlung* ne domine que pour les $e^{\pm}$ au-delà de l'énergie critique $E_c \sim 500/Z$ MeV et reste donc marginal ici.

Les photons, quant à eux, interagissent via l'*effet photoélectrique* à basse énergie (keV), la *diffusion Compton* aux énergies intermédiaires (quelques MeV), puis la *création de paires* $\gamma \to e^+ e^-$ à haute énergie ($\gg 2 m_e c^2$) [4]. Dans le SDHCAL, ces mécanismes contribuent essentiellement à la composante électromagnétique des gerbes, alimentée par la désintégration $\pi^0 \to \gamma\gamma$.

### 1.1.2 Hadrons et neutrons

Les hadrons chargés perdent d'abord de l'énergie par ionisation, mais, soumis à l'**interaction forte**, leurs processus d'interaction sont beaucoup plus complexes. Lorsqu'un hadron incident interagit avec un noyau, il déclenche une **spallation nucléaire** [11, 12] en deux étapes : une **cascade intranucléaire**, au cours de laquelle le hadron induit des collisions secondaires — certains hadrons produits s'échappent du noyau, d'autres sont réabsorbés — puis la **désexcitation du noyau**, par évaporation de protons, de

neutrons et de particules $\alpha$, suivie d'émission de $\gamma$.

Ce processus est hautement stochastique, et une fraction de l'énergie reste **invisible aux calorimètres** : énergie de liaison nucléaire consommée lors de la spallation, recul du noyau résiduel, et neutrons secondaires faiblement ou tardivement détectés — ces derniers produisant, selon leur énergie, des signaux retardés ou délocalisés par diffusion élastique, diffusion inélastique ou capture radiative [11, 13]. Cette combinaison d'ionisation, d'interactions fortes et de cascades nucléaires, avec une part d'énergie non détectée, explique la difficulté à atteindre une résolution comparable à celle des calorimètres électromagnétiques [14, 12].

Enfin, les **hadrons neutres** tels que le $K_L^0$ n'ionisent pas et ne déposent de l'énergie que via ces interactions nucléaires, ce qui rend leur point de départ de gerbe nettement plus variable. Cette propriété sera exploitée au chapitre 3.

## 1.2 Gerbes électromagnétiques

Les gerbes électromagnétiques (EM) sont initiées par des électrons, des photons, ou par des $\pi^0 \to \gamma\gamma$ [15, 16]. Elles résultent de l'alternance entre *bremsstrahlung* ($e^\pm \to e^\pm\gamma$) et *création de paires* ($\gamma \to e^+e^-$), jusqu'à ce que l'énergie descende sous l'énergie critique $E_c$, où l'ionisation devient dominante. Leur structure est fixée par deux grandeurs [4] : la **longueur de radiation** $X_0$, distance sur laquelle un électron perd en moyenne $1/e$ de son énergie par bremsstrahlung, qui donne l'échelle longitudinale ; et le **rayon de Molière** $R_M \approx 21\,\mathrm{MeV} \cdot X_0/E_c$, qui définit l'extension transverse — environ 90% de l'énergie est contenue dans un cylindre de rayon $R_M$. Elles constituent une référence utile : leur développement est compact, régulier et bien modélisé, contrairement aux gerbes hadroniques.

## 1.3 Gerbes hadroniques

Lorsqu'un hadron de haute énergie pénètre dans un matériau absorbant, il initie une **gerbe hadronique** — une cascade complexe de particules secondaires résultant d'interactions nucléaires successives. Contrairement au cas électromagnétique, ces gerbes présentent d'importantes fluctuations événement par événement dans leur composition, leur extension spatiale et la fraction d'énergie effectivement détectée [12, 14].

### 1.3.1 Développement et longueur d'interaction

La gerbe débute par une interaction inélastique du hadron incident avec un noyau du milieu, produisant pions chargés et neutres, kaons, nucléons secondaires et fragments nucléaires ; les hadrons secondaires suffisamment énergétiques alimentent la cascade à leur tour. Une caractéristique essentielle est la production de $\pi^0$, qui se désintègrent quasi instantanément selon $\pi^0 \to \gamma\gamma$ et initient des sous-gerbes électromagnétiques imbriquées. La fraction d'énergie dérivée vers cette composante EM fluctue fortement d'un événement à l'autre et constitue la principale source de variabilité de la réponse calorimétrique.

Le développement longitudinal est gouverné par la **longueur d'interaction nucléaire** [4] :

$$\lambda_I = \frac{A}{N_A \rho \sigma_{\text{inel}}}, \tag{1.2}$$

où $A$ est la masse molaire du matériau, $\rho$ sa densité, $N_A$ le nombre d'Avogadro et $\sigma_{\text{inel}}$ la section efficace inélastique hadron-noyau.

**TABLE 1.1.** Comparaison des longueurs caractéristiques pour quelques matériaux d'absorbeur courants [4].

| **Matériau** | $Z$ | $X_0$ (cm) | $\lambda_I$ (cm) | $\lambda_I / X_0$ |
|---|---|---|---|---|
| Fer (Fe) | 26 | 1.76 | 16.77 | 9.5 |
| Plomb (Pb) | 82 | 0.56 | 17.59 | 31.4 |
| Acier inox | – | 1.76 | 16.77 | 9.5 |
| Tungstène (W) | 74 | 0.35 | 9.95 | 28.4 |

Le Tableau 1.1 montre que, quelle que soit la densité du matériau, $\lambda_I$ reste toujours bien supérieure à $X_0$ : les gerbes hadroniques sont plus profondes et plus diffuses que les gerbes électromagnétiques, ce qui impose des calorimètres plus épais et moins bien contenus.

### 1.3.2 Fraction électromagnétique et rapport $h/e$

La fraction d'énergie transférée à la composante EM via la production de $\pi^0$ est appelée **fraction électromagnétique**, $f_{\text{em}} = E_{\text{EM}}/E_{\text{tot}}$. En moyenne, elle croît avec l'énergie incidente selon une loi approximative [12] :

$$\langle f_{\text{em}} \rangle \approx 1 - \left( \frac{E}{E_0} \right)^{m-1}, \tag{1.3}$$

avec $E_0$ et $m$ des paramètres dépendant du matériau et de l'espèce hadronique. Toutefois, $f_{\text{em}}$ fluctue fortement d'un événement à l'autre, même à énergie fixée. La réponse moyenne d'un calorimètre à une gerbe hadronique s'écrit alors [12] :

$$\langle E_\pi \rangle = \left[ f_{\text{em}} + (1 - f_{\text{em}}) \frac{h}{e} \right] E, \tag{1.4}$$

où $e$ et $h$ désignent respectivement les réponses électromagnétique et hadronique du détecteur. Un calorimètre est dit **compensant** lorsque $h/e = 1$, ce qui minimise l'effet des fluctuations de $f_{\text{em}}$ sur la résolution. Hors compensation, ces fluctuations constituent la contribution dominante à la non-linéarité et à la dégradation de la résolution énergétique.

### 1.3.3 Énergie invisible, fuites et résolution

L'énergie invisible évoquée plus haut est intrinsèquement variable d'un événement à l'autre [14] ; s'y ajoutent les **fuites longitudinales ou latérales**, lorsque la gerbe n'est pas totalement contenue dans le volume instrumenté. La paramétrisation standard de la résolution énergétique d'un calorimètre hadronique est alors [14] :

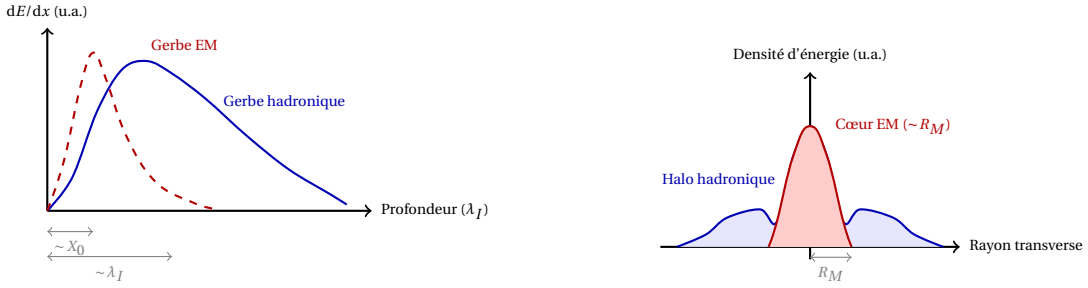
$$\frac{\sigma(E)}{E} = \frac{a}{\sqrt{E/\text{GeV}}} \oplus b \oplus \frac{c}{E/\text{GeV}}, \tag{1.5}$$

où $a$ est le terme stochastique (dominé par les fluctuations de $f_{\text{em}}$ et les fluctuations d'échantillonnage), $b$ le terme constant (effets systématiques, non-uniformités, fuites) et $c$ le terme de bruit électronique. Cette décomposition sera ajustée sur les résultats du chapitre 4, où elle permet de distinguer ce qui relève des fluctuations de gerbe de ce qui relève des limites instrumentales.

### 1.3.4 Structure temporelle et profils spatiaux

Les cascades hadroniques ont une structure temporelle plus étendue que les gerbes électromagnétiques : une partie du signal est déposée rapidement par les particules relativistes, d'autres contributions apparaissent plus tardivement via les neutrons ralentis puis capturés, avec des temps caractéristiques de quelques dizaines de nanosecondes. La réponse mesurée dépend donc de la fenêtre temporelle d'acquisition, aspect pertinent pour le SDHCAL dont les variables temporelles constituent des descripteurs potentiellement discriminants pour le PID (chapitre 3).

Spatialement, le profil longitudinal présente une montée rapide suivie d'une décroissance lente, tandis que le profil transverse se compose d'un **cœur dense**, enrichi en composante électromagnétique et de rayon proche de $R_M$, entouré d'une **région périphérique diffuse**, dominée par les hadrons secondaires et les neutrons, qui s'étend jusqu'à plusieurs $\lambda_I$.




**(a)** Profils longitudinaux comparés.

**(b)** Profil transverse d'une gerbe hadronique.

**FIGURE 1.1.** (a) Profils longitudinaux comparés d'une gerbe hadronique (bleu) et électromagnétique (rouge pointillé) ; les échelles caractéristiques $X_0$ et $\lambda_I$ sont indiquées. (b) Profil transverse d'une gerbe hadronique montrant le cœur électromagnétique compact (rouge) et le halo hadronique étendu (bleu).

Les fluctuations de $f_{\text{em}}$, les profils spatiaux différenciés selon l'espèce et la structure temporelle des dépôts constituent autant d'observables exploitables pour le PID et la reconstruction d'énergie — à condition de disposer d'un calorimètre suffisamment granulaire pour les mesurer finement. C'est précisément l'objet du détecteur décrit au chapitre suivant.

# Chapitre 2

# Le calorimètre SDHCAL

## 2.1 Concept et géométrie du prototype

Le *Semi-Digital Hadron CALorimeter* (SDHCAL) est un calorimètre hadronique hautement granulaire développé dans le cadre de la collaboration CALICE [9, 17], dans le contexte des futurs collisionneurs linéaires [18], où la reconstruction précise des jets impose une excellente séparation spatiale des particules et une mesure fiable des gerbes hadroniques.

Contrairement aux calorimètres conventionnels, il ne repose pas uniquement sur une mesure globale de l'énergie déposée : son principe consiste à exploiter la structure tridimensionnelle des gerbes, en combinant une granularité spatiale fine et une lecture à trois seuils conservant l'information de densité locale des dépôts. Cette approche est particulièrement adaptée aux algorithmes de type *Particle Flow Algorithm* [5, 19].

Le prototype est un calorimètre à échantillonnage constitué de 48 couches actives insérées entre des plaques d'acier inoxydable de 2 cm d'épaisseur [17], soit une profondeur totale d'environ $6\,\lambda_I$. Chaque couche active couvre $96 \times 96$ cm$^2$ et est segmentée en pads de $1 \times 1$ cm$^2$, soit 9216 cellules indépendantes par plan, ce qui donne accès à une image tridimensionnelle détaillée du développement des cascades.

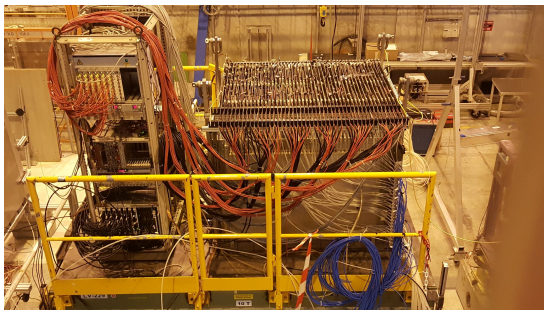


**FIGURE 2.1.** Vue du prototype SDHCAL instrumenté lors d'une campagne de test faisceau.

## 2.2 Détection dans les GRPC et lecture semi-digitale

Les détecteurs actifs utilisés sont des chambres résistives à plaques de verre, ou *Glass Resistive Plate Chambers* (GRPC) [20] : deux plaques de verre séparées par un faible entrefer gazeux, dans lequel se développe l'avalanche induite par le passage d'une particule chargée. Le signal induit est collecté sur les pads de lecture situés à proximité de l'anode ; la charge mesurée dépend du nombre d'ionisations initiales, de la position de passage, des conditions de champ électrique, de la composition du gaz et des fluctuations propres à l'avalanche. Ces chambres offrent un coût modéré pour de grandes surfaces, une bonne homogénéité spatiale, une efficacité élevée pour les particules au minimum d'ionisation et une compatibilité naturelle avec une lecture segmentée en pads [20, 21].

L'originalité du SDHCAL réside dans sa lecture semi-digitale codée sur deux bits : trois seuils de charge $T_1 < T_2 < T_3$ sont appliqués à chaque canal, et chaque hit est classé selon le plus haut seuil franchi, ce qui permet de distinguer les dépôts isolés, les régions de densité intermédiaire et les zones très denses de la gerbe. Une lecture purement digitale saturerait dans les régions centrales des gerbes ; la lecture semi-digitale conserve une sensibilité à la densité locale tout en maintenant une électronique plus simple qu'une lecture analogique complète.

Les observables directement accessibles sont le nombre total de hits, les compteurs par seuil $N_1$, $N_2$, $N_3$, les fractions relatives entre seuils, les distributions spatiales des hits et les densités locales de dépôt. Elles constituent la base des méthodes de reconstruction d'énergie et d'identification hadronique étudiées dans ce mémoire. L'électronique de lecture embarquée qui produit ces signaux est décrite en Annexe F.

## 2.3 Simulation et digitalisation

L'étude présentée dans ce mémoire repose sur une chaîne de simulation basée sur l'environnement iLCSoft, utilisant Geant4 [22, 23] pour la propagation des particules dans le détecteur. La simulation fournit les dépôts d'énergie élémentaires dans les couches actives.

Une étape de digitalisation transforme ensuite ces dépôts physiques en hits comparables à ceux produits par l'électronique réelle : sélection temporelle des dépôts, application d'une efficacité de détection, génération d'une charge induite fluctuante, diffusion transverse vers les pads voisins, puis application des trois seuils semi-digitaux. La sortie contient, pour chaque hit, ses coordonnées discrètes $(I, J, K)$, le seuil franchi, un horodatage et l'identifiant de l'événement, converties ensuite en formats `ROOT` [24] et `CSV`. Cette étape est déterminante pour la suite : toutes les observables exploitées dans les chapitres 3 et 4 sont construites à partir de ces hits digitalisés, et non des dépôts d'énergie continus fournis par Geant4.

## 2.4 Validation expérimentale et performances de référence

Le prototype a été étudié au CERN avec des faisceaux de muons, d'électrons et de hadrons sur une large gamme d'énergies [9, 17, 25]. La comparaison entre données et simulation porte sur le nombre total de hits par événement, les distributions par seuil $N_1$, $N_2$, $N_3$, l'efficacité MIP et la multiplicité des pads, les profils longitudinaux, l'extension transverse et la position du maximum de gerbe. Ces comparaisons permettent d'ajuster les paramètres de digitalisation, de tester différentes listes de physique hadronique de Geant4 [23] et d'estimer les incertitudes systématiques de modélisation. Les performances de référence sur données réelles, en particulier la résolution en énergie hadronique, sont documentées dans [25] et constituent le point de comparaison naturel des résultats du chapitre 4.

Grâce à l'information multi-seuil, l'énergie incidente y est estimée à partir d'une combinaison pondérée des compteurs de hits $N_1$, $N_2$, $N_3$, dont les coefficients dépendent du nombre total de hits [25]. Cette méthode, reprise et étudiée en détail au chapitre 4, sert de référence paramétrique dans ce travail.

Le concept a naturellement ses limites : dépendance des chambres gazeuses aux conditions opératoires, nécessité d'une calibration précise, et profondeur finie du prototype aux plus hautes énergies — cette dernière contrainte se manifestera directement dans les résultats du chapitre 4.

# Chapitre 3

# Identification hadronique dans le SDHCAL par apprentissage supervisé

La granularité du SDHCAL et sa lecture à trois seuils donnent accès à la morphologie des gerbes au-delà du seul nombre total de hits. Ce chapitre étudie dans quelle mesure cette information permet de distinguer les espèces hadroniques avant d'appliquer une reconstruction d'énergie adaptée.

## 3.1 Enjeux physiques et signatures attendues

L'identification des particules (*Particle Identification*, PID) constitue une étape importante dans les expériences de physique des hautes énergies. Dans les états finals hadroniques, les particules produites forment souvent des jets issus de la fragmentation de quarks et de gluons, et une mauvaise identification des espèces peut conduire à une association incorrecte des dépôts d'énergie, à une calibration inadéquate ou à une dégradation de la résolution globale [4]. Une telle séparation est importante non seulement pour la classification des événements, mais aussi pour la reconstruction de l'énergie, puisque la réponse calorimétrique dépend de l'espèce incidente. Elle s'inscrit plus largement dans la logique des approches de type *Particle Flow*, où la qualité de la reconstruction globale repose sur une identification correcte des objets détectés.

Les trois espèces étudiées présentent des différences de masse, de charge et de structure interne qui influencent leur mode d'interaction avec la matière et donc la structure moyenne de leurs gerbes. Ces propriétés, et les conséquences calorimétriques attendues, sont rassemblées dans le Tableau 3.1. Les **pions chargés** sont des mésons légers : avant leur première interaction nucléaire, ils déposent de l'énergie par ionisation dans les premières couches du calorimètre, puis la production de pions neutres secondaires, suivie de la désintégration $\pi^0 \to \gamma\gamma$, alimente la composante électromagnétique de la cascade — leurs gerbes présentent ainsi souvent un développement relativement précoce et un cœur électromagnétique marqué. Les **protons** sont des baryons de masse plus élevée, dont la nature baryonique modifie la dynamique de la cascade, notamment à travers la conservation du nombre baryonique : à énergie identique, leurs gerbes tendent en moyenne à être plus hadroniques, plus profondes et plus diffuses, avec une fraction électromagnétique généralement plus faible. Les **kaons neutres longs**, enfin, ne portent pas de charge électrique et ne déposent donc pas d'énergie par ionisation avant leur première interaction nucléaire ; le point de départ de leur gerbe, gouverné par leur libre parcours moyen dans le matériau, est nettement plus variable, et leur contenu en étrangeté implique des voies de réaction différentes de celles des pions et des protons.

Ces différences se traduisent par des signatures calorimétriques moyennes distinctes — signal d'ionisation avant gerbe, fraction électromagnétique, profondeur de première interaction, développement longitudinal et extension transverse — dont la comparaison espèce par espèce est donnée au Tableau F.1,

**TABLE 3.1.** Propriétés fondamentales des trois espèces hadroniques étudiées et conséquences calorimétriques attendues [4].

| Espèce | Masse (MeV) | Charge | Temps de vie | Contenu en quarks | Nature | Conséquence principale |
|---|---|---|---|---|---|---|
| Pion chargé $\pi^-$ | 139.57 | $-1$ | 26.0 ns | $\bar{u}d$ | Méson | Ionisation initiale ; composante EM souvent marquée |
| Proton $p$ | 938.27 | $+1$ | stable | $uud$ | Baryon | Gerbe plus hadronique et plus profonde |
| Kaon neutre long $K_L^0$ | 497.61 | 0 | 51.2 ns | $\frac{1}{\sqrt{2}}(d\bar{s} - s\bar{d})$ | Méson neutre | Pas d'ionisation initiale ; départ de gerbe variable |

en Annexe F. Ces tendances restent toutefois statistiques, car les gerbes hadroniques présentent de fortes fluctuations événement par événement.

Ces différences suggèrent que des observables de morphologie, telles que le profil longitudinal, la compacité transverse, la profondeur du premier dépôt ou la répartition entre seuils, portent une information discriminante exploitable pour le PID.

## 3.2 Stratégie : pourquoi un apprentissage supervisé

La difficulté provient de la nature même des interactions hadroniques. Contrairement aux gerbes électromagnétiques, dont le développement est relativement régulier, les gerbes hadroniques présentent de fortes fluctuations d'un événement à l'autre. Le point de première interaction, la profondeur moyenne de développement, l'étalement transverse, la densité locale des dépôts et la fraction d'énergie invisible varient sensiblement, même à énergie incidente fixée. Certaines espèces, comme les protons et les pions chargés, produisent ainsi des signatures partiellement recouvrantes, rendant leur séparation non triviale.

Le SDHCAL possède néanmoins plusieurs caractéristiques favorables à cette tâche : sa très haute granularité permet de reconstruire la morphologie des gerbes couche par couche, tandis que la lecture semi-digitale à trois seuils apporte une information indirecte sur la densité locale du dépôt d'énergie. Lorsqu'une information temporelle est disponible, elle peut également contribuer à la discrimination via le temps de vol ou la dynamique d'initiation de la gerbe. L'ensemble forme un espace d'observables riche, mais complexe, dans lequel les corrélations entre variables jouent un rôle important.

Dans ce contexte, une approche par apprentissage supervisé s'impose naturellement : les descripteurs extraits sont nombreux, souvent corrélés, et leur pouvoir discriminant repose sur des dépendances non linéaires difficiles à exploiter au moyen de simples coupures séquentielles. L'objectif est donc d'entraîner un classificateur capable d'apprendre automatiquement une frontière de séparation efficace entre espèces à partir de leur signature calorimétrique.

Plusieurs familles de modèles ont été comparées sur un même jeu de variables d'entrée : perceptrons multicouches [26, 27], forêts aléatoires et arbres de décision boostés [28]. Les méthodes de boosting se sont révélées les plus performantes pour ce problème tabulaire, plus précises que les forêts aléatoires tout en nécessitant moins d'ajustements fins qu'un réseau dense. L'implémentation **LightGBM** [29] a été retenue comme modèle de référence pour la classification multiclasse $\pi^-$, $p$, $K_L^0$, notamment pour l'accès direct qu'elle donne à des indicateurs d'importance des variables, utiles à l'interprétation physique. Le détail de la comparaison entre modèles et les hyperparamètres retenus figurent en Annexe B.5.

## 3.3 Données simulées et descripteurs physiques

L'étude repose sur des échantillons simulés de particules mono-énergétiques correspondant aux trois espèces considérées : pions négatifs $\pi^-$, protons $p$ et kaons neutres longs $K_L^0$. Chaque classe contient environ $1.3 \times 10^5$ événements, générés entre 1 et 130 GeV. Ce domaine couvre à la fois les interactions de basse énergie, où les gerbes restent peu développées, et les régimes plus énergétiques, caractérisés par une activité hadronique plus étendue et plus fluctuante.

Plutôt que d'utiliser directement la liste exhaustive des hits du détecteur, nous construisons un ensemble de descripteurs physiques résumant les principales propriétés morphologiques de chaque événement. Ces variables sont extraites à l'aide de l'outil `ShowerAnalyzer` et regroupées en familles complémentaires :

— **Activité globale et information en seuils :** nombre total de hits, occupations associées aux trois seuils semi-digitaux (`Thr1`, `Thr2`, `Thr3`), multiplicité locale. Ces variables renseignent sur l'intensité globale de la gerbe et sur la densité locale des dépôts d'énergie.

— **Développement longitudinal :** plan de début de gerbe (`Begin`), barycentre en profondeur (`Zbary`), dispersion longitudinale (`Zrms`), position du maximum ou paramètres ajustés du profil longitudinal. Elles sont sensibles à la profondeur de première interaction et à l'évolution de la cascade dans l'absorbeur.

— **Développement transverse et compacité :** rayon effectif (`Radius`), densité locale (`Density`), excentricité, valeurs propres géométriques ($\lambda_1$, $\lambda_2$). Ces observables décrivent l'étalement latéral et l'anisotropie spatiale de la gerbe.

— **Structure locale :** nombre de clusters intra-couche, taille moyenne et maximale des clusters, présence éventuelle de segments quasi-linéaires. Elles caractérisent la fragmentation interne de l'activité.

— **Variables temporelles :** temps du premier hit (`tMin`), temps moyen (`tMean`), dispersion temporelle (`tSpread`). Elles peuvent refléter à la fois le temps de vol de la particule incidente et la dynamique temporelle de l'interaction hadronique.

Certaines de ces variables décrivent principalement la géométrie de la gerbe, d'autres son intensité locale ou sa chronologie ; leur combinaison fournit une représentation compacte, mais physiquement pertinente, de chaque événement. Lorsque l'étude inclut l'information temporelle, un *smearing* gaussien est appliqué afin de représenter une résolution instrumentale finie. La définition mathématique complète de chaque descripteur, ainsi que le détail de la préparation des données, sont donnés en Annexes A et B.1.

## 3.4 Protocole d'entraînement et métriques

L'évaluation repose sur trois sous-ensembles disjoints — entraînement, validation et test — obtenus par un découpage stratifié préservant les proportions des trois espèces. L'ensemble de validation sert à suivre l'apprentissage, à régler les hyperparamètres et à déclencher l'arrêt anticipé (*early stopping*) lorsque la performance cesse de s'améliorer ; l'ensemble de test n'intervient que pour l'évaluation finale. Cette organisation mesure la capacité de généralisation du modèle plutôt que son ajustement aux

données d'entraînement. Le modèle est entraîné en mode multiclasse par minimisation de la fonction de coût *multi-logloss*.

Des tests de rééquilibrage des classes par *SMOTE* (*Synthetic Minority Over-sampling Technique*) ont également été menés. Les gains observés étant restés limités, et la génération d'événements synthétiques risquant d'introduire des corrélations artificielles, cette stratégie n'a pas été retenue dans la chaîne principale. Le détail du découpage, des hyperparamètres et de la procédure d'entraînement est donné en Annexe B.5.

Les performances sont quantifiées à l'aide de métriques complémentaires : **accuracy globale** et **accuracy équilibrée** (moyenne des taux de bonne classification par classe, moins sensible aux déséquilibres statistiques), **matrice de confusion**, **multi-logloss**, **courbes ROC one-vs-rest** et aire sous la courbe (AUC), et **histogrammes des probabilités prédites**. Leur usage conjoint est nécessaire : une accuracy élevée ne garantit pas une bonne calibration probabiliste, tandis que la matrice de confusion identifie précisément quelles espèces restent difficiles à distinguer. Dans le cas présent, la confusion résiduelle entre protons et pions constitue un indicateur plus informatif que l'accuracy seule.

## 3.5 Résultats de classification

Les performances du modèle LightGBM sont évaluées sur l'ensemble de test indépendant, non utilisé lors des phases d'apprentissage et de validation. Les résultats présentés reflètent donc la capacité réelle de généralisation du classificateur pour la séparation des trois espèces hadroniques étudiées. Le suivi de la fonction de coût au cours de l'entraînement, qui ne montre pas de signe de sur-ajustement, est reporté en Annexe B.5.

**Matrice de confusion.** La matrice de confusion normalisée obtenue sur l'échantillon de test est représentée Figure 3.1. Elle met en évidence des comportements sensiblement différents selon les espèces :

— **Pions** $\pi^-$ : environ 48.8 % des événements sont correctement identifiés, tandis que ~ 47.9 % sont confondus avec des protons ;

— **Protons** $p$ : la séparation est meilleure, avec ~ 68.6 % d'identifications correctes, l'erreur dominante correspondant à une attribution vers la classe pion (~ 27.4 %) ;

— **Kaons neutres** $K_L^0$ : la classification est nettement plus performante, avec environ 86.0 % des événements correctement reconstruits.

Ces trois valeurs sont les *rappels* par classe, c'est-à-dire les termes diagonaux de la matrice normalisée par ligne. Leur moyenne non pondérée définit l'**accuracy équilibrée** :

$$\mathrm{BA} = \frac{1}{3}\,(48.8 + 68.6 + 86.0)\ \% = 67.8\,\%,$$

métrique de référence ici car indépendante des effectifs relatifs des trois classes dans l'échantillon de test. Le rappel des pions reste supérieur au niveau attendu d'une décision aléatoire entre trois classes (33 %), mais de peu : pour cette classe, le classificateur n'apporte qu'une information limitée, et les 47.9 % de pions attribués à la classe proton constituent à eux seuls la contribution dominante aux erreurs du modèle.

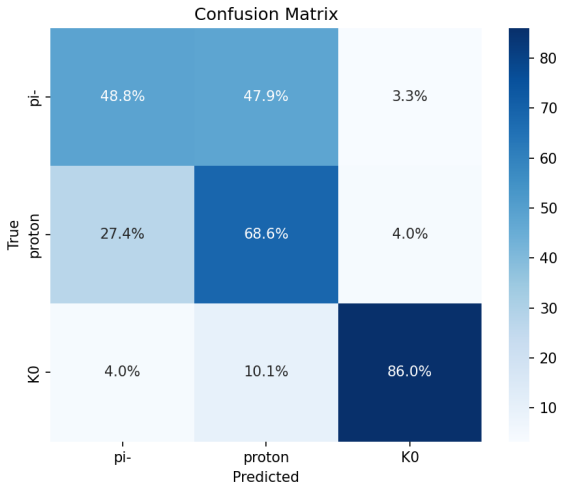



**FIGURE 3.1.** Matrice de confusion normalisée sur l'échantillon de test (pourcentages par ligne). Les classes sont ordonnées selon $\{\pi^-, p, K_L^0\}$.

**Étude binaire pion/proton.** Une configuration binaire, utilisée ensuite pour le routage des modèles d'énergie, a également été entraînée sur environ $2 \times 10^5$ événements par espèce entre 1 et 130 GeV. Elle atteint une accuracy globale proche de 61 %. La matrice de confusion associée donne 49.1 % de pions et 73.0 % de protons correctement identifiés ; 50.9 % des pions sont classés comme protons et 27.0 % des protons comme pions. Cette asymétrie doit être conservée à l'esprit pour interpréter les biais de la chaîne complète.

**Apport de l'information temporelle.** Les variables temporelles ont été incluses après application d'une résolution effective de 100 ps. Elles apportent une information complémentaire sur l'initiation et le développement de la gerbe. Leur contribution propre n'est toutefois pas isolée dans les résultats retenus : l'interprétation repose donc principalement sur les observables semi-digitales et morphologiques, dont le rôle est établi par l'étude d'importance des variables.

**Interprétation physique.** La meilleure séparation des $K_L^0$ s'explique par une dynamique hadronique différente de celle des pions et des protons. Dans les interactions se produisant dans l'absorbeur, les états finals sont très souvent dominés par la production de pions : leur faible masse les rend énergétiquement faciles à produire, les symétries approximatives de l'interaction forte — notamment l'isospin — et un espace de phase favorable renforcent cette dominance, et aucune création de quark étrange supplémentaire n'est requise. La production de kaons nécessite au contraire la création d'étrangeté ($s\bar{s}$) et implique des masses plus élevées : elle est donc statistiquement moins probable aux énergies considérées, et les cascades secondaires initiées par un $K_L^0$ diffèrent en moyenne de celles dominées par les pions. S'y ajoute le rôle des $\pi^0$, dont les fluctuations de production influencent directement la compacité locale, la densité d'activité et le développement longitudinal observés dans le calorimètre.

À l'inverse, protons et pions chargés interagissent tous deux par interaction forte sans dynamique d'étrangeté, et leurs gerbes restent largement dominées par les fluctuations de première interaction nucléaire et par la variabilité de la composante électromagnétique secondaire. Il en résulte un recouvrement important dans l'espace des variables tabulaires utilisées ici. La confusion résiduelle pion/proton ne traduit donc pas une faiblesse particulière du modèle, mais la proximité physique réelle de leurs

signatures. Il est par ailleurs probable que cette difficulté dépende de l'énergie incidente : à basse énergie, la faible multiplicité de hits accentue les fluctuations statistiques, tandis qu'à plus haute énergie certaines signatures morphologiques deviennent plus marquées — une étude différentielle par tranches d'énergie constituerait un prolongement naturel.

**Probabilités prédites.** Les histogrammes des probabilités de sortie (Figure 3.2) confirment ces tendances et renseignent sur le degré de confiance des prédictions. Les vrais $K_L^0$ reçoivent majoritairement des probabilités élevées pour leur classe correcte, avec une superposition limitée avec les distributions des pions et des protons. En revanche, les probabilités associées à la classe proton présentent un recouvrement significatif entre vrais protons et vrais pions : une fraction non négligeable des événements des deux classes reçoit des scores intermédiaires, traduisant une zone d'ambiguïté où la décision devient moins robuste. La confusion observée ne provient donc pas uniquement de limites algorithmiques, mais d'un recouvrement intrinsèque entre classes dans l'espace des variables utilisées. Ces distributions suggèrent enfin qu'une exploitation probabiliste des sorties — seuils ajustés, calibration des scores, sélection d'événements de haute pureté — constituerait une piste intéressante selon les besoins d'analyse.

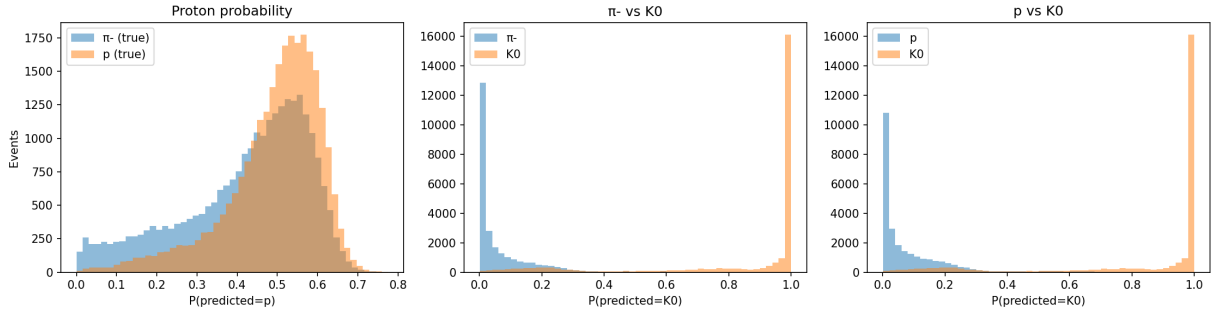



**FIGURE 3.2.** Histogrammes des probabilités prédites : (gauche) $P(\text{classe} = p)$ pour vrais $\pi^-$ et vrais $p$ ; (centre) $P(\text{classe} = K^0)$ pour vrais $\pi^-$ et vrais $K_L^0$ ; (droite) $P(\text{classe} = K^0)$ pour vrais $p$ et vrais $K_L^0$.

### 3.5.1 Variables discriminantes

Au-delà des performances globales, il est important d'identifier quelles observables portent l'information utile à la séparation, afin de comprendre les mécanismes physiques exploités par le modèle et de repérer d'éventuelles redondances. L'étude des corrélations linéaires entre variables d'entrée, présentée en Annexe F, montre que plusieurs observables transportent une information partiellement redondante — notamment au sein des variables décrivant l'activité globale et la compacité de la gerbe.

L'analyse des importances internes du modèle, estimées à partir du *gain* cumulé apporté par chaque variable lors des coupures successives, est présentée Figure 3.3.

**Variables dominantes.** La variable `Thr3`, correspondant au nombre de hits franchissant le seuil le plus élevé, apparaît comme la plus discriminante, nettement devant les autres : les régions les plus denses de la gerbe jouent donc un rôle central dans la séparation des espèces. Les variables `Density` et `Radius` figurent également parmi les contributions les plus élevées, montrant que la compacité locale et l'extension transverse moyenne sont particulièrement informatives. Un second groupe re-

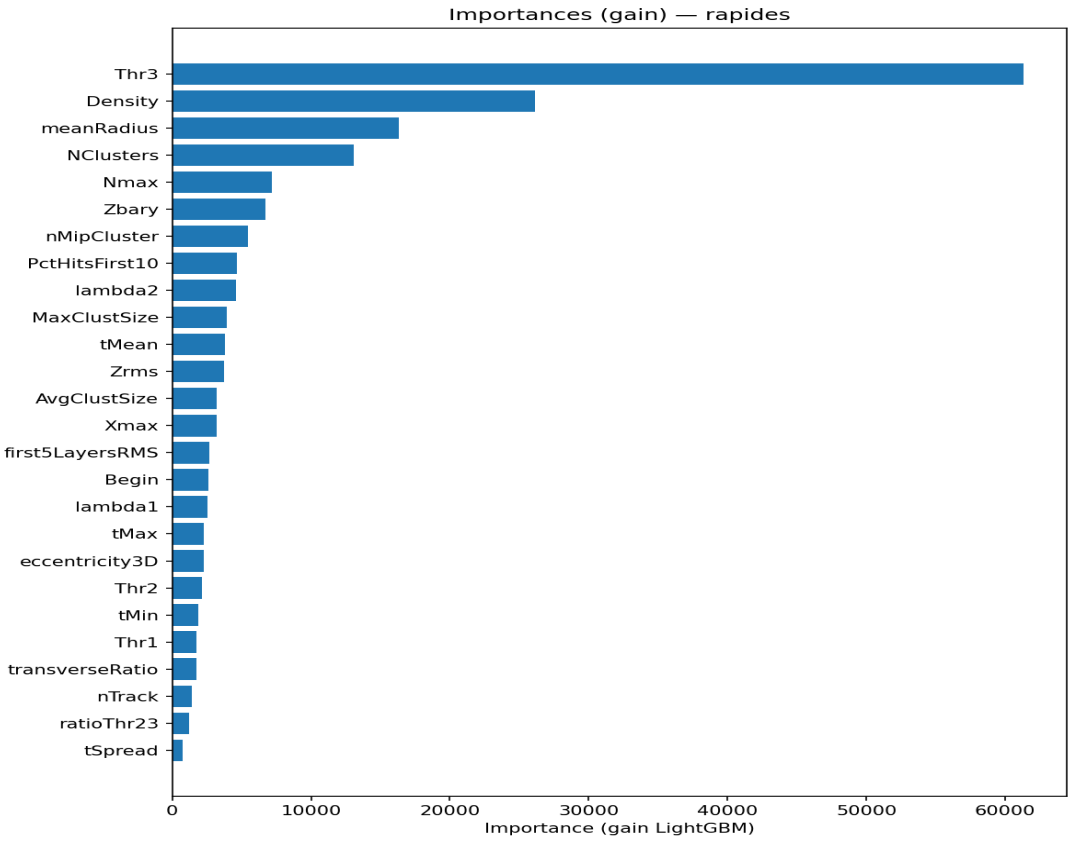



**FIGURE 3.3.** Importances des variables extraites du modèle LightGBM à partir du gain cumulé.

groupe `NClusters`, `Nmax`, `Zbary`, `nMipCluster` et `PctHitsFirst10`, qui traduisent la fragmentation de l'activité, la multiplicité locale et le développement longitudinal.

La séparation repose ainsi sur trois familles d'information : la **densité locale d'activité** (`Thr3`, `Density`), la **morphologie transverse** (`Radius`), et la **structuration longitudinale et la fragmentation** (`Zbary`, `NClusters`, `Nmax`). Ce constat est cohérent avec la physique des gerbes hadroniques dans un calorimètre hautement granulaire.

### 3.5.2 Limites et systématiques

**Robustesse vis-à-vis des effets instrumentaux.** La hiérarchie de variables décrite ci-dessus est physiquement plausible, mais elle a été établie dans des conditions de simulation idéalisées et doit être confirmée en conditions réalistes. Les performances reportées ne préjugent donc pas de celles qui seraient obtenues sur données réelles. Plusieurs non-idéalités sont susceptibles de dégrader la séparation, et leur impact n'a pas été quantifié dans ce travail : une résolution temporelle dégradée, des offsets de calibration entre couches, des variations des conditions de prise de données, des inefficacités locales ou un bruit électronique résiduel, ainsi que la présence de canaux défectueux ou instables. Ces effets touchent directement les observables les plus discriminantes — l'activité au seuil élevé et la densité locale dépendent de l'efficacité des chambres et de l'uniformité de la calibration. Une étude de sensibilité à ces non-idéalités constitue donc un préalable à toute transposition du classificateur vers les données de faisceau.

**Systématiques liées à la simulation.** Comme toute approche supervisée entraînée sur simulation, les performances mesurées dépendent du réalisme du modèle physique utilisé pour générer les gerbes hadroniques. Ce point constitue la limite la plus structurante de ce travail : le classificateur apprend les régularités de la simulation, et rien ne garantit a priori que celles-ci se retrouvent dans les données. L'impact du choix de la liste de physique hadronique de Geant4 [23] n'a pas été évalué ici, pas plus que celui des paramètres de réponse du détecteur, des inefficacités instrumentales, ou de la modélisation temporelle des signaux. Une comparaison entre plusieurs configurations de simulation, puis une confrontation aux données de test faisceau, seraient nécessaires pour estimer l'incertitude systématique associée au classificateur — d'autant que la séparation des $K_L^0$ repose précisément sur des différences de production d'étrangeté, dont la modélisation varie selon les listes de physique.

**Prolongements sur ce chapitre.** Deux prolongements immédiats se dégagent de cette analyse : une étude d'ablation par groupes de variables (densité, longitudinal, transverse, temps), qui permettrait de vérifier que le pouvoir discriminant repose bien sur les observables identifiées et de tester explicitement l'impact du retrait des variables temporelles. L'interprétabilité du modèle pourrait par ailleurs être approfondie à l'aide de méthodes locales telles que SHAP, afin de passer d'une importance globale à une explication événement par événement. Les autres axes d'optimisation envisagés sont détaillés en Annexe B.5.

La principale limite de l'approche reste toutefois l'utilisation de variables agrégées : bien que physiquement motivées, elles ne restituent qu'une partie de la richesse spatiale et temporelle des hits bruts, ce qui motive l'exploration présentée dans la section suivante.

## 3.6 Étude exploratoire : approche GNN

Les descripteurs globaux utilisés jusqu'ici ne conservent qu'une partie de l'information spatiale et temporelle contenue dans la topologie fine des gerbes. Une étude exploratoire a donc été engagée à l'aide de réseaux de neurones graphiques (*Graph Neural Networks*, GNN) [30, 31, 7], où chaque événement est représenté par un graphe de hits. Des variantes binaires et multiclasses ont été développées ; leur principe est détaillé en Annexe C.

Cette piste, engagée en fin de stage, a permis de mettre en place la représentation des événements sous forme de graphes et une première chaîne d'apprentissage. Son niveau de maturité ne permettait cependant pas encore une comparaison quantitative contrôlée avec LightGBM. Elle est donc présentée comme une étude de faisabilité, destinée à être poursuivie avec des échantillons, des découpages et des conditions instrumentales identiques à ceux de l'approche tabulaire.

# Chapitre 4

# Reconstruction de l'énergie

## 4.1 Enjeux dans un calorimètre semi-digital

La reconstruction de l'énergie d'une gerbe hadronique est limitée par les fluctuations de la première interaction, de la fraction électromagnétique, des pertes invisibles et des fuites. Dans le SDHCAL, la lecture à trois seuils ajoute une discrétisation de la charge et une saturation locale dans les régions denses. En revanche, la forte granularité fournit des informations de forme susceptibles de corriger une partie de ces fluctuations.

Deux estimateurs sont comparés : une calibration paramétrique fondée sur les nombres de hits aux trois seuils, et une régression LightGBM exploitant un ensemble plus large de descripteurs de gerbe. Les comparaisons entre scénarios sont rassemblées au chapitre 5.

## 4.2 Données disponibles et protocole d'évaluation

L'étude utilise des simulations de pions, de protons et de $K_L^0$ entre 1 et 130 GeV. Pour l'étude binaire pion/proton, environ $2 \times 10^5$ événements par espèce sont disponibles. Les modèles sont évalués sur des événements distincts de ceux employés pour l'entraînement. Les performances énergétiques sont décrites par le biais relatif

$$\delta(E) = \frac{\langle E_{\mathrm{reco}} \rangle - E_{\mathrm{true}}}{E_{\mathrm{true}}} \tag{4.1}$$

et par la dispersion du résidu relatif autour de sa valeur moyenne. Une valeur positive de $\delta$ traduit une surestimation de l'énergie, une valeur négative une sous-réponse. La procédure historique de calcul de la largeur retient le cœur central de la distribution ; elle convient à la comparaison interne des scénarios, mais les valeurs correspondantes ne sont pas utilisées ici comme mesure absolue de $\sigma(E)/E$.

## 4.3 Méthode paramétrique par comptage de seuils

Pour chaque événement, $N_1$, $N_2$ et $N_3$ désignent les nombres de hits attribués aux trois seuils semi-digitaux, et $N_{\mathrm{hit}} = N_1 + N_2 + N_3$. L'estimateur utilisé est

$$E_{\mathrm{reco}} = \alpha(N_{\mathrm{hit}})N_1 + \beta(N_{\mathrm{hit}})N_2 + \gamma(N_{\mathrm{hit}})N_3, \tag{4.2}$$

avec des poids quadratiques en $N_{\mathrm{hit}}$, par exemple

$$\alpha(N_{\mathrm{hit}}) = a_0 + a_1 N_{\mathrm{hit}} + a_2 N_{\mathrm{hit}}^2, \tag{4.3}$$

et des expressions analogues pour $\beta$ et $\gamma$, soit neuf coefficients ajustés sur simulation. Cette forme conserve une interprétation directe des trois seuils, mais elle ne peut exploiter toute l'information spatiale et temporelle du détecteur.

## 4.4 Ajustement des paramètres par minimisation d'une fonction pondérée

Pour une espèce donnée, les paramètres $\vec{\theta}$ sont obtenus en minimisant la fonction objectif

$$S(\vec{\theta}) = \sum_i \frac{\left[E_i^{\text{reco}}(\vec{\theta}) - E_i^{\text{true}}\right]^2}{E_i^{\text{true}}}. \tag{4.4}$$

Cette pondération limite la domination des événements de haute énergie dans l'ajustement. La méthode est désignée par convention comme méthode « $\chi^2$ » dans la suite, mais $S$ ne constitue pas un $\chi^2$ statistique au sens d'un test d'adéquation, son dénominateur n'étant pas une variance expérimentale.

Des calibrations distinctes peuvent ainsi être construites pour les pions, les protons et les kaons. Leur utilisation avec l'espèce vraie représente un cas idéal ; dans une chaîne réaliste, le choix de la calibration dépend du PID. Les détails d'implémentation sont décrits en Annexe E.

## 4.5 Résultats de la méthode paramétrique

Les Figures 4.1 et 4.2 présentent la méthode paramétrique appliquée sans routage par PID. Elles montrent l'évolution de la réponse moyenne et la diminution de la dispersion relative lorsque l'énergie augmente.

## 4.6 Régression LightGBM

La seconde approche apprend directement $E_{\text{true}}$ à partir des compteurs de seuils et de descripteurs de morphologie : activité totale, densité, développement longitudinal et extension transverse. Les modèles spécifiques à chaque espèce constituent le cas le plus favorable ; dans la chaîne complète, le classificateur sélectionne le modèle appliqué à l'événement.

Les résultats sont présentés Figures 4.3 et 4.4. Ils montrent que la régression fournit une réponse exploitable sur le domaine énergétique étudié.

## 4.7 Comparaison et portée des résultats

La méthode paramétrique est compacte, rapide et interprétable ; la régression peut exploiter des corrélations plus riches, au prix d'une dépendance accrue à la simulation et au domaine d'entraînement. Le choix de l'estimateur modifie surtout la linéarité, tandis que les différences de dispersion entre scénarios restent plus limitées. Le chapitre 5, établi à 20 et 80 GeV, compare ces effets sur un échantillon contenant plusieurs espèces.

### 4.7.1 Paramétrisation de la résolution

Une résolution calorimétrique est souvent ajustée par

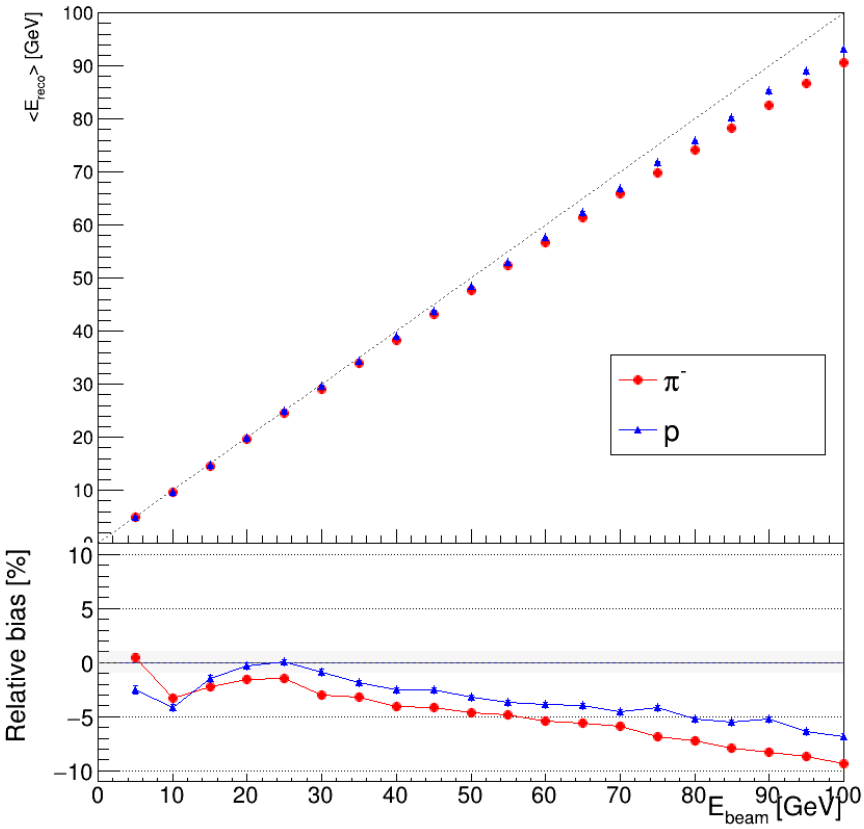



**FIGURE 4.1.** Linéarité et biais relatif de la calibration paramétrique.

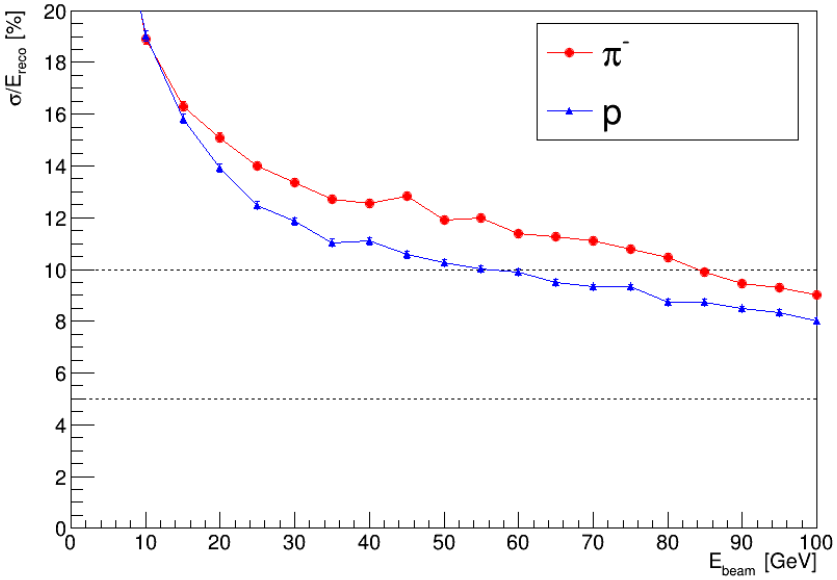



**FIGURE 4.2.** Indicateur de dispersion relative obtenu avec la calibration paramétrique.

$$\frac{\sigma(E)}{E} = \frac{a}{\sqrt{E/\mathrm{GeV}}} \oplus b. \tag{4.5}$$

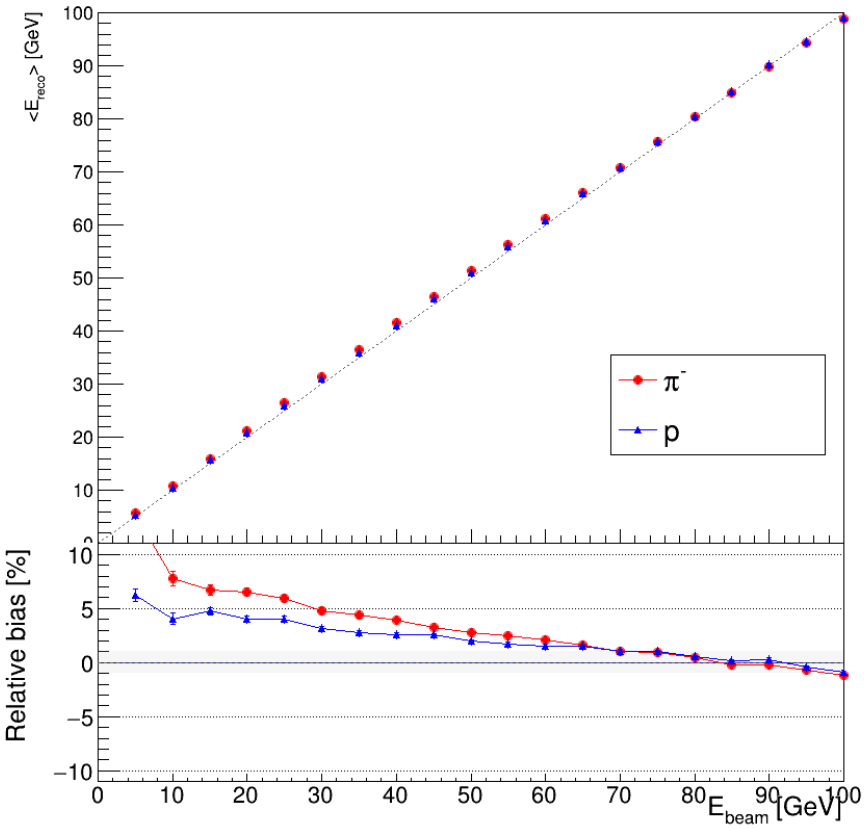



**FIGURE 4.3.** Linéarité et biais relatif de la régression LightGBM.

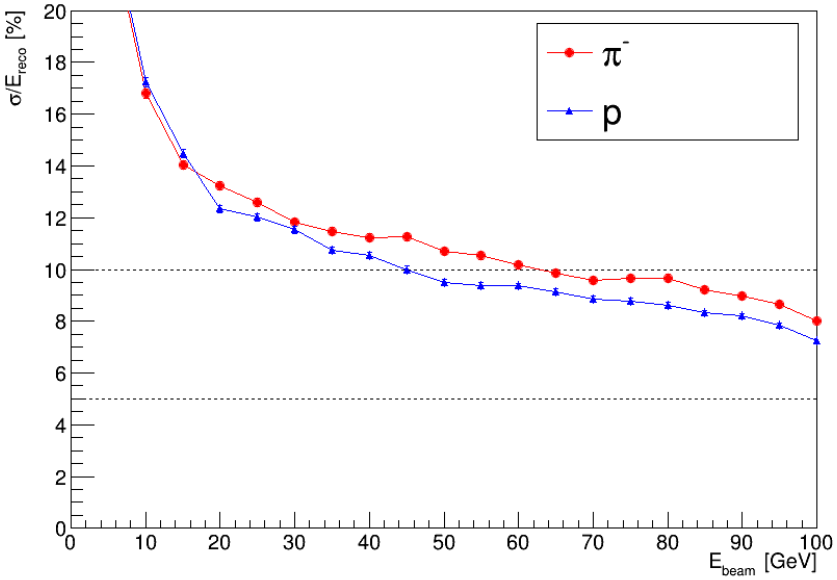



**FIGURE 4.4.** Indicateur de dispersion relative obtenu avec la régression LightGBM.

Un ajustement fiable de $a$ et $b$ exige une estimation non biaisée de la largeur dans chaque tranche d'énergie ainsi que ses incertitudes. Ces paramètres ne sont donc pas extraits des courbes présentées

ici.

## 4.8 Limites et systématiques

Les résultats reposent entièrement sur simulation. Leur transfert aux données réelles dépend de la modélisation des interactions hadroniques, du bruit, des inefficacités, de la calibration des chambres et des fuites. Une validation expérimentale demanderait donc de confronter les distributions d'entrée et les performances à des données de faisceau, en conservant le même protocole d'entraînement et d'évaluation. L'analyse des mélanges d'espèces est développée au chapitre suivant.

# Chapitre 5

# Analyse sur échantillons mixtes

## 5.1 Motivation et scénarios comparés

Lorsque l'espèce incidente n'est pas connue, l'utilisation d'une calibration spécialisée exige d'abord une décision de PID. Une erreur de classification route alors l'événement vers un estimateur inadapté et peut déplacer l'échelle d'énergie. Trois scénarios sont comparés :

(i) une calibration paramétrique déterminée sur les pions puis appliquée à toutes les espèces, notée $\chi^2$ **pion vers tous** ;

(ii) le classificateur BDT suivi de la calibration paramétrique de la classe prédite, noté **BDT +** $\chi^2$ ;

(iii) le même classificateur suivi d'une régression d'énergie BDT spécifique à la classe prédite, noté **BDT + BDT**.

Le premier scénario est une référence simple correspondant à l'application universelle de la calibration pion. Il ne constitue pas une borne inférieure mathématique et ne doit pas être interprété comme le meilleur estimateur possible sans PID. Les deux autres scénarios incluent les erreurs du classificateur.

## 5.2 Chaîne PID + régression BDT

Dans cette chaîne, chaque événement est classé puis traité par le régresseur associé à la classe prédite. Les résultats de linéarité et de dispersion sont donnés Figures 5.1 et 5.2.

## 5.3 Chaîne PID + méthode paramétrique

Le scénario BDT + $\chi^2$ utilise le même routage, mais applique ensuite la calibration analytique de l'équation 4.2. Les figures correspondantes sont reportées en Annexe E.4. Cette séparation entre classification et calibration conserve une interprétation simple de l'estimateur, mais reste directement sensible aux confusions entre espèces.

## 5.4 Référence pion appliquée à toutes les espèces

La référence $\chi^2$ pion vers tous applique une unique calibration à l'ensemble du mélange, sans décision de PID. Les résultats sont donnés Figures 5.3 et 5.4. Ils illustrent le biais introduit lorsque la réponse d'une espèce est reconstruite avec une calibration déterminée sur une autre.

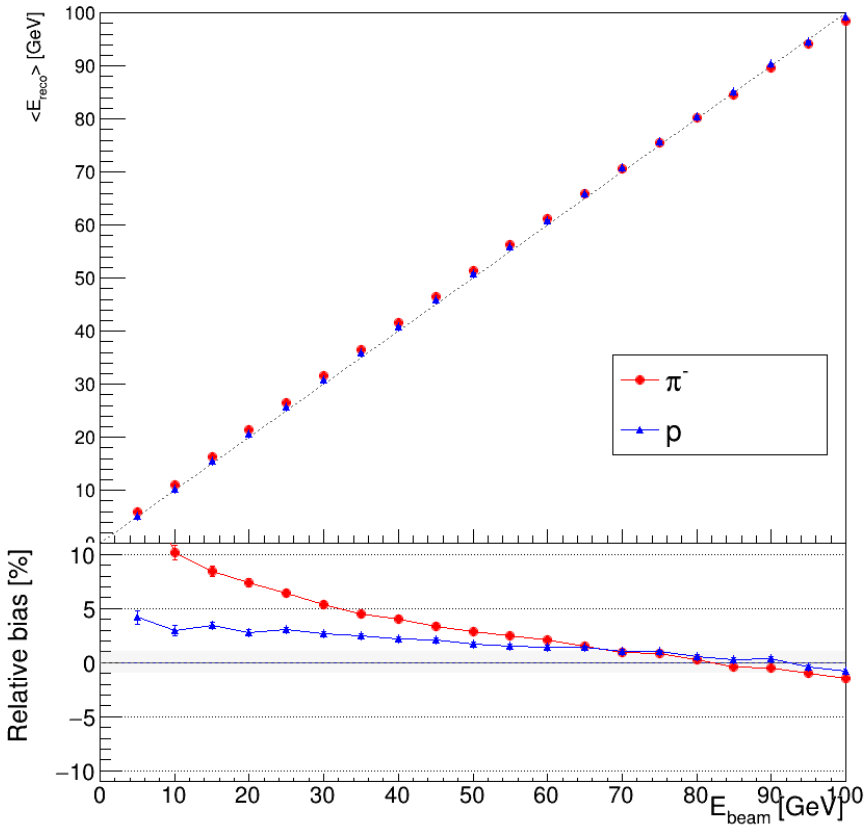



**FIGURE 5.1.** Linéarité et biais relatif de la chaîne PID + BDT.

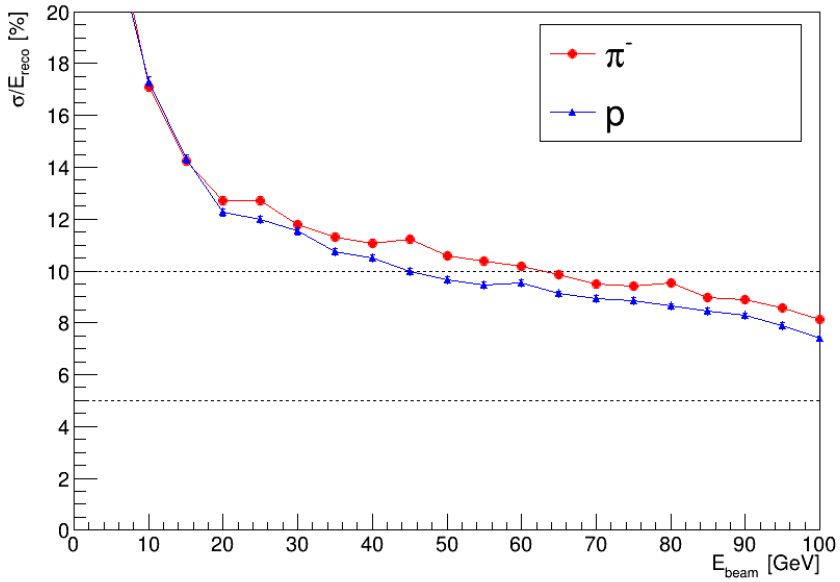



**FIGURE 5.2.** Indicateur de dispersion relative de la chaîne PID + BDT.

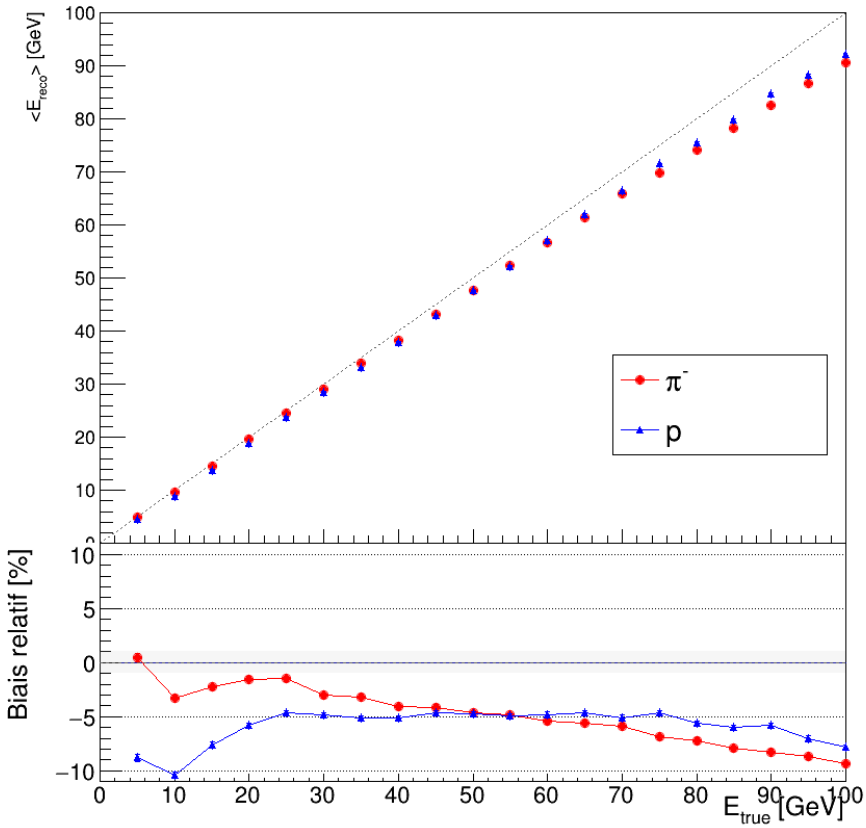



**FIGURE 5.3.** Linéarité et biais relatif avec la calibration paramétrique pion appliquée à toutes les espèces.

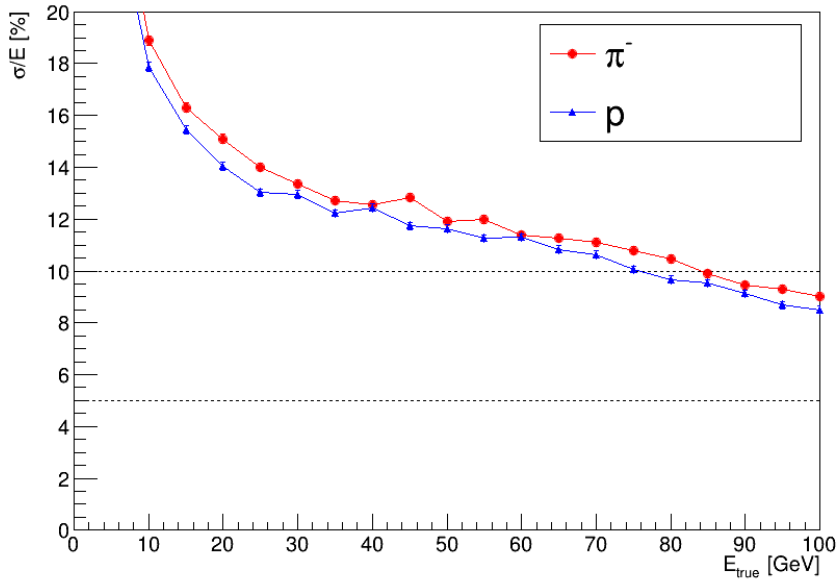



**FIGURE 5.4.** Indicateur de dispersion relative avec la calibration paramétrique pion appliquée à toutes les espèces.

## 5.5 Comparaison quantitative à 20 et 80 GeV

Le Tableau 5.1 rassemble les biais calculés à partir des prédictions événement par événement. Les valeurs sont arrondies à 0.1 point de pourcentage.

**TABLE 5.1.** Biais relatif $\delta(E)$ en pourcentage à 20 et 80 GeV.

| | $\pi^-$ | | $K_L^0$ | | $p$ | |
|---|---|---|---|---|---|---|
| **Scénario** | 20 | 80 | 20 | 80 | 20 | 80 |
| $\chi^2$ pion vers tous | −0.7 | −4.9 | −6.4 | −5.6 | −6.8 | −4.8 |
| BDT + $\chi^2$ | +2.8 | −4.7 | −2.9 | −5.2 | −1.7 | −4.3 |
| BDT + BDT | +7.1 | +0.9 | +6.3 | 0.0 | +3.0 | 0.0 |

Le résultat principal concerne le biais. À 20 GeV, le routage BDT + $\chi^2$ rapproche les protons et les kaons de zéro par rapport à la calibration pion universelle, mais déplace le biais des pions de −0.7 % à +2.8 %. À 80 GeV, ses gains restent modestes. La chaîne BDT + BDT conduit à des biais positifs plus importants à 20 GeV, mais ramène les trois espèces à moins de 1 % de biais à 80 GeV.

Les courbes de dispersion diminuent avec l'énergie et restent proches entre les trois scénarios. Comme leur largeur a été estimée sur le cœur tronqué des distributions, elles sont utilisées pour une comparaison qualitative et non pour quantifier un gain absolu de résolution. L'effet le plus net du PID dans cette étude concerne donc le contrôle de l'échelle d'énergie.

## 5.6 Limites de l'analyse

Cette comparaison ne permet pas d'isoler séparément le gain d'un PID parfait, le coût des erreurs de classification et le gain propre à chaque régresseur, car toutes les combinaisons correspondantes n'ont pas été étudiées. Elle ne compare pas non plus les chaînes à un estimateur inclusif optimisé sans PID. Il serait donc excessif de conclure que le PID surpasse systématiquement toute méthode indépendante de l'espèce.

La stabilité des résultats vis-à-vis de la composition du mélange et des incertitudes systématiques de simulation reste à étudier. Les résultats établissent néanmoins une tendance cohérente : l'information d'espèce peut réduire certains biais de calibration, tandis que les dispersions restent dominées par les fluctuations intrinsèques des gerbes.

# Conclusion générale

Ce mémoire étudie deux problèmes couplés dans le SDHCAL : l'identification de l'espèce hadronique et la reconstruction de son énergie. La granularité du détecteur et sa lecture semi-digitale donnent accès à la densité et à la morphologie des gerbes, mais la stochasticité des interactions hadroniques limite la séparation des espèces et la précision énergétique.

Pour le **PID multiclasse**, le modèle LightGBM atteint une accuracy équilibrée de 67.8 %. Les rappels sont de 48.8 % pour les pions, 68.6 % pour les protons et 86.0 % pour les $K_L^0$. La difficulté principale est la confusion pion/proton : 47.9 % des pions sont classés comme protons. Dans l'étude binaire employée pour la reconstruction d'énergie, l'accuracy globale est proche de 61 %, avec 49.1 % de pions et 73.0 % de protons correctement identifiés. L'analyse des variables montre que la séparation repose principalement sur l'activité au troisième seuil, la densité locale et la morphologie de la gerbe.

Pour la **reconstruction d'énergie**, deux familles d'estimateurs ont été étudiées : la calibration paramétrique fondée sur les compteurs aux trois seuils et une régression BDT exploitant davantage de descripteurs. À 20 et 80 GeV, l'apport du PID se lit surtout sur le biais. Par exemple, pour les protons à 20 GeV, le biais passe de −6.8 % avec la calibration pion universelle à −1.7 % avec BDT + $\chi^2$, puis à +3.0 % avec BDT + BDT. À 80 GeV, la chaîne BDT + BDT maintient le biais des trois espèces en dessous de 1 %. Les courbes de dispersion sont proches entre scénarios ; elles ne permettent pas d'attribuer au PID un gain absolu de résolution avec la même précision que pour le biais.

Ces résultats ne démontrent pas qu'un routage par PID surpasse tout estimateur inclusif : la référence disponible est une calibration pion appliquée à toutes les espèces, et non un modèle sans PID optimisé sur le mélange. Ils indiquent néanmoins que la connaissance, même imparfaite, de l'espèce peut corriger une partie des décalages d'échelle dus à une calibration universelle.

La portée de ces résultats reste celle d'une étude sur simulation. Une validation sur données de faisceau et une évaluation des incertitudes liées au modèle hadronique, à la réponse du détecteur et à la composition des échantillons seront nécessaires avant toute conclusion expérimentale.

# Perspectives

Une première perspective consiste à mesurer séparément la performance d'un estimateur inclusif sans PID, le gain maximal obtenu avec l'espèce vraie et la dégradation introduite par les erreurs du classificateur. Cette comparaison devra conserver les mêmes sélections et le même échantillon de test pour l'ensemble des méthodes, et inclure les incertitudes statistiques associées.

Le PID pion/proton reste le principal verrou. Des performances par tranche d'énergie, une calibration des probabilités et une étude d'ablation systématique des groupes de variables permettraient de mieux comprendre la séparation. Pour la reconstruction, un modèle inclusif prenant les probabilités de classes comme entrées éviterait un routage discontinu et pourrait exploiter l'incertitude du PID.

L'approche GNN demeure une piste exploratoire pour utiliser directement les hits. Une reprise de cette étude devra comparer les architectures à données, découpages et résolutions temporelles identiques, afin d'établir si la représentation en graphes apporte une information supplémentaire par rapport aux variables construites.

Enfin, toute conclusion expérimentale exige une confrontation aux données de faisceau et une étude des systématiques : liste de physique Geant4, bruit, inefficacités, calibrations, stabilité temporelle et composition du faisceau. C'est à cette condition que les méthodes développées pourront être intégrées de manière crédible à une chaîne de reconstruction de type *Particle Flow* [5].

# Annexe A

# Descripteurs de gerbe : définitions

## A.1 Principe et inventaire

Toutes les analyses de ce mémoire reposent sur des variables physiques dérivées des hits enregistrés dans le SDHCAL. Ces *descripteurs de gerbe* sont calculés par un outil dédié développé en `C++`, `ShowerAnalyzer`, dont le rôle est de transformer la description brute d'un événement — une liste de hits élémentaires

$$(I_i,\ J_i,\ K_i,\ x_i,\ y_i,\ z_i,\ t_i,\ \mathrm{thr}_i)$$

— en un ensemble réduit d'observables caractérisant la composition en seuils semi-digitaux, la topologie spatiale, le développement longitudinal, la compacité transverse, la structure temporelle et les éventuelles sous-structures internes. Ces variables constituent les entrées des modèles de PID et de reconstruction d'énergie.

Les fichiers simulés sont lus au format `ROOT`, chaque événement fournissant les indices de cellule `I`, `J`, l'indice de couche `K`, les positions `x`, `y`, `z`, le temps du hit, le seuil franchi, ainsi que la vérité Monte-Carlo `particle1PDG`. Les variables calculées sont ajoutées comme nouvelles branches d'un arbre enrichi, qui alimente ensuite les analyses.

Le pipeline produit les observables suivantes :

| | | | |
|---|---|---|---|
| `Thr1` | `Thr2` | `Thr3` | `Begin` |
| `Radius` | `Density` | `NClusters` | `ratioThr23` |
| `Zbary` | `Zrms` | `PctHitsFirst10` | `PlanesWithClusmore2` |
| `AvgClustSize` | `MaxClustSize` | `lambda1` | `lambda2` |
| `N1` | `N2` | `N3` | `tMin` |
| `tMax` | `tMean` | `tSpread` | `Nmax` |
| `z0_fit` | `Xmax` | `lambda` | `nTrackSegments` |
| `eccentricity3D` | `nHitsTotal` | `sumThrTotal` | |

Les sections suivantes définissent chaque famille : formule, notation employée dans le code, et sens physique.

## A.2 Variables liées aux seuils semi-digitaux

Le SDHCAL repose sur une lecture *semi-digitale* à trois seuils, permettant de distinguer différents niveaux de charge déposée dans une cellule active. Chaque hit est associé à une valeur discrète $\mathrm{thr}_i \in \{1,2,3\}$ correspondant à un dépôt faible, intermédiaire ou élevé. Cette information constitue une approximation de la densité locale d'ionisation, donc indirectement de l'intensité du dépôt d'énergie. Les variables construites à partir de ces seuils sont rassemblées dans le Tableau A.1.

**TABLE A.1.** Descripteurs construits à partir de la lecture semi-digitale à trois seuils. $N_{\text{hits}}$ désigne le nombre total de hits de l'événement.

| Variable | Définition | Sens physique |
|---|---|---|
| `N1`, `N2`, `N3` | $N_j = \#\{i \mid \text{thr}_i = j\}$ | Répartition brute des hits selon leur intensité. |
| `nHitsTotal` | $N_{\text{hits}} = N_1 + N_2 + N_3$ | Activité globale de la gerbe. |
| `Thr1`, `Thr2`, `Thr3` | $100 \times N_j / N_{\text{hits}}$ | Composition relative de la gerbe, indépendante de la multiplicité totale. |
| `ratioThr23` | $\frac{\texttt{Thr2} + \texttt{Thr3}}{\texttt{Thr1}}$ | Variable de dureté : compare les hits « énergétiques » aux hits de faible amplitude. Une valeur élevée traduit une gerbe plus dense, des dépôts plus localisés, une composante électromagnétique plus marquée ou une interaction hadronique plus violente. |
| `sumThrTotal` | $N_1 + 2N_2 + 3N_3$ | Estimateur simple de l'énergie visible totale, supérieur au simple comptage $N_{\text{hits}}$ car il valorise les hits de seuil élevé. |

Ces variables conservent l'information spécifique au mode semi-digital du SDHCAL et permettent de distinguer les gerbes diffuses riches en seuil 1, les gerbes compactes présentant un excès de seuils 2 et 3, les événements peu énergétiques contenant peu de hits, et les dépôts saturés à haute énergie. Dans les modèles d'apprentissage supervisé présentés dans ce mémoire, $N_1$, $N_3$ et `sumThrTotal` figurent parmi les variables les plus importantes pour la reconstruction d'énergie.

## A.3 Descripteurs longitudinaux

Le développement longitudinal d'une gerbe hadronique constitue une source majeure d'information physique : la profondeur de première interaction, la vitesse de croissance de la cascade et son étalement dans le détecteur diffèrent selon la particule incidente et son énergie. Le `ShowerAnalyzer` calcule les observables du Tableau A.2 à partir de l'indice de couche $K$, utilisé comme proxy de la coordonnée en profondeur.

Ces variables longitudinales sont centrales pour l'identification pion/proton, la séparation des espèces neutres et chargées, la reconstruction d'énergie et la détection de fuites longitudinales à haute énergie. Dans les modèles LightGBM étudiés, `Begin`, `Zbary` et `PctHitsFirst10` apparaissent régulièrement parmi les descripteurs les plus informatifs.

## A.4 Descripteurs transverses et géométriques

Au-delà du développement longitudinal, la forme transverse contient une information importante : deux particules de même énergie peuvent produire des signatures spatiales très différentes — gerbe compacte, diffuse, allongée, fragmentée ou multi-cœur. Les observables correspondantes sont définies dans le Tableau A.3.

Le rayon effectif s'appuie sur un axe de gerbe reconstruit au préalable : les barycentres des premières couches actives sont ajustés par deux droites $x(z) = a_1 z + b_1$ et $y(z) = a_2 z + b_2$, qui définissent la trajectoire moyenne. La distance transverse de chaque hit à cet axe, $d_i^2 = (x_i - x_0)^2 + (y_i - y_0)^2$, fournit ensuite le rayon quadratique moyen.

Ces variables permettent de distinguer une gerbe hadronique compacte d'une interaction diffuse, de repérer les événements contenant plusieurs sous-gerbes, de caractériser la direction dominante du

**TABLE A.2.** Descripteurs du développement longitudinal. $h(K)$ désigne le nombre de hits enregistrés dans la couche $K$.

| Variable | Définition | Sens physique |
|---|---|---|
| `Zbary` | $\frac{1}{N_{\text{hits}}}\sum_i K_i$ | Profondeur moyenne de dépôt. Une valeur faible indique un développement précoce, une valeur élevée une interaction plus tardive ou une pénétration plus profonde. |
| `Zrms` | $\sqrt{\frac{1}{N_{\text{hits}}}\sum_i (K_i - Z_{\text{bary}})^2}$ | Largeur longitudinale de la gerbe : dépôt concentré (faible valeur) ou gerbe étendue et fluctuante (grande valeur). |
| `Begin` | $\min L$ tel que $h(L+k) \geq 4,\ k = 0..3$ | Profondeur de première interaction hadronique, estimée par la première séquence de quatre couches consécutives contenant chacune au moins quatre hits ; valeur sentinelle 48 si aucune séquence n'est trouvée. Particulièrement discriminante : les pions interagissent souvent plus tôt, les protons peuvent pénétrer davantage, et les fluctuations hadroniques modulent fortement cette profondeur. |
| `PctHitsFirst10` | $100 \times \frac{\#\{i \mid 0 \leq K_i \leq 9\}}{N_{\text{hits}}}$ | Part initiale de la gerbe. Une valeur élevée signale une interaction rapide, un fort dépôt initial ou une composante électromagnétique marquée. |

**TABLE A.3.** Descripteurs transverses et géométriques. $\mathbf{C}$ désigne la matrice de covariance transverse des hits et $(e_1 \leq e_2 \leq e_3)$ les valeurs propres de la covariance complète sur $(x, y, z)$.

| Variable | Définition | Sens physique |
|---|---|---|
| `Radius` | $\sqrt{\frac{1}{N_{\text{hits}}}\sum_i d_i^2}$ | Écartement moyen des hits autour de l'axe de gerbe : petite valeur pour une gerbe étroite et collimatée, grande valeur pour une gerbe diffuse ou fortement latérale. |
| `lambda1`, `lambda2` | valeurs propres de $\mathbf{C}$, $\lambda_1 \geq \lambda_2$ | Forme du dépôt dans le plan transverse : $\lambda_1 \simeq \lambda_2$ pour une forme circulaire, $\lambda_1 \gg \lambda_2$ pour une structure allongée, deux valeurs faibles pour une gerbe compacte. |
| `eccentricity3D` | $\frac{e_3}{e_1 + e_2 + e_3}$ | Anisotropie tridimensionnelle, comprise entre 0 et 1 : proche de 1 pour une structure quasi linéaire, plus faible pour un développement volumique étendu. |

dépôt et d'améliorer la reconstruction d'énergie via la corrélation entre forme et confinement.

## A.5 Densité locale et structure en amas

La seule multiplicité des hits ne suffit pas à décrire une gerbe : deux événements de même nombre total de coups peuvent présenter des organisations internes très différentes — dépôt compact, structure fragmentée, zones vides, sous-cœurs multiples. Deux mécanismes sont utilisés pour capturer cette information.

La **densité locale pondérée** considère, pour chaque hit $i$, les cellules voisines dans un carré $3 \times 3$ de la même couche ($|I_j - I_i| \leq 1$, $|J_j - J_i| \leq 1$, $K_j = K_i$). Chaque voisin contribue avec un poids dépendant du seuil franchi, $w = 1$, 45.45 et 136.36 pour les seuils 1, 2 et 3 respectivement, ce qui reflète la charge typique associée à chaque niveau.

Le **clustering intra-couche** traite chaque couche active comme une grille 2D indépendante et

regroupe les hits adjacents en amas par 4-connexité, $(\Delta I, \Delta J) \in \{(\pm 1, 0), (0, \pm 1)\}$, le regroupement étant réalisé par exploration de graphe. Les variables extraites sont rassemblées dans le Tableau A.4.

**TABLE A.4.** Descripteurs de densité locale et de structure en amas. $\mathcal{V}(i)$ désigne le voisinage $3 \times 3$ du hit $i$ dans sa couche, $n_c$ le nombre de hits de l'amas $c$.

| Variable | Définition | Sens physique |
|---|---|---|
| `Density` | $\frac{\sum_i C_i}{\sum_i w(\mathrm{thr}_i)}, \quad C_i = \sum_{j \in \mathcal{V}(i)} w(\mathrm{thr}_j)$ | Densité locale moyenne : valeur élevée pour des zones denses et un cœur marqué, faible pour une gerbe diffuse. Sensible aux concentrations locales d'énergie ; elle s'est révélée importante dans plusieurs modèles de PID et de régression. |
| `NClusters` | $\sum_K N_{\mathrm{clusters}}(K)$ | Fragmentation globale de la gerbe. |
| `MaxClustSize` | $\max_c n_c$ | Taille du plus gros cœur local. |
| `AvgClustSize` | $\frac{1}{N_{\mathrm{clusters}}} \sum_c n_c$ | Taille typique des amas. |
| `PlanesWithClusmore2` | nombre de couches à $\geq 2$ amas | Multiplicité de sous-structures dans une même couche. |

Ces observables séparent les gerbes compactes dominées par un seul cœur des topologies fragmentées, des interactions secondaires multiples et des événements mal contenus, qui montrent souvent plusieurs amas dispersés. Un proton produit typiquement une gerbe plus dense et structurée, un pion davantage de fluctuations et de sous-amas. Dans les arbres boostés utilisés ici, `AvgClustSize`, `MaxClustSize` et `Density` figurent régulièrement parmi les variables utiles, car elles relient directement morphologie locale et nature de la particule incidente.

## A.6 Variables temporelles

La simulation fournit une information temporelle hit par hit, complémentaire de la topologie spatiale : temps de vol de la particule incidente, chronologie du développement hadronique, composantes retardées dues aux neutrons secondaires, étalement temporel de la gerbe. Quatre observables simples en sont extraites (Tableau A.5).

**TABLE A.5.** Descripteurs temporels. $N_t$ désigne le nombre de hits temporellement valides.

| Variable | Définition | Sens physique |
|---|---|---|
| `tMin` | $\min_i(t_i)$ | Premier hit de l'événement : sensible au temps de vol initial, donc à la masse de la particule à impulsion donnée, et corrélé à la profondeur de première interaction. Figure parmi les variables les plus importantes de l'étude PID. |
| `tMax` | $\max_i(t_i)$ | Hit le plus tardif : sensible aux composantes lentes — diffusion neutronique, interactions secondaires retardées, traînes temporelles longues. |
| `tMean` | $\frac{1}{N_t} \sum_i t_i$ | Position moyenne de la distribution temporelle. |
| `tSpread` | `tMax` − `tMin` | Durée totale de l'activité : faible pour un dépôt rapide et compact, grande pour une activité étalée dans le temps. |

Les différences pion/proton observées dans ce travail proviennent en partie de l'écart de masse $m_p \gg m_\pi$, qui produit à énergie comparable des temps de vol distincts. Une réserve importante s'attache toutefois à ces variables : la résolution temporelle native de la simulation est extrêmement fine, et un *smearing* gaussien a été appliqué dans plusieurs analyses afin de reproduire des conditions

instrumentales réalistes. Ce point est déterminant pour `tMin`, dont une précision irréaliste renforce artificiellement les performances de classification — comme le montre l'étude GNN de la section 3.6.

## A.7 Profil longitudinal et ajustement de Gaisser–Hillas

Au-delà de `Begin` ou `Zbary`, la forme longitudinale peut être modélisée finement. Un profil est reconstruit couche par couche en sommant les seuils, $E(K) \propto \sum_{i \in K} \mathrm{thr}_i$, le seuil semi-digital servant de proxy du dépôt d'énergie. Un point de départ est estimé au préalable comme la première couche présentant une activité soutenue sur plusieurs plans successifs, ce qui écarte les hits isolés, les pré-coups marginaux et les fluctuations non représentatives ; le profil peut ensuite être lissé par moyenne glissante. Il est ajusté par une fonction inspirée du formalisme de Gaisser–Hillas :

$$E(z) = N_{\max} \left( \frac{z - z_0}{X_{\max} - z_0} \right)^{\frac{X_{\max} - z_0}{\lambda}} \exp\left( \frac{X_{\max} - z}{\lambda} \right),$$

où $z$ est la profondeur et $z_0$ le point de départ effectif. Les quatre paramètres ajustés constituent les variables extraites (Tableau A.6).

**TABLE A.6.** Variables issues de l'ajustement de Gaisser–Hillas du profil longitudinal.

| Variable | Paramètre | Sens physique |
|---|---|---|
| `Nmax` | $N_{\max}$ | Amplitude maximale du profil : corrélée à l'énergie incidente et sensible à la compacité du cœur de gerbe. |
| `z0_fit` | $z_0$ | Origine effective de la cascade ; affine l'information portée par `Begin`. |
| `Xmax` | $X_{\max}$ | Position du maximum longitudinal : précoce pour une interaction rapide, tardive pour un développement plus profond. |
| `lambda` | $\lambda$ | Extension de la gerbe : contrôle la largeur et la décroissance après le maximum. |

Ces paramètres condensent la structure complète du profil et servent à l'identification, à la reconstruction d'énergie et à la séparation des gerbes compactes et étalées. L'ajustement reste toutefois instable lorsque peu de couches sont actives, à basse énergie, lorsque la gerbe est tronquée par fuite ou lorsque plusieurs sous-cascades se superposent ; dans ces cas, les variables plus robustes (`Begin`, `Zbary`, `PctHitsFirst10`) restent plus performantes. Dans les analyses LightGBM, leur pouvoir prédictif s'est révélé secondaire par rapport à `tMin`, `sumThrTotal`, $N_1$, $N_3$ ou `Density`, tout en apportant une information complémentaire sur la morphologie profonde.

## A.8 Recherche de segments quasi-linéaires

Une gerbe hadronique n'est pas uniquement un dépôt diffus : elle peut contenir des structures localement rectilignes — traces de secondaires chargés, fragments pénétrants, trajectoire résiduelle du primaire, sous-cascades collimatées. La granularité du SDHCAL permet de les identifier géométriquement, ce que quantifie la variable `nTrackSegments`.

La procédure comporte quatre étapes. Les hits de chaque couche sont d'abord regroupés par 8-connexité ($|\Delta I| \leq 1$, $|\Delta J| \leq 1$), chaque amas fournissant un barycentre $(x_c, y_c, z_c)$. Les amas trop volumineux ou situés dans des zones trop denses sont ensuite écartés, afin de ne pas confondre le cœur de gerbe avec une trajectoire isolée : seuls les petits amas compacts, spatialement séparés du cœur, sont

conservés. Une **transformée de Hough** est alors appliquée aux barycentres restants, projetés dans les plans $(z, x)$ et $(z, y)$, chaque maximum significatif de l'accumulateur correspondant à une trajectoire candidate. Les candidats sont enfin validés selon leur extension sur plusieurs couches, leur continuité, l'absence de grands trous, la faiblesse des résidus autour de la droite ajustée et leur non-concentration dans les seules premières couches. Le nombre de structures validées définit `nTrackSegments`.

Une valeur élevée signale plusieurs secondaires chargés énergétiques, une interaction riche en fragments ou une composante pénétrante importante; une valeur faible correspond à une gerbe dense sans trajectoire nette, à un dépôt fortement diffus ou à une énergie plus basse. Les protons produisent typiquement des topologies plus structurées, les pions davantage de fluctuations diffuses, et les événements neutres montrent moins de traces initiales nettes.

Cette reconstruction reste difficile dans une gerbe dense — confusion avec le cœur hadronique, superposition de trajectoires, inefficacités locales, sensibilité aux paramètres de clustering. Il s'agit donc d'un indicateur morphologique, non d'un traqueur dédié : moins dominant que les variables temporelles ou de comptage, il enrichit néanmoins les modèles supervisés testés.

## A.9 Hiérarchie des variables et tableau récapitulatif

Toutes ces variables ne contribuent pas avec la même intensité aux tâches étudiées. Pour la **séparation pion/proton**, les plus discriminantes dans les modèles LightGBM sont `tMin` (temps de vol), `Begin` (profondeur de première interaction), `Density` (compacité locale), `PctHitsFirst10` (activité précoce), `Zbary` (profondeur moyenne) et `AvgClustSize` (structure locale) : elles reflètent respectivement la cinématique de la particule incidente, la chronologie de l'interaction et la topologie interne de la cascade. Pour la **reconstruction d'énergie**, ce sont `sumThrTotal`, $N_1$, $N_3$, `nHitsTotal` et `Density` qui dominent, c'est-à-dire les observables directement liées à la quantité totale de signal et à sa concentration. Les descripteurs géométriques (`lambda1`, `lambda2`, `eccentricity3D`) et les paramètres de l'ajustement de Gaisser–Hillas jouent un rôle complémentaire, tandis que `nTrackSegments` reste le plus secondaire.

Le Tableau A.7 rassemble l'ensemble des descripteurs, leur signification physique et leur usage principal.

| Variable | Signification physique | Usage principal |
|---|---|---|
| **Variables de seuils semi-digitaux** | | |
| `N1, N2, N3` | Nombre de hits aux trois seuils | Reconstruction d'énergie |
| `Thr1, Thr2, Thr3` | Fractions relatives des seuils | PID / Morphologie |
| `sumThrTotal` | Somme pondérée des seuils | Énergie |
| `ratioThr23` | Dureté moyenne du dépôt | PID |
| `nHitsTotal` | Multiplicité totale | Énergie |
| **Descripteurs longitudinaux** | | |
| `Begin` | Première interaction visible | PID |
| `Zbary` | Profondeur moyenne de la gerbe | PID + Énergie |
| `Zrms` | Largeur longitudinale | PID |
| `PctHitsFirst10` | Fraction précoce des hits | PID |
| `Xmax` | Position du maximum longitudinal | Morphologie |
| `Nmax` | Intensité maximale de la gerbe | Énergie |
| `lambda` | Largeur du profil longitudinal | Morphologie |
| **Descripteurs transverses** | | |
| `Radius` | Rayon transverse effectif | PID |
| `lambda1, lambda2` | Axes principaux du dépôt | Morphologie |
| `eccentricity3D` | Allongement spatial global | Topologie |
| **Densité et amas** | | |
| `Density` | Compacité locale pondérée | PID + Énergie |
| `NClusters` | Nombre total d'amas | Topologie |
| `AvgClustSize` | Taille moyenne des amas | PID |
| `MaxClustSize` | Taille du plus grand amas | Morphologie |
| `PlanesWithClusmore2` | Plans contenant plusieurs amas | Fragmentation |
| **Variables temporelles** | | |
| `tMin` | Premier hit temporel | PID + Énergie |
| `tMax` | Dernier hit observé | Morphologie |
| `tMean` | Temps moyen de la gerbe | Complémentaire |
| `tSpread` | Durée totale de l'activité | PID |
| **Sous-structures internes** | | |
| `nTrackSegments` | Segments quasi-linéaires reconstruits | Topologie avancée |

**TABLE A.7.** Résumé des principaux descripteurs calculés par `ShowerAnalyzer` et de leur intérêt physique dans les analyses présentées dans ce mémoire.

Chaque observable possède ainsi une interprétation reliée aux mécanismes d'interaction hadronique, tout en fournissant un espace d'entrée compact et robuste pour les méthodes supervisées. Cette construction illustre qu'un calorimètre hautement granulaire ne se limite pas à mesurer une énergie totale : il fournit une image quadridimensionnelle de l'événement, exploitable soit par des variables construites manuellement comme ici, soit directement par des approches de type CNN ou GNN (section 3.6).

# Annexe B

# Configuration du classificateur PID

Cette annexe décrit la mise en œuvre du classificateur hadronique supervisé du chapitre 3 : jeux de données, prétraitement, protocole d'apprentissage et hyperparamètres.

## B.1 Jeux de données et variables d'entrée

Le classificateur est entraîné sur des fichiers simulés au format `ROOT`, enrichis par les variables calculées avec `ShowerAnalyzer` (Annexe A). Trois échantillons sont utilisés, un par espèce, contenant chacun environ $1.3 \times 10^5$ événements d'énergie primaire distribuée uniformément entre 1 GeV à 130 GeV ; ils sont concaténés pour former l'ensemble global d'apprentissage.

L'identité vraie de la particule est fournie par la variable `particlePDG`. Les codes retenus, $-211$, 2212 et 311, correspondent respectivement à $\pi^-$, $p$ et $K_L^0$, et sont convertis en labels entiers 0, 1 et 2 pour l'apprentissage.

Les 26 variables d'entrée sont issues de l'analyse topologique et calorimétrique des gerbes :

$$\begin{aligned}\mathscr{X} = \big[&\texttt{Thr1}, \texttt{Thr2}, \texttt{Thr3}, \texttt{Begin}, \texttt{Radius}, \texttt{Density}, \texttt{NClusters}, \texttt{ratioThr23},\\ &\texttt{Zbary}, \texttt{Zrms}, \texttt{PctHitsFirst10}, \texttt{PlanesWithClusmore2}, \texttt{AvgClustSize}, \texttt{MaxClustSize},\\ &\texttt{lambda1}, \texttt{lambda2}, \texttt{tMin}, \texttt{tMax}, \texttt{tMean}, \texttt{tSpread}, \texttt{Nmax}, \texttt{z0_fit},\\ &\texttt{Xmax}, \texttt{lambda}, \texttt{nTrackSegments}, \texttt{eccentricity3D}\big].\end{aligned}$$

Elles décrivent la composition en seuils et l'activité locale, le développement longitudinal, la compacité transverse, la fragmentation en amas, la structure temporelle et la présence éventuelle de traces secondaires internes. Cette représentation condense l'information brute hit par hit en un nombre limité de variables discriminantes.

## B.2 Nettoyage et prétraitement

Les tableaux extraits des fichiers `ROOT` sont d'abord inspectés pour éliminer les valeurs non physiques : les infinis positifs et négatifs sont remplacés par des valeurs manquantes, les lignes incomplètes supprimées et le tableau réindexé, ce qui évite la propagation d'erreurs numériques pendant l'apprentissage. Seuls les événements correspondant aux trois codes PDG retenus sont conservés ; les autres particules éventuellement présentes dans les arbres d'entrée sont exclues.

Un **smearing temporel** est ensuite appliqué. La résolution temporelle native de la simulation étant irréaliste, un bruit gaussien $\varepsilon \sim \mathcal{N}(0, \sigma^2)$, avec $\sigma = 0.1$ ns (soit 100 ps), est ajouté aux variables `tMin`, `tMax` et `tSpread`. Cette prescription fournit une échelle instrumentale réaliste pour l'étude, sans chercher ici

à isoler quantitativement la contribution propre de chaque observable temporelle.

Aucune normalisation explicite n'est nécessaire : les méthodes fondées sur des arbres de décision sont insensibles à l'échelle absolue des variables, contrairement aux réseaux de neurones ou aux méthodes à distance. Le pipeline travaille donc directement sur les observables physiques brutes.

## B.3 Protocole d'apprentissage

Le protocole d'entraînement conditionne la validité des performances reportées : il doit garantir qu'aucune information de l'échantillon d'évaluation n'a influencé le modèle, directement ou indirectement.

### Découpage en trois ensembles

Les données sont séparées en trois sous-ensembles disjoints, selon un découpage **stratifié** qui conserve les proportions relatives des trois classes. Dans un premier temps, 20 % des événements sont extraits aléatoirement pour constituer l'échantillon de **test** indépendant. Les 80 % restants sont ensuite redivisés pour en extraire un ensemble de **validation** représentant 20 % de cette portion, soit 16 % du total. La répartition finale est donc :

$$\text{train} = 64\%, \qquad \text{validation} = 16\%, \qquad \text{test} = 20\%.$$

L'ensemble d'entraînement ajuste les paramètres internes du modèle. L'ensemble de validation sert pendant l'apprentissage à surveiller la convergence et à déclencher l'arrêt anticipé. L'ensemble de test n'est utilisé qu'une seule fois, à la fin, pour estimer les performances reportées au chapitre 3 ; il n'intervient ni dans l'entraînement, ni dans le choix des hyperparamètres. Le découpage repose sur une graine fixée (`random_state` = 42), ce qui garantit la reproductibilité exacte des ensembles d'un lancement à l'autre.

### Absence de fuite d'information

Cette séparation stricte est ce qui protège les résultats d'un artefact de sur-apprentissage. Deux précautions la complètent. D'une part, le rééquilibrage des classes par SMOTE, décrit ci-dessous, est appliqué **uniquement à l'ensemble d'entraînement** : les ensembles de validation et de test restent tels quels, faute de quoi des événements synthétiques interpolés pollueraient l'estimation des performances. D'autre part, l'arrêt anticipé étant piloté par la validation, cet ensemble participe indirectement à la sélection du modèle et ne peut donc pas servir à mesurer la généralisation — d'où la nécessité du troisième ensemble, le test, qui reste totalement isolé.

### Fonction de coût et arrêt anticipé

Le modèle prédit pour chaque événement $i$ un vecteur de probabilités $\mathbf{p}_i = (p_{i1}, \ldots, p_{iK})$ avec $\sum_k p_{ik} = 1$. L'apprentissage minimise la **cross-entropy multiclasse** :

$$\mathscr{L} = -\frac{1}{N} \sum_{i=1}^{N} \sum_{k=1}^{K} y_{ik} \log(p_{ik}),$$

où $y_{ik} = 1$ si l'événement $i$ appartient à la classe $k$ et 0 sinon. Cette perte pénalise fortement les prédictions confiantes mais incorrectes ; sa minimisation augmente la probabilité attribuée à la vraie classe et améliore la calibration des sorties. Dans le contexte pion/proton, elle revient à apprendre les régions de l'espace des observables où les deux signatures se chevauchent partiellement.

L'entraînement est interrompu lorsque la perte de validation ne s'améliore plus pendant **50 itérations consécutives**, le modèle conservé étant celui de meilleure performance sur validation. Cette procédure sélectionne automatiquement le nombre d'arbres, évite une complexification inutile et limite le sur-apprentissage. La Figure B.1 montre l'évolution des pertes d'entraînement et de validation : les deux courbes décroissent régulièrement et restent proches, la perte de validation se stabilisant autour de $\sim 0.61$ sans divergence marquée — signe d'un apprentissage stable.

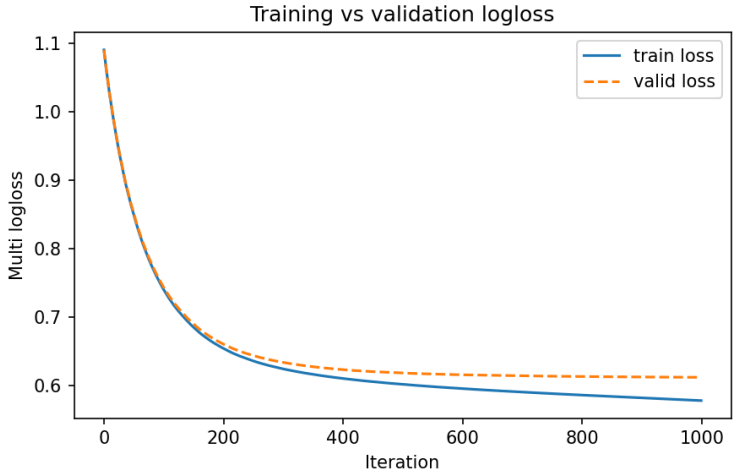



**FIGURE B.1.** Évolution de la fonction de coût *multi-logloss* sur les ensembles d'entraînement et de validation au cours de l'apprentissage LightGBM.

## B.4 Rééquilibrage des classes par SMOTE

Les échantillons simulés étant de tailles comparables, de légères fluctuations peuvent néanmoins apparaître après nettoyage et découpage. La méthode **SMOTE** (*Synthetic Minority Over-sampling Technique*) génère des exemples supplémentaires dans les régions peu peuplées de l'espace des variables : pour une observation minoritaire $\mathbf{x}_i$, un voisin proche $\mathbf{x}_j$ de même classe est sélectionné, puis un point synthétique est construit par interpolation,

$$\mathbf{x}_{\text{new}} = \mathbf{x}_i + \lambda(\mathbf{x}_j - \mathbf{x}_i), \qquad \lambda \in [0,1],$$

ce qui renforce la densité de la classe minoritaire sans duplication d'événements existants. Le procédé améliore en principe la stabilité de l'apprentissage et le rappel des classes minoritaires, tout en réduisant le biais vers la classe majoritaire.

Les données simulées étant ici relativement équilibrées, SMOTE relève davantage de la précaution méthodologique que de la correction indispensable. Les gains mesurés étant restés limités, et la génération d'événements synthétiques risquant d'introduire des corrélations artificielles ou de modifier localement la structure statistique des données, cette stratégie n'a pas été retenue dans la chaîne

principale.

## B.5 Modèle et hyperparamètres

Le classificateur repose sur `LightGBM`, méthode d'agrégation séquentielle d'arbres de décision où chaque nouvel arbre corrige les erreurs résiduelles du modèle courant. Ses performances dépendent fortement du choix des hyperparamètres, qui contrôlent conjointement la capacité d'apprentissage et la régularisation. Les valeurs retenues sont données au Tableau B.1.

**TABLE B.1.** Hyperparamètres retenus pour le classificateur LightGBM.

| Paramètre | Valeur | Rôle |
|---|---|---|
| `learning_rate` | 0.01 | Amplitude de correction de chaque nouvel arbre ; une valeur faible améliore la généralisation. |
| `n_estimators` | 1000 | Nombre maximal d'arbres construits (borné en pratique par l'arrêt anticipé). |
| `num_leaves` | 63 | Nombre maximal de feuilles par arbre ; contrôle la finesse des séparations. |
| `max_depth` | $-1$ | Profondeur non contrainte explicitement. |
| `min_child_samples` | 30 | Nombre minimal d'événements dans une feuille terminale. |
| `subsample` | 0.8 | Fraction d'événements tirée à chaque itération. |
| `colsample_bytree` | 0.8 | Fraction de variables candidates par arbre. |
| `reg_alpha` | 0.1 | Pénalisation $L_1$. |
| `reg_lambda` | 0.1 | Pénalisation $L_2$. |

Ce jeu privilégie un compromis entre pouvoir de séparation, robustesse au bruit statistique, temps d'entraînement raisonnable et stabilité entre différents découpages. Une recherche automatique par grille (`GridSearchCV`) est également disponible dans le script, mais n'a été utilisée que lors de campagnes d'optimisation spécifiques.

Plusieurs axes d'optimisation restent envisageables et n'ont pas été explorés systématiquement : ajustement fin des hyperparamètres, pondération spécifique des classes ou des erreurs de classification, calibration des probabilités de sortie (*Platt scaling*, régression isotonique), entraînement conditionné par tranches d'énergie, validation croisée sur plusieurs découpages, et optimisation directe de métriques équilibrées plutôt que de la seule accuracy. L'apprentissage par intervalles d'énergie paraît particulièrement pertinent, les signatures hadroniques évoluant sensiblement entre basse et haute énergie.

## B.6 Métriques d'évaluation

Les performances sont évaluées exclusivement sur l'ensemble de test. L'**accuracy** mesure la fraction d'événements correctement classés, Accuracy $= \frac{1}{N_{\text{test}}} \sum_i \mathbf{1}(\hat{y}_i = y_i)$, où $y_i$ est la vraie classe et $\hat{y}_i$ la classe prédite. La **matrice de confusion**, $C_{ij} = \#(\text{vraie classe} = i,\ \text{prédite} = j)$, normalisée ligne par ligne pour donner des probabilités conditionnelles, identifie précisément les confusions $\pi^- / p$, les confusions avec les $K_L^0$ et les asymétries entre classes. L'**AUC ROC one-vs-rest** caractérise la capacité de séparation de chaque classe à seuil variable, et les **histogrammes des probabilités prédites** renseignent sur le degré de confiance des décisions. L'accuracy équilibrée, moyenne non pondérée des rappels par classe, complète l'accuracy globale en la rendant insensible aux effectifs relatifs — c'est la métrique de référence retenue au chapitre 3.

# Annexe C

# Classification hadronique par réseau de neurones graphique

Cette annexe détaille l'étude exploratoire par réseau de neurones graphique (GNN) présentée à la section 3.6 : construction des graphes, architecture, protocole d'entraînement et limites de l'implémentation. Contrairement à l'approche tabulaire, le réseau exploite directement la topologie des hits, sans passer par des variables reconstruites manuellement.

## C.1 Données et prétraitement des nœuds

Deux variantes ont été étudiées : la séparation binaire pion/proton et la classification multiclasse incluant les kaons. Les fichiers d'entrée sont des tableaux `CSV` où chaque ligne représente un hit avec ses coordonnées spatiales, son information temporelle et le seuil semi-digital franchi.

Le code prévoit un découpage *train* / *validation* / *test* au niveau des **événements** et non des hits, chaque événement recevant un identifiant unique construit à partir de son numéro et de son espèce. Cette précaution évite que les hits d'un même événement soient répartis entre plusieurs sous-échantillons. La configuration documentée utilise un découpage stratifié `StratifiedShuffleSplit` de 70 %/10 %/20 %. Son application effective à l'entraînement final ne peut pas être contrôlée sans les entrées. La variable temporelle est discrétisée au centième d'unité,

$$t \longrightarrow \frac{\lfloor 100\, t \rfloor}{100},$$

ce qui limite les fluctuations numériques trop fines tout en conservant l'information utile.

Chaque hit est décrit par ses informations brutes $(x,\ y,\ z,\ t,\ \mathrm{thr})$, avec $\mathrm{thr} \in \{1,2,3\}$. Les coordonnées spatiales sont transformées par un `RobustScaler` — fondé sur la médiane et l'intervalle interquartile, donc moins sensible aux valeurs extrêmes qu'une standardisation classique — ajusté *uniquement* sur l'échantillon d'entraînement. La variable temporelle, de distribution non gaussienne, est régularisée par un `QuantileTransformer`, et le seuil est encodé en *one-hot*. Le vecteur d'entrée de chaque nœud comporte ainsi **7 composantes**.

## C.2 Construction du graphe

Chaque événement est converti en graphe orienté reliant les hits selon un critère de proximité spatiale et de causalité longitudinale, afin de reconstruire une topologie cohérente avec la propagation de la gerbe.

Pour chaque nœud $i$, on retient ses $k = 8$ plus proches voisins au sens de la distance sur coordonnées

normalisées,

$$d_{ij}^2 = (x'_i - x'_j)^2 + (y'_i - y'_j)^2 + (z'_i - z'_j)^2,$$

parmi les seuls hits situés en amont du développement : la **contrainte causale** $z_j < z_i$ interdit les arêtes entre régions tardives et précoces, qui n'auraient pas de sens physique. Une **fenêtre temporelle** $|t_i - t_j| < \Delta t$, avec $\Delta t = 2.0$, élimine enfin les connexions incompatibles avec la chronologie du dépôt. Le graphe résultant associe à chaque événement un ensemble de nœuds porteurs de leurs sept caractéristiques et un ensemble d'arêtes locales cohérentes en profondeur comme en temps, ce qui permet au réseau d'exploiter la morphologie tridimensionnelle sans imposer de discrétisation en voxels.

## C.3 Architecture et entraînement

Le classificateur combine plusieurs opérateurs de convolution sur graphe afin de capturer à la fois les corrélations locales entre hits voisins, les motifs directionnels de la gerbe et des structures plus globales. Le vecteur d'entrée est d'abord projeté dans un espace latent de dimension $d_{\text{hidden}} = 64$ par une couche linéaire suivie d'une activation `GELU`, $\mathbf{h}^{(0)} = \text{GELU}(W_0\mathbf{x} + b_0)$. Une couche `GATConv` à **quatre têtes d'attention** pondère ensuite différemment les voisins d'un nœud selon leur importance dans la structure locale ; une couche `TAGConv` agrège l'information sur plusieurs ordres de voisinage, étendant le champ réceptif à des corrélations de moyenne portée ; une couche `GraphConv` raffine enfin la représentation. Chacune est suivie d'une normalisation `GraphNorm` et d'une activation ReLU.

Les embeddings de nœuds sont convertis en une représentation unique de l'événement par concaténation de deux agrégations,

$$\mathbf{g} = [\text{MaxPool}(\mathbf{h}),\ \text{MeanPool}(\mathbf{h})]\,,$$

le *max pooling* captant les signatures locales dominantes et le *mean pooling* l'activité moyenne. Un perceptron final — couche linéaire, `Dropout(0.3)`, activation `GELU`, sortie à trois neurones — produit les log-probabilités des trois classes.

L'apprentissage minimise la `Negative Log-Likelihood` multiclasses,

$$\mathscr{L} = -\frac{1}{N}\sum_{i=1}^{N} \log p_\theta(y_i \mid G_i),$$

où $G_i$ est le graphe de l'événement $i$ et $y_i$ sa classe vraie. L'optimisation utilise `AdamW` avec un taux initial $\text{lr} = 10^{-3}$ et une décroissance des poids $\lambda_{\text{wd}} = 10^{-4}$, sur des mini-lots de taille 64, pour un maximum de 50 époques. Un scheduler `ReduceLROnPlateau` divise le taux d'apprentissage par deux lorsque la perte de validation stagne pendant trois époques consécutives, et un arrêt anticipé (patience de 10 époques) retient le modèle maximisant l'accuracy de validation.

## C.4 Résultats, limites et perspectives

L'implémentation prévoit une évaluation par accuracy, matrice de confusion et courbes d'apprentissage. Cette étude ayant été engagée en fin de stage, elle est présentée comme une **preuve de faisabilité** de la représentation en graphes plutôt que comme une mesure finale des performances physiques du GNN.

Trois axes d'amélioration se dégagent. Le **volume statistique** est le levier le plus direct : la performance d'un modèle profond dépend fortement de la taille de l'échantillon, et une montée en statistique autoriserait des architectures plus expressives, aujourd'hui susceptibles de surapprendre. La **richesse des variables d'entrée** vient ensuite : le modèle n'exploite que position, temps et seuil, alors que les indices de couche $(I, J, K)$, des informations locales de densité, des voisinages multi-rayons ou des descripteurs hybrides issus de `ShowerAnalyzer` pourraient être ajoutés — une approche combinant variables expertes et apprentissage profond offrirait vraisemblablement le meilleur compromis. La **topologie du graphe**, enfin, repose ici sur un unique schéma $k$-NN causal à $k = 8$ ; des graphes dynamiques recalculés à chaque couche, un rayon fixe en distance physique, une connectivité hiérarchique entre couches ou des arêtes pondérées par distance et compatibilité temporelle constituent autant d'alternatives non explorées. La définition du graphe étant un choix arbitraire du concepteur, elle représente une source de systématique propre à cette classe de méthodes.

## C.5 Tableau récapitulatif

**TABLE C.1.** Résumé du pipeline de classification hadronique par réseau de neurones graphique.

| **Élément** | **Description** |
|---|---|
| Objectif | Classification supervisée binaire ou multiclasse des hadrons, selon la variante du code. |
| Type de données | Événements SDHCAL convertis en graphes, un graphe par événement. |
| Nœuds | Hits individuels du calorimètre. |
| Features des nœuds | Coordonnées spatiales normalisées, temps transformé, encodage one-hot du seuil semi-digital. |
| Dimension d'entrée | 7 variables par nœud. |
| Construction des arêtes | Voisinage $k$-NN causal avec $k = 8$, contrainte en profondeur et fenêtre temporelle $\Delta t = 2.0$. |
| Prétraitement | `RobustScaler` pour l'espace, `QuantileTransformer` pour le temps. |
| Architecture | Projection linéaire + `GATConv` + `TAGConv` + `GraphConv`. |
| Pooling global | Concaténation `global max pool` + `global mean pool`. |
| Classifieur final | MLP avec `Dropout`(0.3) et sortie à trois classes. |
| Fonction de coût | Negative Log-Likelihood multiclasses. |
| Optimiseur | `AdamW`, taux initial $10^{-3}$, weight decay $10^{-4}$. |
| Régularisation | Scheduler `ReduceLROnPlateau` + early stopping (patience = 10). |
| Découpage des données | 70 % entraînement, 10 % validation, 20 % test. |
| Métriques | Accuracy, matrice de confusion, courbes d'apprentissage. |
| Forces | Exploitation directe de la topologie 3D des gerbes, pas de features manuelles obligatoires. |
| Limites | Étude exploratoire nécessitant une comparaison contrôlée avec l'approche tabulaire. |
| Perspective | PID avancé, régression d'énergie, Particle Flow, modèles spatio-temporels. |

# Annexe D

# Régression de l'énergie avec LightGBM

Cette annexe décrit la mise en œuvre de la régression supervisée utilisée au chapitre 4 pour estimer l'énergie incidente à partir des descripteurs de gerbe. Deux modèles indépendants sont entraînés, l'un pour les pions $\pi^-$, l'autre pour les protons $p$, afin d'adapter la régression aux différences de développement des cascades. Le protocole général — découpage en trois ensembles, arrêt anticipé, absence de fuite d'information — est identique à celui du classificateur PID et détaillé en Annexe B.3 ; seules les spécificités de la régression sont reprises ici.

## D.1 Données et variables d'entrée

Les données proviennent de fichiers `ROOT` générés par la simulation du SDHCAL puis enrichis par les descripteurs de l'Annexe A. Chaque événement contient l'énergie vraie de la particule primaire, $E_{\text{true}} =$ `primaryEnergy`, ainsi que l'ensemble des observables géométriques, topologiques, semi-digitales et temporelles. Les variables retenues en entrée sont regroupées au Tableau D.1.

**Table D.1.** Variables d'entrée de la régression d'énergie et interprétation physique.

| Catégorie | Variables | Interprétation |
|---|---|---|
| Morphologie | `Radius`, `meanRadius`, `Zrms` | extension spatiale de la gerbe |
| Début / profondeur | `Begin`, `Xmax`, `Zbary` | position longitudinale |
| Densité | `Density`, `nhitDensity` | compacité locale |
| Seuils | `N3`, `sumThrTotal`, `ratioThr23` | contenu énergétique semi-digital |
| Clusters | `nCluster`, `MaxClustSize` | structure interne |
| Temps | `tMean`, `tMax` | développement temporel |
| Forme globale | `eccentricity3D`, `lambda1`, `lambda2` | anisotropie de la gerbe |

Le choix de ces variables repose sur leur sens physique vis-à-vis du dépôt d'énergie : certaines traduisent la quantité totale d'interactions visibles, d'autres permettent de corriger indirectement les fluctuations de développement de gerbe. L'approche multivariable exploite simultanément ces corrélations non linéaires, ce qu'une calibration analytique simple ne peut reproduire.

Le prétraitement suit la même logique qu'en Annexe B.2 : les événements contenant des valeurs non définies (`NaN`) ou infinies dans au moins une variable sont supprimés, ce qui évite les erreurs d'apprentissage, les divisions non physiques et les biais liés aux événements mal reconstruits. Le découpage sépare d'abord 80 % des événements pour l'apprentissage et 20 % pour le test, une fraction de validation étant ensuite extraite de l'ensemble d'apprentissage. L'ensemble de test n'intervient jamais dans l'optimisation des hyperparamètres.

## D.2 Apprentissage en espace logarithmique

La reconstruction directe de l'énergie sur une large plage dynamique pose plusieurs difficultés : dispersion croissante avec l'énergie, asymétrie des distributions résiduelles, et poids relatif plus fort des erreurs aux basses énergies. La cible de régression n'est donc pas $E$ mais sa transformée logarithmique,

$$y = \log(E_{\text{true}}),$$

le modèle apprenant $\hat{y} = f(\mathbf{x})$, l'énergie reconstruite étant obtenue par transformation inverse $E_{\text{reco}} = \exp(\hat{y})$.

Ce choix réduit la dynamique entre faibles et hautes énergies, homogénéise les erreurs relatives, stabilise l'apprentissage et diminue l'influence des événements extrêmes. Son intérêt physique est direct : une erreur absolue constante sur $\log E$ correspond approximativement à une erreur relative constante sur $E$, c'est-à-dire au comportement attendu d'une résolution calorimétrique. L'entraînement minimise une perte quadratique en espace logarithmique, complétée par une métrique personnalisée évaluant la résolution relative après retour dans l'espace physique, ce qui oriente l'optimisation vers une performance physiquement pertinente et non seulement vers une précision numérique.

## D.3 Modèle et hyperparamètres

Le régresseur repose sur un `LGBMRegressor`, adapté à la reconstruction calorimétrique par sa capacité à modéliser des dépendances non linéaires complexes, à exploiter les corrélations entre descripteurs, à gérer des variables hétérogènes avec peu de prétraitement et à fournir des importances de variables. La configuration retenue figure au Tableau D.2.

**TABLE D.2.** Hyperparamètres retenus pour la régression d'énergie.

| Paramètre | Valeur |
|---|---|
| `learning_rate` | 0.05 |
| `n_estimators` | 2000 |
| `num_leaves` | 127 |
| `max_depth` | illimité (−1) |
| `subsample` | 0.8 |
| `colsample_bytree` | 0.8 |
| `min_child_samples` | 20 |
| `reg_lambda` | 0.1 |

Ces valeurs assurent une bonne capacité d'apprentissage tout en limitant le sur-ajustement. Une recherche automatique par grille (`GridSearchCV`) sur le nombre de feuilles, la profondeur, le taux d'apprentissage et le nombre d'arbres est disponible mais n'a été utilisée que lors de campagnes d'optimisation spécifiques. Comme pour le classificateur, l'ensemble de validation sert à surveiller la convergence et à déclencher l'arrêt anticipé, deux métriques étant suivies : la perte quadratique (`l2`) et la métrique de résolution relative. La graine aléatoire est fixée pour garantir la reproductibilité.

## D.4 Métriques d'évaluation

Les performances sont évaluées sur l'ensemble de test. La **racine de l'erreur quadratique moyenne** mesure l'écart absolu typique et pénalise fortement les grandes erreurs :

$$\mathrm{RMSE} = \sqrt{\frac{1}{N}\sum_{i=1}^{N}\left(E_i^{\mathrm{reco}} - E_i^{\mathrm{true}}\right)^2}.$$

L'**erreur absolue moyenne** $\mathrm{MAE} = \frac{1}{N}\sum_i |E_i^{\mathrm{reco}} - E_i^{\mathrm{true}}|$ est plus robuste aux valeurs extrêmes, et le **coefficient de détermination** $R^2 = 1 - \sum(y_i - \hat{y}_i)^2 / \sum(y_i - \bar{y})^2$ quantifie la fraction de variance expliquée.

La quantité de base est le résidu relatif $r_i = (E_i^{\mathrm{reco}} - E_i^{\mathrm{true}})/E_i^{\mathrm{true}}$. Le biais et la résolution doivent être distingués :

$$\delta = \langle r \rangle, \qquad \frac{\sigma(E)}{E} = \sqrt{\frac{1}{N}\sum_i (r_i - \langle r \rangle)^2}.$$

La chaîne utilisée pendant l'étude enregistrait également la RMS autour de zéro, $\sqrt{\langle r^2 \rangle}$, qui combine ces deux contributions selon $\langle r^2 \rangle = \delta^2 + \sigma_r^2$. Les courbes de largeur fondées sur le cœur tronqué des distributions sont donc interprétées comme des indicateurs comparatifs, tandis que le biais est étudié séparément à partir de la moyenne de $r$.

Ces métriques globales sont complétées par des études différentielles en fonction de l'énergie incidente — linéarité, biais relatif et résolution par intervalle — qui constituent les résultats reportés au chapitre 4. Le pipeline produit automatiquement les courbes d'apprentissage, le profil de linéarité, la courbe de résolution, la déviation relative et l'importance des variables, et sauvegarde les modèles entraînés ainsi que les paramètres et performances de chaque campagne, ce qui assure la traçabilité des résultats d'une exécution à l'autre.

# Annexe E

# Reconstruction d'énergie par méthode paramétrique $\chi^2$

Cette annexe détaille la mise en œuvre de la méthode paramétrique du chapitre 4 : sélection des événements, procédure numérique de minimisation et calcul de l'énergie reconstruite. Le principe et la formulation étant exposés au corps du mémoire (section 4.3), seuls les éléments d'implémentation sont repris ici.

## E.1 Sélection des événements et prétraitement

Les fichiers d'entrée contiennent des échantillons simulés de pions négatifs et de protons dans la plage $1 \leq E_{\text{true}} \leq 130$ GeV ; seuls les événements de cet intervalle sont conservés pour la minimisation.

Une attention particulière est portée aux gerbes présentant une **fuite longitudinale** importante : les événements possédant au moins un hit dans la dernière couche instrumentée sont rejetés. Ce critère supprime les interactions insuffisamment contenues, pour lesquelles une partie de l'énergie quitte le calorimètre et biaiserait la calibration. C'est un point important pour l'interprétation des résultats : la calibration est donc établie sur des gerbes bien contenues, alors que l'échantillon d'évaluation, lui, ne l'est pas nécessairement aux plus hautes énergies.

Pour chaque événement retenu, seules quatre grandeurs sont nécessaires — $N_1$, $N_2$, $N_3$ et l'énergie primaire simulée $E_{\text{true}}$ — le nombre total de hits étant reconstruit par $N_{\text{hit}} = N_1 + N_2 + N_3$. Ce prétraitement évite que les événements mal contenus dégradent l'ajustement, garantit un domaine énergétique homogène et limite la calibration aux observables strictement nécessaires : la méthode reste ainsi volontairement simple, robuste et directement interprétable.

## E.2 Procédure numérique avec `TMinuit`

L'optimisation des neuf paramètres $(a_0, a_1, a_2, b_0, b_1, b_2, c_0, c_1, c_2)$ est réalisée avec la classe `TMinuit` de `ROOT` [24], historiquement très utilisée en physique des hautes énergies pour les ajustements multi-paramétriques non linéaires. Les paramètres sont initialisés à des valeurs de départ différentes selon l'espèce considérée, ce qui améliore la convergence en plaçant l'algorithme dans une région réaliste de l'espace des paramètres ; chaque coefficient est défini avec une valeur initiale, un pas numérique d'exploration et, le cas échéant, des bornes.

La minimisation utilise l'algorithme `MIGRAD`, méthode quasi-newtonienne exploitant les gradients locaux de la fonction objectif $S$. À convergence, `TMinuit` fournit les valeurs optimales des paramètres, leurs incertitudes estimées, la valeur minimale $S_{\min}$ et un indicateur d'état de la matrice de covariance. Le code récupère également le statut `istat`, interprété comme suit : 0 pour une matrice de covariance

indisponible, 1 pour une approximation grossière, 2 pour une matrice définie positive et 3 pour une estimation fiable et précise — une valeur élevée signalant donc une convergence robuste.

Ce choix d'outil est adapté au problème : le nombre de paramètres reste modéré, la fonction objectif est continue, les résultats sont physiquement interprétables et la méthode reste rapide sur de grands échantillons. Les corrélations entre coefficients ajustés, accessibles via la matrice de covariance, méritent une attention particulière : les neuf paramètres n'étant pas indépendants, l'interprétation individuelle de chacun reste limitée.

## E.3 Calcul de l'énergie reconstruite

Une fois les paramètres optimisés, la reconstruction s'applique événement par événement. Pour chaque interaction, le nombre total de hits $N_{\text{hit}}$ est calculé, puis les coefficients dépendant de la multiplicité,

$$\alpha = a_0 + a_1 N_{\text{hit}} + a_2 N_{\text{hit}}^2, \qquad \beta = b_0 + b_1 N_{\text{hit}} + b_2 N_{\text{hit}}^2, \qquad \gamma = c_0 + c_1 N_{\text{hit}} + c_2 N_{\text{hit}}^2,$$

avant d'obtenir $E_{\text{reco}} = \alpha N_1 + \beta N_2 + \gamma N_3$.

Cette écriture attribue un poids distinct aux hits selon leur seuil — dépôts les plus faibles au seuil 1, zones plus denses au seuil 2, cœur énergétique de la gerbe au seuil 3 — la dépendance en $N_{\text{hit}}$ ajustant automatiquement ces pondérations lorsque la taille de la gerbe croît avec l'énergie. La méthode est très rapide en inférence : après calibration, aucune minimisation supplémentaire n'est requise, la reconstruction se réduisant à quelques évaluations polynomiales suivies d'une combinaison linéaire.

## E.4 Chaîne PID + reconstruction paramétrique

Les figures E.1 et E.2 complètent la section 5.3 : elles présentent la linéarité et la résolution obtenues sur échantillon mixte lorsque l'identification par PID est suivie de la reconstruction paramétrique. Les valeurs commentées dans le corps du mémoire en sont extraites.

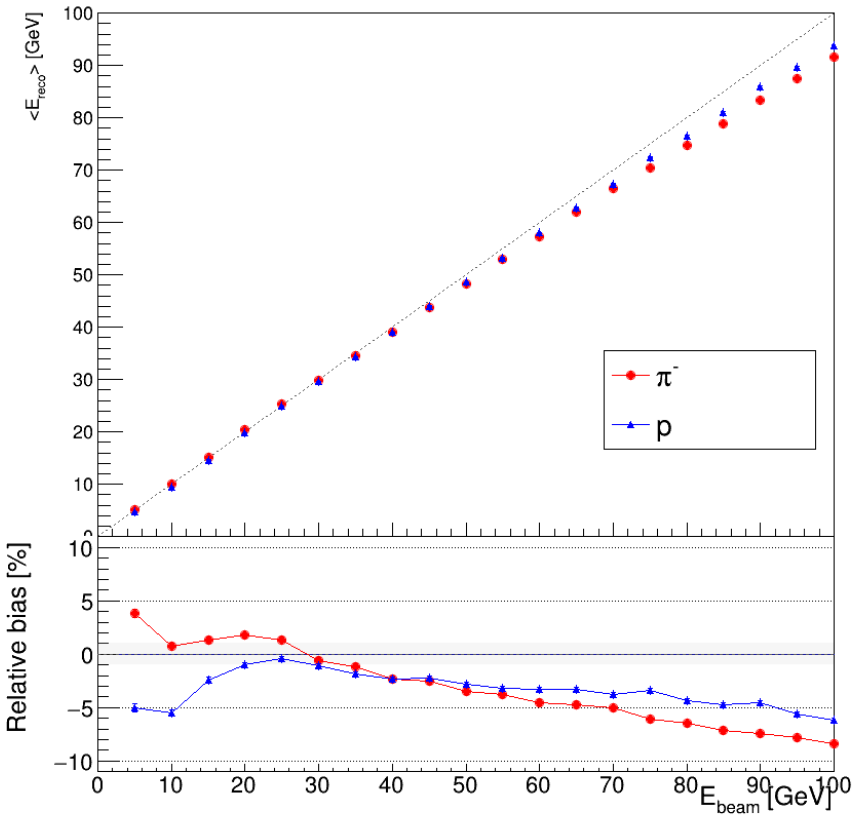



**FIGURE E.1.** Linéarité et biais relatif de la chaîne PID + méthode paramétrique sur échantillon mixte.

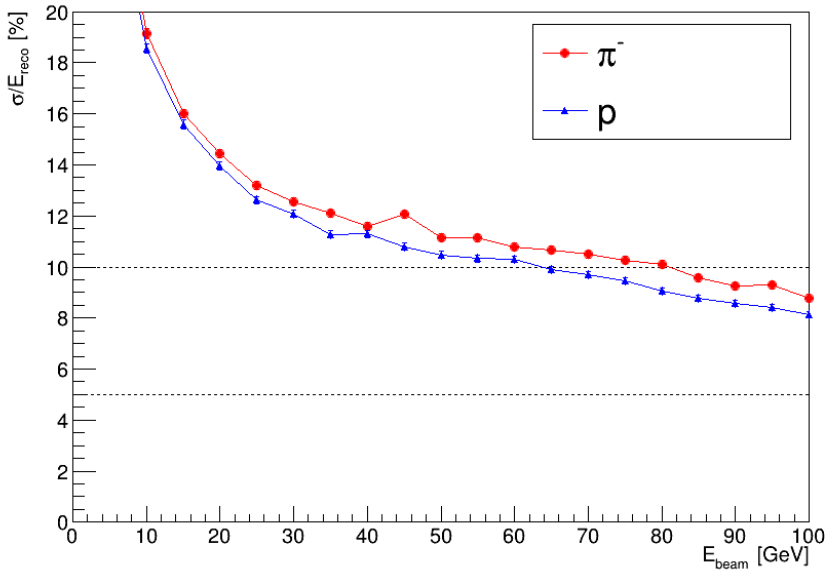



**FIGURE E.2.** Résolution relative de la chaîne PID + méthode paramétrique sur échantillon mixte.

## E.5 Forces et limites de la méthode

Cette approche est rapide, robuste, interprétable et peu coûteuse en calcul : une modélisation relativement simple suffit à obtenir des performances crédibles sur une large gamme énergétique, ce qui confirme la pertinence intrinsèque du concept semi-digital pour la calorimétrie hadronique. Elle reste cependant limitée face à la richesse réelle des données disponibles — géométrie fine des gerbes, densités locales, corrélations spatiales, signatures temporelles, fluctuations événement par événement — dont elle n'exploite aucune. C'est pourquoi elle constitue la référence de comparaison des approches supervisées plutôt qu'une fin en soi.

## E.6 Tableau récapitulatif

**TABLE E.1.** Résumé de la méthode paramétrique de reconstruction d'énergie par ajustement $\chi^2$.

| **Élément** | **Description** |
|---|---|
| Type de méthode | Calibration analytique semi-digitale fondée sur les compteurs de hits aux trois seuils. |
| Variables principales | $N_1$, $N_2$, $N_3$, avec $N_{\text{hit}} = N_1 + N_2 + N_3$. |
| Formule de reconstruction | $E_{\text{reco}} = \alpha N_1 + \beta N_2 + \gamma N_3$. |
| Dépendance des coefficients | $\alpha$, $\beta$, $\gamma$ paramétrés par des polynômes quadratiques en $N_{\text{hit}}$. |
| Nombre de paramètres | 9 paramètres libres : $(a_0, a_1, a_2, b_0, b_1, b_2, c_0, c_1, c_2)$. |
| Optimisation | Minimisation numérique avec `TMinuit` via l'algorithme `MIGRAD`. |
| Échantillons utilisés | Événements simulés de $\pi^-$ et protons entre 1 et 130 GeV. |
| Prétraitement | Rejet des événements présentant des hits dans la dernière couche instrumentée (fuite longitudinale). |
| Observables de sortie | Linéarité, biais relatif, résolution $\sigma(E)/E$, distributions reconstruites. |
| Forces | Rapide, robuste, interprétable, faible coût de calcul. |
| Limites | N'utilise pas la topologie détaillée des gerbes ni les corrélations complexes. |
| Rôle dans ce mémoire | Méthode baseline de référence comparée aux approches LightGBM. |

# Annexe F

# Compléments sur le détecteur et l'identification hadronique

Cette annexe regroupe des éléments écartés du corps du mémoire : les caractéristiques de l'électronique de lecture du prototype, le tableau comparatif des signatures calorimétriques attendues pour les trois espèces étudiées, et les corrélations entre variables d'entrée des modèles d'apprentissage.

## F.1 Électronique de lecture et acquisition

L'électronique de lecture est intégrée au plus près des chambres grâce aux ASICs HARDROC [32], conçus pour les détecteurs gazeux hautement segmentés. Chaque ASIC gère plusieurs dizaines de canaux et dispose d'une mémoire locale permettant de stocker les informations avant la lecture.

Cette architecture embarquée réduit le câblage externe et rend possible l'instrumentation d'un très grand nombre de canaux. Le système peut fonctionner en mode déclenché ou en mode sans déclenchement, selon les conditions expérimentales.

Une stratégie de *power pulsing* peut également être utilisée afin de réduire la consommation électrique pendant les périodes sans faisceau, un point important pour les futurs collisionneurs linéaires.

## F.2 Signatures calorimétriques attendues

Le Tableau F.1 détaille, espèce par espèce, les signatures moyennes attendues dans le SDHCAL à partir des différences physiques discutées à la section 3.1. Ces tendances sont statistiques : les fortes fluctuations des gerbes hadroniques font que les distributions correspondantes se recouvrent largement événement par événement, ce qui est précisément la difficulté que doit surmonter le classificateur.

**Table F.1.** Comparaison qualitative des signatures calorimétriques moyennes attendues dans le SDHCAL.

| **Caractéristique** | **Pion $\pi^-$** | **Proton $p$** | **Kaon neutre long $K_L^0$** |
|---|---|---|---|
| Signal d'ionisation avant gerbe | Oui | Oui | Non |
| Fraction électromagnétique moyenne | Élevée | Plus faible | Variable |
| Profondeur de première interaction | Plutôt précoce | Plutôt précoce | Plus variable |
| Développement longitudinal | Relativement précoce | Plus profond | Variable |
| Extension transverse | Modérée | Plus large | Variable |
| Fluctuations événement/événement | Importantes | Importantes | Très importantes |

## F.3 Corrélations entre variables d'entrée

La Figure F.1 présente la matrice de corrélation de Pearson calculée sur l'ensemble des variables d'entrée des modèles d'apprentissage, tous événements confondus. Plusieurs groupes cohérents s'y dessinent, qui correspondent aux familles de descripteurs définies en Annexe A.

Les variables d'**activité globale et de compacité** — `Thr1`, `Thr2`, `Thr3`, `NClusters`, `Nmax`, `AvgClustSize`, `MaxClustSize` et `Density` — présentent des corrélations modérées à fortes, ce qui est attendu puisqu'elles mesurent toutes, sous des formes différentes, l'intensité locale ou globale de la gerbe. Les descripteurs **longitudinaux** (`Begin`, `Zbary`, `Zrms`, `Xmax`, `z0_fit`) sont positivement corrélés entre eux, décrivant conjointement la position de départ et l'évolution de la cascade en profondeur. Les variables de **forme géométrique** ($\lambda_1$, $\lambda_2$, `eccentricity3D`) sont liées par leur rôle commun dans la description de l'anisotropie spatiale. Les variables **temporelles** (`tMin`, `tMean`, `tSpread`), enfin, ne sont que faiblement à modérément corrélées entre elles, mais montrent certains liens avec les variables longitudinales — ce qui suggère une connexion entre chronologie du signal et profondeur d'initiation de la gerbe.

Cette organisation indique que plusieurs variables transportent une information partiellement redondante. Une sélection plus compacte des observables — en conservant un représentant robuste par groupe corrélé, par exemple `Thr3` ou `Nmax`, `Density` ou `NClusters` — pourrait donc être envisagée sans perte majeure de performance, avec le bénéfice d'une dimension réduite, d'un entraînement plus rapide et d'une interprétation physique plus lisible.

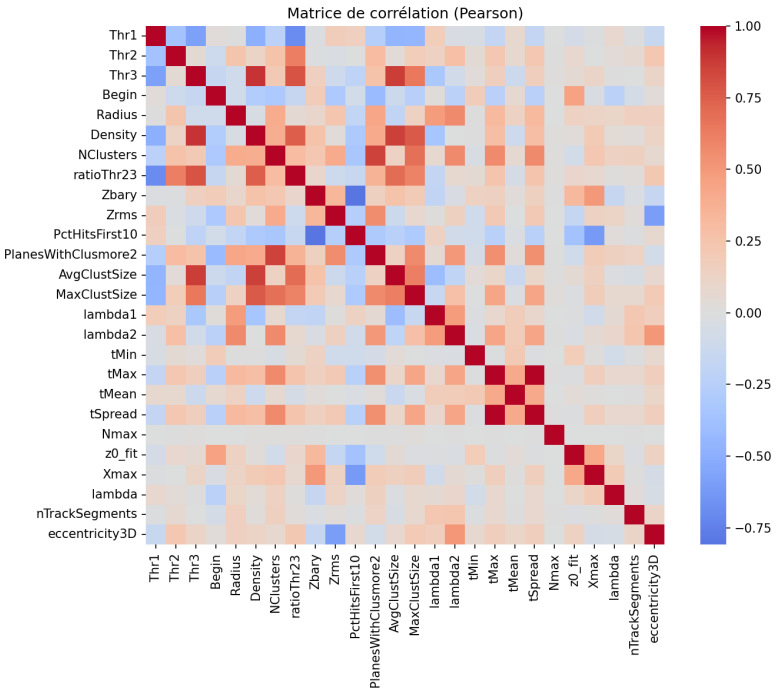



**FIGURE F.1.** Matrice de corrélation de Pearson des variables d'entrée utilisées pour la classification.

# Bibliographie


[1] David J. GRIFFITHS. *Introduction to Elementary Particles*. 2nd. Wiley-VCH, 2008.

[2] F. HALZEN et A. D. MARTIN. *Quarks and Leptons : An Introductory Course in Modern Particle Physics*. Wiley, 1984.

[3] M. E. PESKIN et D. V. SCHROEDER. *An Introduction to Quantum Field Theory*. Westview Press, 1995.

[4] S. Navas et AL. « Review of Particle Physics ». In : *Physical Review D* 110 (2024), p. 030001. DOI : 10.1103/PhysRevD.110.030001.

[5] M. A. THOMSON. « Particle Flow Calorimetry and the PandoraPFA Algorithm ». In : *Nuclear Instruments and Methods in Physics Research A* 611 (2009), p. 25-40. DOI : 10.1016/j.nima.2009.09.009.

[6] A. Hoecker et AL. « TMVA - Toolkit for Multivariate Data Analysis ». In : *PoS ACAT* 040 (2007). arXiv : physics/0703039.

[7] H. QU et L. GOUSKOS. « ParticleNet : Jet Tagging via Particle Clouds ». In : *Physical Review D* 101 (2020), p. 056019. DOI : 10.1103/PhysRevD.101.056019.

[8] M. Abdughani et AL. « Probing stop pair production at the LHC with graph neural networks ». In : *Journal of High Energy Physics* 08 (2019), p. 055. DOI : 10.1007/JHEP08(2019)055.

[9] CALICE COLLABORATION. « First results of the CALICE SDHCAL technological prototype ». In : *Journal of Instrumentation* 7.04 (2012), P04015. DOI : 10.1088/1748-0221/7/04/P04015.

[10] Hans BICHSEL. « Straggling in thin silicon detectors ». In : *Reviews of Modern Physics* 60 (1988), p. 663-699. DOI : 10.1103/RevModPhys.60.663.

[11] Glenn F. KNOLL. *Radiation Detection and Measurement*. Wiley, 2010.

[12] Richard WIGMANS. *Calorimetry : Energy Measurement in Particle Physics*. Oxford University Press, 2000.

[13] William R. LEO. *Techniques for Nuclear and Particle Physics Experiments*. Springer, 1994.

[14] C. W. FABJAN et F. GIANOTTI. « Calorimetry for particle physics ». In : *Reviews of Modern Physics* 75 (2003), p. 1243-1286. DOI : 10.1103/RevModPhys.75.1243.

[15] Walter HEITLER. *The Quantum Theory of Radiation*. 3rd. Oxford University Press, 1954.

[16] Bruno ROSSI. *High-Energy Particles*. Prentice Hall, 1952.

[17] CALICE COLLABORATION. « Construction and Commissioning of a Technological Prototype of a Semi-Digital Hadronic Calorimeter ». In : *Journal of Instrumentation* 10 (2015), P10039. DOI : 10.1088/1748-0221/10/10/P10039.

[18] ILC COLLABORATION. *International Linear Collider Technical Design Report*. 2013. arXiv : 1306.6327.

[19] J. S. MARSHALL et M. A. THOMSON. « The Pandora Software Development Kit for Pattern Recognition ». In : *European Physical Journal C* 75 (2015), p. 439. DOI : 10.1140/epjc/s10052-015-3659-3.

[20] M. Bedjidian et AL. « Performance of Glass Resistive Plate Chambers for a High Granularity Semi-Digital Hadron Calorimeter ». In : *Journal of Instrumentation* 6 (2011), P02001. DOI : 10.1088/1748-0221/6/02/P02001.

[21] CALICE COLLABORATION. « Description and stability of a RPC-based calorimeter in electromagnetic and hadronic shower environments ». In : *Journal of Instrumentation* 17.07 (2022), P07034. DOI : 10.1088/1748-0221/17/07/P07034.

[22] S. Agostinelli et AL. « GEANT4 : A Simulation Toolkit ». In : *Nuclear Instruments and Methods A* 506 (2003), p. 250-303. DOI : 10.1016/S0168-9002(03)01368-8.

[23] J. Allison et AL. « Recent Developments in Geant4 ». In : *Nuclear Instruments and Methods A* 835 (2016), p. 186-225. DOI : 10.1016/j.nima.2016.06.125.

[24] R. BRUN et F. RADEMAKERS. « ROOT : An Object Oriented Data Analysis Framework ». In : *Nuclear Instruments and Methods A* 389 (1997), p. 81-86. DOI : 10.1016/S0168-9002(97)00048-X.

[25] CALICE COLLABORATION. « Hadronic Energy Resolution of the Highly Granular SDHCAL Prototype ». In : *Journal of Instrumentation* 11 (2016), P04001. DOI : 10.1088/1748-0221/11/04/P04001.

[26] D. E. RUMELHART, G. E. HINTON et R. J. WILLIAMS. « Learning representations by back-propagating errors ». In : *Nature* 323 (1986), p. 533-536. DOI : 10.1038/323533a0.

[27] Ian GOODFELLOW, Yoshua BENGIO et Aaron COURVILLE. *Deep Learning*. MIT Press, 2016.

[28] T. HASTIE, R. TIBSHIRANI et J. FRIEDMAN. *The Elements of Statistical Learning*. Springer, 2009.

[29] G. Ke et AL. « LightGBM : A Highly Efficient Gradient Boosting Decision Tree ». In : *NeurIPS*. 2017.

[30] F. Scarselli et AL. « The Graph Neural Network Model ». In : *IEEE Transactions on Neural Networks* 20 (2009), p. 61-80. DOI : 10.1109/TNN.2008.2005605.

[31] J. Shlomi et AL. « Graph Neural Networks in Particle Physics ». In : *Machine Learning : Science and Technology* 2 (2021), p. 021001. DOI : 10.1088/2632-2153/abbf9a.

[32] F. Dulucq et AL. « HARDROC : Readout Chip for Calorimeters ». In : *IEEE Nuclear Science Symposium Conference Record*. 2010, p. 1678-1683. DOI : 10.1109/NSSMIC.2010.5873944.